

LAPORAN PRAKTIKUM
PRAKTIKUM PENAMBANGAN DATA
PERTEMUAN 2
EXPLORATORY DATA ANALYSIS DAN DATA PREPROCESSING



Disusun oleh:

Nama : Hafidz Rizqullah Prasetya
NIM : 24/535493/SV/24243
Kelas : PL5A1
Dosen Pengampu : Dr. Imam Fahrurrozi, S.T., M.Cs.

PROGRAM STUDI D-IV
TEKNOLOGI REKAYASA PERANGKAT LUNAK
DEPARTEMEN TEKNIK ELEKTRO DAN INFORMATIKA
SEKOLAH VOKASI
UNIVERSITAS GADJAH MADA
YOGYAKARTA
2026

Daftar Isi

Daftar Isi	2
Tujuan Praktikum	3
Dasar Teori	4
2.1 Artificial Intelligence dan Machine Learning	4
2.1.1 Artificial Intelligence	4
2.1.2 Machine Learning	4
2.2 Exploratory Data Analysis	5
2.3 Data Preprocessing	6
2.3.1 Pembersihan Data dan Imputasi	7
2.3.2 Encoding Atribut Kategorikal	8
2.3.3 Pembagian Dataset dan Scaling	9
Hasil dan Pembahasan	10
3.1 Percobaan Latihan Praktikum	10
3.1.1 Persiapan dan Impor Pustaka	10
3.2 Exploratory Data Analysis	11
3.2.1 Memuat Dataset Bank Churners	11
3.2.2 Pemeriksaan dan Pemisahan Kelas	11
3.2.3 Visualisasi Dataset Bank Churners	11
3.2.4 Visualisasi Dataset IoT	12
3.3 Data Preprocessing	12
3.3.1 Memuat dan Memeriksa Dataset Titanic	12
3.3.2 Distribusi, Korelasi, dan Kualitas Data	13
3.3.3 Imputasi Missing Value	14
3.3.4 Seleksi Fitur dan Encoding	14
3.3.5 Pembagian Dataset dan Scaling	14
3.4 Tugas dan Analisis Praktikum	15
3.4.1 Rencana Analisis Tugas	15
Kesimpulan	16
Daftar Pustaka	17

Tujuan Praktikum

1. Mahasiswa mampu memahami konsep dasar Artificial Intelligence (AI) dan Machine Learning (ML).
2. Mahasiswa mampu menerapkan Exploratory Data Analysis (EDA) untuk memahami karakteristik, distribusi, dan kualitas dataset.
3. Mahasiswa mampu menerapkan teknik dasar data preprocessing, meliputi penanganan missing value dan duplikasi, encoding, pembagian dataset, serta scaling fitur.

Dasar Teori


2.1 Artificial Intelligence dan Machine Learning

2.1.1 Artificial Intelligence

Artificial Intelligence (AI) adalah bidang ilmu komputer yang mengembangkan sistem agar mampu melakukan tugas yang umumnya membutuhkan kecerdasan manusia, seperti mengenali pola, belajar dari pengalaman, memahami informasi, dan mengambil keputusan. Dalam penerapannya, kualitas data sangat memengaruhi kemampuan sistem AI karena data menjadi dasar untuk menemukan pola dan menghasilkan prediksi [1].

2.1.2 Machine Learning

Machine Learning (ML) merupakan cabang AI yang memungkinkan komputer mempelajari pola dari data dan meningkatkan kinerjanya tanpa aturan yang diprogram secara eksplisit untuk setiap kasus. ML dapat dibagi menjadi *supervised learning*, *unsupervised learning*, dan *reinforcement learning*. Pada *supervised learning*, data memiliki label untuk keperluan klasifikasi atau prediksi. Pada *unsupervised learning*, model mencari struktur atau pola tersembunyi tanpa label. Sementara itu, *reinforcement learning* belajar melalui umpan balik berupa penghargaan dan hukuman [5].




Gambar 1: Klasifikasi Artificial Intelligence, Machine Learning, dan Deep Learning.

2.2 Exploratory Data Analysis

Exploratory Data Analysis (EDA) adalah proses memeriksa dan memahami dataset sebelum dilakukan pemodelan. EDA digunakan untuk mengetahui struktur data, tipe atribut, distribusi nilai, hubungan antarvariabel, outlier, missing value, dan duplikasi. Pemeriksaan dapat dilakukan menggunakan `head()`, `tail()`, `shape`, `describe()`, dan `isnull().sum()` pada DataFrame pandas.


Visualisasi membantu menyampaikan karakteristik data secara lebih mudah. Line plot digunakan untuk melihat perubahan atau tren, pie chart untuk proporsi, bar plot untuk membandingkan kategori, histogram untuk distribusi numerik, scatter plot untuk hubungan dua variabel, box plot untuk ringkasan kuartil dan outlier, serta violin plot untuk bentuk distribusi dan kepadatan data. Korelasi antarvariabel numerik juga dapat dihitung dengan `corr()` untuk mengetahui arah dan kekuatan hubungan linear [2, 6].



Gambar 2: Alur Exploratory Data Analysis mulai dari data mentah hingga menghasilkan kesimpulan.

2.3 Data Preprocessing


Data preprocessing merupakan serangkaian langkah untuk membersihkan dan mengubah data mentah menjadi data yang siap dianalisis atau digunakan oleh model ML. Tahap ini penting karena data yang tidak konsisten, tidak lengkap, atau memiliki skala berbeda dapat menurunkan kualitas analisis dan performa model.



Gambar 3: Contoh alur data preprocessing yang meliputi ekstraksi, standardisasi spasial, smoothing, pemilihan citra, dan normalisasi intensitas.

2.3.1 Pembersihan Data dan Imputasi


Missing value dapat diperiksa menggunakan `isnull().sum()`, sedangkan baris duplikat dapat diperiksa menggunakan `duplicated().sum()`. Missing value dapat ditangani dengan menghapus baris atau kolom yang bermasalah, atau dengan imputasi. Nilai median sering digunakan untuk atribut numerik karena lebih tahan terhadap outlier, sedangkan modus dapat digunakan untuk atribut kategorikal. Duplikasi perlu dihapus apabila merepresentasikan pengamatan yang tercatat lebih dari satu kali [3].



Gambar 4: Hubungan mean, median, dan mode pada distribusi data sebagai pertimbangan pemilihan metode imputasi.

2.3.2 Encoding Atribut Kategorikal

Algoritma ML umumnya memerlukan input numerik. One-hot encoding mengubah kategori menjadi beberapa kolom biner dan sesuai untuk kategori nominal. Label encoding mengubah kategori menjadi bilangan integer dan perlu digunakan secara hati-hati karena angka dapat dianggap memiliki urutan. Pada fitur kategorikal nominal, one-hot encoding biasanya lebih aman untuk mencegah model menganggap adanya hubungan ordinal yang sebenarnya tidak ada [5, 4].




Gambar 5: Perbandingan label encoding dan one-hot encoding pada variabel kategorikal.

2.3.3 Pembagian Dataset dan Scaling

Dataset biasanya dibagi menjadi data latih dan data uji menggunakan `train_test_split()`. Data latih digunakan untuk membangun model, sedangkan data uji digunakan untuk mengukur kemampuan generalisasi model. Parameter pembagian harus disesuaikan dengan instruksi praktikum, misalnya 80:20.

Scaling digunakan agar fitur numerik berada pada skala yang sebanding. *Standardization* menggunakan rata-rata dan simpangan baku sehingga data memiliki rata-rata mendekati nol dan simpangan baku mendekati satu. Sementara itu, *normalization* seperti Min-Max Scaling memetakan nilai ke rentang tertentu, umumnya 0 sampai 1. Parameter scaler harus di-fit pada data latih saja, kemudian digunakan untuk mentransformasi data uji agar tidak terjadi kebocoran informasi [7, 8].



Gambar 6: Alur pembagian features dan target menjadi data latih serta data uji menggunakan train-test split.

Hasil dan Pembahasan

3.1 Percobaan Latihan Praktikum


Pada bagian ini saya mendokumentasikan percobaan EDA dan data preprocessing sesuai langkah pada modul Pertemuan 2. Karena screenshot hasil eksekusi belum dilampirkan, setiap lokasi keluaran notebook diberi placeholder yang akan saya ganti setelah praktikum selesai.

3.1.1 Persiapan dan Impor Pustaka

Saya menyiapkan lingkungan Python dan mengimpor pandas untuk manipulasi data, NumPy untuk komputasi numerik, Matplotlib untuk visualisasi, serta scikit-learn untuk pre-processing.

```
1 import pandas as pd
2 import numpy as np
3 import matplotlib.pyplot as plt
4 from sklearn.model_selection import train_test_split
5 from sklearn.preprocessing import StandardScaler, MinMaxScaler, LabelEncoder
```

Listing .1: Impor pustaka praktikum.



Gambar 1: Impor pustaka yang digunakan dalam praktikum.


3.2 Exploratory Data Analysis

3.2.1 Memuat Dataset Bank Churners

Untuk latihan EDA, saya menggunakan dataset Bank Churners dari Kaggle. Dataset ini berisi informasi nasabah kartu kredit dengan label `Attrition_Flag` yang menunjukkan status nasabah. Dataset saya muat menggunakan `pd.read_csv()`.

```
1 df_churning = pd.read_csv('https://raw.githubusercontent.com/ganjar87/  
  ↳ data_science_practice/main/BankChurners.csv')  
2 df_churning.head()
```

Listing .2: Memuat dataset Bank Churners.




Gambar 2: Lima baris pertama dataset Bank Churners.

3.2.2 Pemeriksaan dan Pemisahan Kelas

Saya menggunakan `tail()` untuk memeriksa baris terakhir dataset. Setelah itu, saya memisahkan data menjadi nasabah aktif dan nasabah yang berhenti berdasarkan kolom `Attrition_Flag`.

```
1 df_churning.tail()  
2 existing_data = df_churning[df_churning['Attrition_Flag'] == 'Existing Customer']  
3 attrited_data = df_churning[df_churning['Attrition_Flag'] == 'Attrited Customer']
```

Listing .3: Pemeriksaan akhir dan pemisahan kelas.




Gambar 3: Pemeriksaan baris terakhir dan pemisahan kelas nasabah.

3.2.3 Visualisasi Dataset Bank Churners

Saya membuat line chart, pie chart, bar plot, dan stacked bar plot untuk melihat tren serta perbandingan kategori. Untuk data numerik, saya menggunakan histogram, scatter plot,

box plot, dan violin plot. Visualisasi tersebut membantu saya mengamati distribusi usia, perbandingan status nasabah, serta kemungkinan outlier.




Gambar 4: Visualisasi EDA dataset Bank Churners.

3.2.4 Visualisasi Dataset IoT

Saya memuat dataset IoT dan memvisualisasikan perubahan kelembapan terhadap waktu menggunakan line chart.

```
1 df_iot = pd.read_csv('https://raw.githubusercontent.com/ganjar87/  
↪ data_science_practice/main/IoT.csv')  
2 plt.figure(figsize=(15, 3))  
3 plt.plot(df_iot['date'], df_iot['Humidity'])  
4 plt.xlabel('Date')  
5 plt.ylabel('Humidity')  
6 plt.show()
```

Listing .4: Visualisasi kelembapan dataset IoT.



Gambar 5: Perubahan kelembapan terhadap waktu pada dataset IoT.

3.3 Data Preprocessing

3.3.1 Memuat dan Memeriksa Dataset Titanic


Untuk latihan preprocessing, saya menggunakan dataset Titanic. Dataset ini memiliki target Survived. Saya memeriksa data awal, ukuran dataset, statistik deskriptif, dan distribusi target sebelum melakukan transformasi.

```

1 df = pd.read_csv('https://raw.githubusercontent.com/ganjar87/data_science_practice/
↪ main/train.csv')
2 df.head()
3 df.tail()
4 df.shape
5 df.describe()

```

Listing .5: Pemeriksaan awal dataset Titanic.



Gambar 6: Pemeriksaan awal dataset Titanic.

3.3.2 Distribusi, Korelasi, dan Kualitas Data


Saya membuat pie chart target dan histogram fitur numerik. Saya menghitung korelasi menggunakan `corr(numeric_only=True)` serta memeriksa missing value dan duplikasi. Hasil pemeriksaan ini menjadi dasar keputusan pembersihan data.

```

1 df['Survived'].value_counts().plot.pie(autopct='%.2f%%')
2 plt.show()
3 df.hist(figsize=(10, 8))
4 plt.show()
5 df.corr(numeric_only=True)
6 df.isnull().sum()
7 df.duplicated().sum()

```

Listing .6: Pemeriksaan distribusi dan kualitas data.




Gambar 7: Analisis distribusi, korelasi, dan kualitas dataset Titanic.

3.3.3 Imputasi Missing Value

Saya mengisi missing value pada Age menggunakan median karena median lebih tahan terhadap outlier. Kolom kategorikal Cabin dan Embarked saya isi menggunakan modus. Setelah itu, saya memeriksa kembali missing value.

```
1 df['Age'] = df['Age'].fillna(df['Age'].median())
2 df['Cabin'] = df['Cabin'].fillna(df['Cabin'].mode()[0])
3 df['Embarked'] = df['Embarked'].fillna(df['Embarked'].mode()[0])
4 df.isnull().sum()
```

Listing .7: Imputasi missing value.




Gambar 8: Pengecekan missing value setelah imputasi.

3.3.4 Seleksi Fitur dan Encoding

Saya memisahkan fitur dan target dengan menghapus kolom identitas atau kolom yang tidak digunakan. Atribut kategorikal Sex dan Embarked kemudian saya ubah menjadi numerik menggunakan one-hot encoding. Saya juga mempelajari label encoding sebagai metode alternatif.

```
1 X = df.drop(['PassengerId', 'Name', 'Survived', 'Cabin', 'Ticket'], axis=1)
2 y = df['Survived']
3 X = pd.get_dummies(X, columns=['Sex', 'Embarked'], drop_first=True)
```

Listing .8: Seleksi fitur dan one-hot encoding.



Gambar 9: Hasil encoding atribut kategorikal.


3.3.5 Pembagian Dataset dan Scaling

Saya membagi dataset dengan proporsi 80:20. Data latih digunakan untuk proses pembelajaran, sedangkan data uji digunakan untuk evaluasi. Saya menerapkan standardization den-

gan StandardScaler dan normalization dengan MinMaxScaler. Scaler di-fit hanya pada data latih untuk mencegah data leakage.

```
1 X_train, X_test, y_train, y_test = train_test_split(  
2     X, y, test_size=0.2, random_state=42  
3 )  
4 standard_scaler = StandardScaler()  
5 X_train_standard = standard_scaler.fit_transform(X_train)  
6 X_test_standard = standard_scaler.transform(X_test)  
7 minmax_scaler = MinMaxScaler()  
8 X_train_normalized = minmax_scaler.fit_transform(X_train)  
9 X_test_normalized = minmax_scaler.transform(X_test)
```

Listing .9: Train-test split dan scaling.



Gambar 10: Pembagian dataset dan scaling fitur.

3.4 Tugas dan Analisis Praktikum

3.4.1 Rencana Analisis Tugas

Tugas EDA akan saya kerjakan menggunakan dataset *Credit Card Customers*. Saya akan membaca dataset, menjelaskan tujuan penggunaannya, menentukan atribut input dan label, serta mendeskripsikan setiap atribut. Tugas preprocessing akan saya kerjakan menggunakan dataset harga rumah Bengaluru dengan visualisasi, korelasi, statistik deskriptif, pemeriksaan missing value dan duplikasi, encoding, train-test split 80:20, serta scaling.

Kesimpulan

Berdasarkan praktikum yang telah saya lakukan, saya memahami beberapa hal berikut:

1. EDA digunakan untuk memahami struktur, distribusi, kualitas, dan hubungan antar-atribut sebelum pemodelan.
2. Data preprocessing diperlukan untuk menangani missing value dan duplikasi serta mengubah data ke format yang sesuai bagi algoritma ML.
3. Encoding mengubah atribut kategorikal menjadi representasi numerik, sedangkan train-test split dan scaling membantu menyiapkan data untuk pemodelan secara lebih objektif.

Dengan demikian, praktikum ini memberikan dasar yang penting bagi saya untuk melakukan pengolahan dan analisis data menggunakan Python.

Daftar Pustaka

- [1] Dicoding Indonesia, “Machine Learning Workflow: Di Balik Model AI yang Sukses,” 23 Oktober 2024. [Online]. Tersedia: <https://www.dicoding.com/blog/machine-learning-workflow-langkah-langkah-praktis-untuk-membangun-model-ai/>.
- [2] IBM, “Apa Itu Analisis Data Eksplorasi?” [Online]. Tersedia: <https://www.ibm.com/id-id/think/topics/exploratory-data-analysis>.
- [3] IlmudataPy, “Cara Menangani Missing Values di Project Data Science.” [Online]. Tersedia: <https://ilmudatapy.com/menangani-missing-values/>.
- [4] IlmudataPy, “2 Cara Implementasi One-Hot Encoding di Python.” [Online]. Tersedia: <https://ilmudatapy.com/one-hot-encoding-di-python/>.
- [5] Google for Developers, “Working with categorical data.” [Online]. Tersedia: <https://developers.google.com/machine-learning/crash-course/categorical-data>.
- [6] The pandas Development Team, “pandas.DataFrame.describe.” [Online]. Tersedia: <https://pandas.pydata.org/docs/reference/api/pandas.DataFrame.describe.html>.
- [7] Scikit-learn Developers, “Preprocessing data.” [Online]. Tersedia: <https://scikit-learn.org/stable/modules/preprocessing.html>.
- [8] Scikit-learn Developers, “Common pitfalls and recommended practices.” [Online]. Tersedia: https://scikit-learn.org/stable/common_pitfalls.html.