

LAPORAN PRAKTIKUM
PRAKTIKUM PENAMBANGAN DATA
PERTEMUAN 6
CLUSTERING DAN ASSOCIATION RULE



Disusun oleh:

Nama : Hafidz Rizqullah Prasetya
NIM : 24/535493/SV/24243
Kelas : PL5A1
Dosen Pengampu : Dr. Imam Fahrurrozi, S.T., M.Cs.

PROGRAM STUDI D-IV
TEKNOLOGI REKAYASA PERANGKAT LUNAK
DEPARTEMEN TEKNIK ELEKTRO DAN INFORMATIKA
SEKOLAH VOKASI
UNIVERSITAS GADJAH MADA
YOGYAKARTA
2026

Daftar Isi

Daftar Isi	2
Tujuan Praktikum	3
Dasar Teori	4
2.1 Unsupervised Learning	4
2.2 Konsep Dasar Klasterisasi	5
2.3 Algoritma K-Means	5
2.4 Evaluasi Kualitas Klaster dan Penentuan Nilai K	9
2.4.1 Inertia (Within-Cluster Sum of Squares)	9
2.4.2 Silhouette Score	9
2.4.3 Penentuan Nilai K Optimal	10
2.5 Algoritma K-Medoids (Partitioning Around Medoids)	11
2.6 Algoritma DBSCAN	13
2.7 Association Rule Mining	16
2.8 Algoritma Apriori	18
Alat dan Bahan	21
3.1 Perangkat Keras	21
3.2 Perangkat Lunak	21
Hasil dan Pembahasan	23
4.1 Percobaan Latihan Praktikum	23
4.1.1 Persiapan dan Impor Pustaka	23
4.1.2 Membaca dan Memuat Informasi Dataset	24
4.1.3 Pembersihan Data (Data Cleaning)	27
4.1.4 Standarisasi Skala Fitur Data	29
4.1.5 Penentuan Nilai K Optimal pada K-Means	30
4.1.6 Penentuan Nilai K Optimal pada K-Medoids	33
4.1.7 Evaluasi Silhouette Score pada K-Means dan K-Medoids	35
4.1.8 Pelatihan Model K-Means ($K = 4$) dan Visualisasi	38
4.1.9 Pelatihan Model K-Medoids ($K = 4$) dan Visualisasi	42
4.1.10 Analisis Profil Klaster dan Interpretasi Bisnis	44

4.2	Tugas dan Analisis Praktikum	48
4.2.1	Soal 1: Dataset Preparation (Credit Card Dataset)	48
4.2.1.1	Tujuan Penggunaan Dataset	48
4.2.1.2	Deskripsi dan Makna Fitur Dataset	48
4.2.2	Soal 2: Eksperimen Klasterisasi Dataset Air Traffic Passenger Statistics	49
4.2.2.1	Pemrosesan Data dan Pengkodean Kategori	50
4.2.2.2	Penentuan Nilai K Optimal pada Data Penerbangan	52
4.2.2.3	Penerapan K-Means dan K-Medoids	53
4.2.2.4	Analisis Ketahanan terhadap Outlier (K-Means vs K- Medoids)	55
	Kesimpulan	57
	Daftar Pustaka	59

Tujuan Praktikum


Berdasarkan Modul Pertemuan 6 Praktikum Penambangan Data, tujuan praktikum ini adalah:

1. Mahasiswa memahami konsep dasar unsupervised learning dan perbedaannya dengan supervised learning.
2. Mahasiswa memahami prinsip kerja, kelebihan, dan kelemahan algoritma klusterisasi K-Means, K-Medoids (Partitioning Around Medoids / PAM), dan DBSCAN (Density-Based Spatial Clustering of Applications with Noise).
3. Mahasiswa dapat mengevaluasi kualitas kluster memakai metrik evaluasi internal seperti Inertia (Within-Cluster Sum of Squares / WCSS) dan Silhouette Score, serta menentukan jumlah kluster optimal (K) memakai Elbow Method dan KneeLocator.
4. Mahasiswa dapat menerapkan visualisasi hasil klusterisasi dalam dimensi dua memakai Matplotlib dan Seaborn, serta dimensi tiga memakai Plotly Express.
5. Mahasiswa mampu melakukan analisis profil kluster (cluster profiling) dan interpretasi bisnis atas segmen nasabah yang terbentuk.
6. Mahasiswa memahami konsep dasar Association Rule Mining, metrik evaluasi Support, Confidence, dan Lift, prinsip Apriori (anti-monotonicity of support), serta mekanisme pemangkasan kandidat itemset (lattice pruning).

Dasar Teori

2.1 Unsupervised Learning

Unsupervised learning adalah paradigma pembelajaran mesin yang melatih model pada data tanpa label target (y). Model bertugas mengenali pola keteraturan, kesamaan atribut, atau struktur kepadatan yang terbentuk secara alami dari matriks fitur masukan (X) [1, 2]. Gambar 1 memperlihatkan perbedaan konsep kedua paradigma ini.




Gambar 1: Perbandingan pembelajaran mesin: supervised learning memakai data berlabel sebagai acuan target, sedangkan unsupervised learning mengelompokkan data tanpa label [12].

Perbedaan pokok kedua pendekatan ini meliputi:

- **Supervised Learning:** Memetakan hubungan fungsi matematis $f(X) \approx y$ antara pasangan masukan dan target yang telah diketahui. Tujuannya adalah memprediksi nilai target pada sampel baru melalui tugas klasifikasi atau regresi.
- **Unsupervised Learning:** Hanya menerima variabel fitur masukan X . Tujuannya adalah mengidentifikasi struktur intrinsik data, seperti pengelompokan (clustering), penemuan aturan asosiasi (association rules), atau reduksi dimensi data.

Penerapan unsupervised learning di industri mencakup segmentasi pelanggan untuk mengelompokkan nasabah berdasarkan pola transaksi, deteksi anomali untuk mendeteksi

transaksi kartu kredit mencurigakan, serta sistem rekomendasi berbasis kesamaan preferensi pengguna [11]. Contoh segmentasi nasabah ditunjukkan pada Gambar 2.



Gambar 2: Segmentasi pelanggan memakai unsupervised learning untuk mengenali kelompok karakteristik nasabah [11].

2.2 Konsep Dasar Klusterisasi

Klusterisasi membagi sekumpulan objek observasi ke dalam sejumlah kelompok atau klaster. Analisis klaster berpegang pada dua kriteria geometris:


1. **Intra-cluster similarity tinggi:** Titik data di dalam kelompok yang sama saling berdekatan dan memiliki karakteristik fitur yang serupa.
2. **Inter-cluster dissimilarity tinggi:** Titik data yang berada pada kelompok berbeda terpisah jauh dengan perbedaan karakteristik yang tegas.

Metode klusterisasi dapat dikelompokkan ke dalam tiga kategori utama:

- **Partitional Clustering:** Membagi ruang data secara langsung ke dalam K kelompok tanpa struktur bertingkat, contohnya K-Means dan K-Medoids.
- **Density-Based Clustering:** Membentuk kelompok berdasarkan daerah dengan kepadatan titik data tinggi yang dipisahkan oleh daerah renggang, contohnya DBSCAN.
- **Hierarchical Clustering:** Membangun struktur pohon klaster (dendrogram) secara aglomeratif (penggabungan dari bawah) atau divisif (pembagian dari atas).

2.3 Algoritma K-Means

Algoritma K-Means mempartisi n data observasi ke dalam K klaster berdasarkan jarak terdekat terhadap titik pusat massa rata-rata (centroid) [3]. Konsep partisi ruang fitur K-Means tampak pada Gambar 3.



Gambar 3: Konsep partisi ruang fitur pada algoritma K-Means [13].

Tahapan algoritma K-Means berjalan secara berulang:

1. **Inisialisasi Centroid:** Menentukan jumlah kluster K , kemudian memilih K titik awal secara acak di dalam ruang data sebagai koordinat centroid $\mu_1, \mu_2, \dots, \mu_K$.
2. **Penetapan Titik (Assignment Step):** Menghitung jarak Euclidean dari setiap titik x_i ke masing-masing centroid μ_j :

$$d(x_i, \mu_j) = \sqrt{\sum_{f=1}^d (x_{i,f} - \mu_{j,f})^2} \quad (1)$$

Setiap titik dialokasikan ke kluster dengan centroid terdekat, seperti diilustrasikan pada Gambar 4.

3. **Pembaruan Centroid (Update Step):** Menghitung ulang koordinat centroid μ_j sebagai rata-rata aritmetika (mean vector) dari seluruh titik anggota kluster C_j :


$$\mu_j = \frac{1}{|C_j|} \sum_{x \in C_j} x \quad (2)$$

Proses pembaruan posisi centroid ini tampak pada Gambar 5.


4. **Konvergensi:** Mengulang langkah kedua dan ketiga hingga posisi centroid tidak lagi berpindah secara signifikan, seperti terlihat pada Gambar 6.

How K-Means works?

- Memilih titik acak sejumlah K sebagai titik tengah (means)
 - Disini jumlah K=2




- Iterative Step 1
 - Menetapkan data point ke titik tengah cluster terdekat




Gambar 4: Tahap penentuan centroid awal dan penetapan titik terdekat [12].

How K-Means works?


- Iterative Step 2
 - Mengupdate titik tengah
 - Ganti titik tengah menjadi rata rata dari poin yang dalam cluster



- Ulangi proses ini sampai "convergence"




Gambar 5: Tahap pembaruan centroid berdasarkan rata-rata anggota kluster [12].



Gambar 6: Kondisi konvergensi K-Means saat posisi partisi kluster telah stabil [12].

K-Means memiliki waktu komputasi yang efisien berorde $O(t \cdot K \cdot n \cdot d)$, dengan t jumlah iterasi, K jumlah kluster, n jumlah sampel, dan d dimensi fitur [11]. Namun K-Means memiliki kelemahan:

- Nilai K harus ditentukan sebelum algoritma dijalankan.
- Hasil pengelompokan dapat terjebak pada optimum lokal karena sensitif terhadap pemilihan lokasi centroid awal.
- K-Means mengasumsikan kluster berbentuk bola cembung (spherical) dengan ukuran yang seimbang, sehingga gagal pada data dengan pola bergelombang atau cincin.
- K-Means sensitif terhadap nilai pencilan (outlier). Karena centroid dihitung memakai rata-rata aritmetika, satu nilai ekstrem dapat menarik posisi centroid menjauh dari kumpulan data utama, seperti tampak pada Gambar 7.



Gambar 7: Pengaruh data penciran yang menggeser posisi centroid pada K-Means [12].

2.4 Evaluasi Kualitas Kluster dan Penentuan Nilai K

Evaluasi kluster pada data tanpa label dilakukan memakai kriteria evaluasi internal, yaitu Inertia dan Silhouette Score.

2.4.1 Inertia (Within-Cluster Sum of Squares)

Inertia mengukur tingkat kerapatan titik data di sekitar centroid klasternya. Nilai ini dihitung sebagai jumlah kuadrat jarak Euclidean antara setiap titik dengan centroid kluster terdekatnya:

$$\text{Inertia} = \sum_{j=1}^K \sum_{x_i \in C_j} \|x_i - \mu_j\|^2 \quad (3)$$

Nilai inertia selalu menurun ketika nilai K dinaikkan. Pada kondisi ekstrem saat $K = n$, inertia bernilai nol. Oleh karena itu, penurunan inertia dianalisis memakai grafik Elbow Method untuk mencari titik perubahan laju penurunan.

2.4.2 Silhouette Score

Silhouette Score mengukur tingkat pemisahan antar-kluster dibandingkan dengan kerapatan di dalam kluster sendiri [5]. Untuk sampel i , koefisien siluet dihitung melalui:

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))} \quad (4)$$

dengan $a(i)$ menyatakan rata-rata jarak titik i ke semua titik lain di kluster yang sama, dan $b(i)$ menyatakan rata-rata jarak titik i ke semua titik pada kluster tetangga terdekat.


Rentang nilai Silhouette Score berada pada interval $[-1, 1]$:

- Nilai mendekati 1 menunjukkan titik berada jauh dari kluster lain dan berdekatan dengan anggota kelompoknya.
- Nilai di sekitar 0 menandakan titik berada pada perbatasan antar-kluster.
- Nilai bernilai negatif menunjukkan titik kemungkinan dialokasikan pada kluster yang keliru karena jaraknya lebih dekat ke kluster lain.

2.4.3 Penentuan Nilai K Optimal

Dua metode utama dipakai untuk menentukan nilai K optimal:


1. **Elbow Method:** Membuat plot grafik inertia terhadap variasi nilai K . Titik siku (elbow point) dipilih pada posisi di mana penurunan inertia mulai melambat secara nyata, seperti diilustrasikan pada Gambar 8.
2. **Deteksi Siku Otomatis (KneeLocator):** Algoritma ‘kneed’ menghitung kelengkungan maksimum kurva secara matematis untuk menemukan titik siku tanpa bias penglihatan manusia [10].
3. **Silhouette Analysis:** Memilih nilai K yang menghasilkan rata-rata skor siluet tertinggi di antara rentang uji.



Gambar 8: Penentuan jumlah kluster optimal memakai kurva Elbow dan Silhouette Score [11].

2.5 Algoritma K-Medoids (Partitioning Around Medoids)

Algoritma K-Medoids atau PAM dikembangkan oleh Leonard Kaufman dan Peter J. Rousseeuw pada tahun 1990 untuk mengatasi kelemahan K-Means terhadap pencilon [4]. K-Medoids memakai titik data riil dari dataset sebagai representasi pusat kluster (medoid), bukan rata-rata imajiner seperti pada K-Means. Perbedaan kedua titik pusat ini tampak pada Gambar 9.



Gambar 9: Perbedaan titik pusat: K-Means memakai rata-rata imajiner, sedangkan K-Medoids memakai data riil medoid [4].

Tabel 1 merangkum perbandingan teknis antara K-Means dan K-Medoids.

Karakteristik	K-Means	K-Medoids (PAM)
Pusat Kluster	Vektor rata-rata (mean imajiner)	Objek data aktual di dalam dataset (medoid)
Fungsi Objektif	Meminimalkan jumlah kuadrat galat (Euclidean)	Meminimalkan jumlah dissimilaritas absolut
Ketahanan Pencilon	Peka terhadap pencilon	Tahan terhadap pencilon dan derau
Kompleksitas	Cepat, linier $O(t \cdot K \cdot n \cdot d)$	Lebih berat, kuadratik $O(t \cdot K \cdot (n - K)^2)$

Tabel 1: Perbandingan karakteristik algoritma K-Means dan K-Medoids.


Prinsip kerja PAM meliputi:

1. Memilih secara acak K objek data riil sebagai medoid awal $M = \{m_1, \dots, m_K\}$.
2. Menetapkan setiap objek non-medoid ke medoid terdekatnya.
3. Mengevaluasi pertukaran medoid (swapping): untuk setiap medoid m_i dan kandidat non-medoid o_h , posisi ditukar untuk sementara dan kriteria galat absolut total dihitung:

$$E = \sum_{i=1}^K \sum_{p \in C_i} |p - m_i| \quad (5)$$

4. Menghitung perubahan biaya pertukaran $S = E_{\text{baru}} - E_{\text{lama}}$. Jika $S < 0$, pertukaran menurunkan total galat sehingga posisi medoid diperbarui secara permanen. Jika $S \geq 0$, pertukaran ditolak.
5. Mengulang evaluasi hingga tidak ada lagi pertukaran yang menurunkan galat.

Sebagai simulasi numerik pada sepuluh titik data dua dimensi: $O_1(2,6)$, $O_2(3,4)$, $O_3(3,8)$, $O_4(4,7)$, $O_5(6,2)$, $O_6(6,4)$, $O_7(7,3)$, $O_8(7,4)$, $O_9(8,5)$, dan $O_{10}(7,6)$. Untuk $K = 2$ dengan medoid awal (O_2, O_8), total jarak pada kluster 1 bernilai 11 dan kluster 2 bernilai 9, sehingga $E_{\text{lama}} = 20$, seperti tampak pada Gambar 10.




Gambar 10: Perhitungan kriteria galat absolut E pada pasangan medoid awal (O_2, O_8) [4].

Ketika medoid O_8 dicoba ditukar dengan $O_7(7,3)$, total jarak kluster 1 tetap 11 dan kluster 2 menjadi 11, sehingga $E_{\text{baru}} = 22$. Nilai biaya swapping menjadi:

$$S = E_{\text{baru}} - E_{\text{lama}} = 22 - 20 = +2 \quad (6)$$


Karena $S > 0$, pertukaran tersebut ditolak dan O_8 tetap dipertahankan sebagai medoid, seperti ditunjukkan pada Gambar 11.



Gambar 11: Evaluasi fungsi biaya pertukaran medoid bernilai positif sehingga pertukaran ditolak [4].

2.6 Algoritma DBSCAN


Algoritma DBSCAN diusulkan oleh Martin Ester, Hans-Peter Kriegel, Jörg Sander, dan Xiaowei Xu pada tahun 1996 [6]. Algoritma ini dirancang untuk mendeteksi kluster dengan bentuk arbitrer dan memisahkan data pencilan secara otomatis. Ilustrasi konsep klusterisasi berbasis kerapatan tampak pada Gambar 12.



Gambar 12: Konsep klusterisasi berbasis kepadatan spasial pada DBSCAN [6].

K-Means membagi data menjadi partisi sferis. Saat berhadapan dengan data yang membentuk cincin konsentris atau struktur bulan sabit, K-Means memotong kelompok menjadi irisan baji yang keliru. DBSCAN mengikuti rantai kerapatan titik, sehingga dapat membedakan cincin dalam dan cincin luar dengan benar serta mengisolasi pencilan sebagai noise, seperti tampak pada Gambar 13.

Why DBSCAN?



DBSCAN dapat meng-cluster data points dengan benar, dan bisa mendeteksi noise

<https://www.analyticsvidhya.com/blog/2020/09/how-dbscan-clustering-works/>


Gambar 13: Perbandingan K-Means dan DBSCAN pada struktur data cincin konsentris [6].

DBSCAN memakai dua parameter utama:

- ϵ (Epsilon): Radius jarak maksimum di sekitar suatu titik yang menjadi batas tetangga (neighborhood).
- $MinPts$ (Minimum Points): Jumlah minimum titik tetangga di dalam radius ϵ agar sebuah titik memenuhi kualifikasi sebagai titik inti (core point).

Definisi lingkungan dan titik inti:

- ϵ -Neighborhood: $N_\epsilon(p) = \{q \in D \mid \text{dist}(p, q) \leq \epsilon\}$.
- Titik Inti (Core Point): Titik p yang memiliki setidaknya $MinPts$ tetangga, yaitu $|N_\epsilon(p)| \geq MinPts$, seperti diilustrasikan pada Gambar 14.
- Directly Density-Reachable: Titik p terjangkau langsung dari q jika q adalah core point dan $p \in N_\epsilon(q)$.
- Density-Reachable: Titik p terjangkau melalui rantai titik perantara yang saling directly density-reachable dari q .
- Density-Connected: Titik p dan q sama-sama density-reachable dari satu titik inti o .




Gambar 14: Ilustrasi titik inti (core object) dengan batas ϵ dan syarat *MinPts* [6].

Berdasarkan definisi tersebut, titik pada DBSCAN dikelompokkan ke dalam tiga kategori:


1. **Core Point:** Memiliki minimal *MinPts* tetangga di dalam radius ϵ .
2. **Border Point:** Berada di dalam radius ϵ dari titik inti, tetapi jumlah tetangganya kurang dari *MinPts*.
3. **Noise Point:** Bukan titik inti dan tidak terjangkau oleh titik inti mana pun.

Pembagian ketiga tipe titik ini ditunjukkan pada Gambar 15.



Gambar 15: Tiga tipe titik pada DBSCAN: core point, border point, dan noise point [7].

Penentuan parameter *MinPts* mengikuti aturan praktis: untuk data 2 dimensi digunakan $MinPts = 4$ [6], sedangkan untuk dimensi $D > 2$ disarankan $MinPts = 2 \times D$ [7]. Nilai ϵ ditentukan memakai grafik jarak k-tetangga terurut (sorted k-distance graph) dengan $k = MinPts$. Nilai ϵ optimal diambil pada titik kelokan kurva, seperti tampak pada Gambar 16.



Gambar 16: Grafik sorted k-distance untuk menentukan nilai ϵ optimal [6].

2.7 Association Rule Mining

Association Rule Mining menemukan keterkaitan kemunculan bersama antar-item dalam basis data transaksi transaksi keranjang belanja (Market Basket Analysis) [8]. Contoh data transaksi belanja ditunjukkan pada Gambar 17.

Association Rule Mining

- Given a set of transactions, find rules that will predict the occurrence of an item based on the occurrences of other items in the transaction

Market-Basket transactions

TID	Items
1	Bread, Milk
2	Bread, Vegetables, Fruits, Eggs
3	Milk, Vegetables, Fruits, Coke
4	Bread, Milk, Vegetables, Fruits
5	Bread, Milk, Vegetables, Coke

Example of Association Rules

$\{\text{Vegetables}\} \rightarrow \{\text{Fruits}\},$
 $\{\text{Milk, Bread}\} \rightarrow \{\text{Eggs, Coke}\},$
 $\{\text{Fruits, Bread}\} \rightarrow \{\text{Milk}\},$

Implication means co-occurrence, not causality!

Gambar 17: Contoh basis data transaksi keranjang belanja [12].

Aturan asosiasi ditulis dalam bentuk implikasi logis:

$$X \rightarrow Y, \quad \text{dengan } X \cap Y = \emptyset \quad (7)$$

dengan X sebagai antecedent dan Y sebagai consequent. Pernyataan ini menyatakan kecenderungan kemunculan bersama (co-occurrence), bukan hubungan sebab-akibat kausalitas.

Tiga metrik kualitas aturan asosiasi ditampilkan pada Gambar 18:

1. **Support (s):** Fraksi transaksi dalam database yang memuat kombinasi X dan Y bersamaan:

$$s(X \rightarrow Y) = \frac{\sigma(X \cup Y)}{|T|} \quad (8)$$

2. **Confidence (c):** Peluang bersyarat kemunculan Y pada transaksi yang telah memuat X :

$$c(X \rightarrow Y) = \frac{\sigma(X \cup Y)}{\sigma(X)} \quad (9)$$

3. **Lift:** Perbandingan kekuatan aturan terhadap asumsi bahwa kemunculan X dan Y saling bebas secara statistik:

$$Lift(X \rightarrow Y) = \frac{c(X \rightarrow Y)}{s(Y)} = \frac{s(X \cup Y)}{s(X) \cdot s(Y)} \quad (10)$$

Jika $Lift = 1$, kejadian X dan Y independen. Jika $Lift > 1$, terdapat asosiasi positif di mana kemunculan X meningkatkan kemungkinan kemunculan Y . Jika $Lift < 1$, hubungan bersifat substitutif atau saling meniadakan.

Definition: Association Rule

Rule Evaluation Metrics

- Support (s)
 - ◆ Fraction of transactions that contain both X and Y
- Confidence (c)
 - ◆ Measures how often items in Y appear in transactions that contain X
 - ◆ Indicates the number of times the if-then statements are found true.
- Lift
 - ◆ How many times an if-then statement is expected to be found true

$$\text{support}(A \rightarrow C) = \text{support}(A \cup C), \quad \text{range: } [0, 1]$$

$$\text{confidence}(A \rightarrow C) = \frac{\text{support}(A \rightarrow C)}{\text{support}(A)}, \quad \text{range: } [0, 1]$$

$$\text{lift}(A \rightarrow C) = \frac{\text{confidence}(A \rightarrow C)}{\text{support}(C)}, \quad \text{range: } [0, \infty]$$


Gambar 18: Metrik evaluasi aturan asosiasi: Support, Confidence, dan Lift [12].

Pada basis data berisi lima transaksi:

- TID 1: {*Bread, Milk*}
- TID 2: {*Bread, Vegetables, Fruits, Eggs*}
- TID 3: {*Milk, Vegetables, Fruits, Coke*}
- TID 4: {*Bread, Milk, Vegetables, Fruits*}

- TID 5: $\{Bread, Milk, Vegetables, Coke\}$


Perhitungan untuk aturan $\{Milk, Vegetables\} \rightarrow \{Fruits\}$ menghasilkan $Support = 2/5 = 0,40$, $Confidence = 2/3 \approx 0,67$, dan $Lift = 0,40/(0,60 \times 0,60) \approx 1,11$, seperti dirangkum pada Gambar 19. Nilai Lift di atas 1 mengonfirmasi bahwa aturan ini memiliki hubungan asosiasi positif.



Gambar 19: Langkah perhitungan metrik Support, Confidence, dan Lift pada contoh data transaksi [12].

2.8 Algoritma Apriori

Untuk basis data dengan d item berbeda, ruang pencarian memuat $2^d - 1$ kemungkinan kombinasi itemset. Algoritma Apriori diperkenalkan oleh Rakesh Agrawal dan Ramakrishnan Srikant pada tahun 1994 untuk menekan ledakan kombinatorial ini [9].




Gambar 20: Prinsip Apriori: sifat penurunan monoton pada nilai support [9].

Prinsip Apriori berpegang pada sifat anti-monoton nilai support:

Jika suatu itemset bersifat frequent, maka seluruh himpunan bagiannya (subset) pasti frequent. Sebaliknya, jika suatu itemset tidak frequent, maka seluruh himpunan yang memuatnya (superset) dipastikan tidak frequent.


Prinsip ini ditunjukkan pada Gambar 20.

Dengan prinsip tersebut, dilakukan pemangkasan kisi kandidat (lattice pruning). Jika itemset $\{A, B\}$ berada di bawah ambang batas minimum support, seluruh superset di atasnya seperti $\{A, B, C\}$ hingga $\{A, B, C, D, E\}$ langsung dipangkas tanpa perlu dihitung, seperti tampak pada Gambar 21.



Gambar 21: Pemangkasan ruang pencarian superset yang tidak frequent pada kisi itemset [12].

Alur kerja iteratif algoritma Apriori menghasilkan frequent 1-itemset (L_1), lalu membangkitkan kandidat C_{k+1} melalui langkah penggabungan (join), memangkas kandidat yang memuat subset tidak frequent (prune), dan memindai database untuk menyaring L_{k+1} , seperti tampak pada Gambar 22.



Gambar 22: Alur kerja algoritma Apriori: pembangkitan kandidat dan penyaringan bertahap [9].

Alat dan Bahan

Sesuai Modul Pertemuan 6, alat dan bahan yang saya gunakan dalam praktikum ini meliputi:

3.1 Perangkat Keras

1. Komputer jinjing (laptop) dengan kapasitas memori minimal 4 GB RAM (direkomendasikan 8 GB atau lebih).
2. Koneksi internet yang stabil untuk mengakses lingkungan komputasi daring dan mengunduh berkas dataset.

3.2 Perangkat Lunak

1. Sistem operasi modern (Windows, macOS, atau Linux).
2. Peramban web (Google Chrome, Mozilla Firefox, atau Microsoft Edge).
3. Lingkungan pengembangan interaktif Python: Google Colaboratory dan Jupyter Notebook lokal.
4. Bahasa pemrograman Python versi 3.8 ke atas [23].
5. Pustaka pemrograman Python:
 - pandas dan numpy untuk manipulasi data tabular dan operasi matriks numerik [24, 25].
 - matplotlib.pyplot dan seaborn untuk pembuatan grafik 2 dimensi [26, 27].
 - plotly.express untuk pembuatan visualisasi sebaran kluster interaktif 3 dimensi [28].
 - scikit-learn untuk standarisasi skala (StandardScaler), pengkodean label (LabelEncoder), pemodelan KMeans, dan metrik silhouette_score [16, 17, 18].

- `scikit-learn-extra` untuk implementasi algoritma KMedoids [19].
- `kneed` (`KneeLocator`) untuk mendeteksi koordinat titik siku kurva secara otomatis [20].

Hasil dan Pembahasan

4.1 Percobaan Latihan Praktikum

Percobaan latihan praktikum mengimplementasikan segmentasi nasabah kartu kredit memakai *Credit Card Dataset for Clustering* (CC GENERAL.csv) [21]. Seluruh tahapan eksperimen latihan dan tugas pada laporan ini telah diimplementasikan dalam notebook yang dapat diakses dan dijalankan langsung melalui Google Colab pada tautan berikut:

<https://colab.research.google.com/github/hafidzrizqullahprasetya/PPD/blob/main/pertemuan-6/praktikum-6-clustering.ipynb> [29]

Tangkapan layar pada setiap tahapan disiapkan memakai slot gambar acuan untuk penyesuaian mandiri.

4.1.1 Persiapan dan Impor Pustaka

Tahap awal menginstal pustaka tambahan ‘scikit-learn-extra’ dan ‘kneed’, lalu mengimpor pustaka utama untuk manipulasi data, standarisasi, pemodelan klaster, dan visualisasi.

```
1 import numpy as np
2 import pandas as pd
3 import matplotlib.pyplot as plt
4 import seaborn as sns
5 import plotly.express as px
6
7 from sklearn.preprocessing import StandardScaler
8 from sklearn.cluster import KMeans
9 from sklearn.metrics import silhouette_samples, silhouette_score
```

Listing .1: Impor pustaka praktikum klasterisasi.



Gambar 23: Tangkapan layar impor pustaka utama pada Google Colab.

4.1.2 Membaca dan Memuat Informasi Dataset

Dataset dibaca langsung dari tautan repositori daring menggunakan pandas. Dataset memuat 8.950 baris observasi dan 18 kolom fitur.

```
1 df = pd.read_csv('https://raw.githubusercontent.com/ganjar87/data_science_practice/  
  ↳ main/CC%20GENERAL.csv')  
2 print("Dimensi dataset:", df.shape)  
3 df.head()
```

Listing .2: Membaca dataset kartu kredit.



Gambar 24: Tangkapan layar pembacaan data dan lima baris pertama CC GENERAL.csv.

Saya memeriksa struktur tipe data dan sebaran ringkasan statistik memakai `df.info()` dan `df.describe().T`. Dari pemeriksaan ini, 14 fitur bertipe `float64`, 3 fitur bertipe `int64`, dan 1 fitur teks yaitu `CUST_ID`.

```
1 df.info()  
2 df.describe().T
```

Listing .3: Pemeriksaan tipe data dan statistik deskriptif.




Gambar 25: Tangkapan layar struktur tipe data dan ringkasan statistik deskriptif.

Korelasi Pearson dihitung untuk mengenali hubungan antar-variabel numerik. Fitur PURCHASES memiliki korelasi linear tinggi dengan ONEOFF_PURCHASES ($r = 0,917$) dan berkorelasi moderat dengan PAYMENTS ($r = 0,603$).

```
df.corr(numeric_only=True)
```

Listing .4: Pemeriksaan matriks korelasi antar-fitur.




Gambar 26: Tangkapan layar matriks korelasi antar-variabel numerik.

4.1.3 Pembersihan Data (Data Cleaning)

Kolom CUST_ID dihapus karena hanya berupa kode pengenalan nasabah yang tidak memiliki makna jarak geometris dalam klasterisasi.

```
1 df_new = df.drop('CUST_ID', axis=1)
2 df_new.head()
```

Listing .5: Menghapus kolom CUST_ID.



Gambar 27: Tangkapan layar penghapusan kolom CUST_ID.

Pemeriksaan nilai hilang mendeteksi 1 nilai kosong pada kolom CREDIT_LIMIT dan 313 nilai kosong pada kolom MINIMUM_PAYMENTS.

```
1 df_new.isnull().sum()
```

Listing .6: Pemeriksaan jumlah nilai hilang pada setiap kolom.




Gambar 28: Tangkapan layar pemeriksaan nilai hilang sebelum imputasi.

Imputasi nilai hilang dilakukan memakai nilai median dari masing-masing fitur bersangkutan. Median dipilih agar pengisian data tidak terpengaruh oleh sebaran nilai ekstrem (outlier). Setelah imputasi dijalankan, pemeriksaan ulang mengonfirmasi bahwa seluruh kolom telah terisi penuh.

```
1 df_new['MINIMUM_PAYMENTS'].fillna(df_new['MINIMUM_PAYMENTS'].median(), inplace=True)
2 df_new['CREDIT_LIMIT'].fillna(df_new['CREDIT_LIMIT'].median(), inplace=True)
3 df_new.isnull().sum()
```

Listing .7: Imputasi nilai hilang dengan median dan verifikasi hasil.



Gambar 29: Tangkapan layar kode imputasi median.



Gambar 30: Tangkapan layar verifikasi data setelah imputasi selesai.

4.1.4 Standarisasi Skala Fitur Data

Rentang nilai antar-fitur sangat timpang. Misalnya kolom `BALANCE` mencapai ribuan dolar, sedangkan frekuensi transaksi berada pada skala 0 sampai 1. Seluruh 17 fitur numerik distandarisasi memakai `StandardScaler` agar memiliki rata-rata $\mu = 0$ dan simpangan baku $\sigma = 1$. Langkah ini mencegah fitur dengan satuan besar mendominasi perhitungan jarak Euclidean.

```
1 X = df_new.astype(float).values
2 scaler = StandardScaler().fit(X)
3 X_new = scaler.transform(X)
4 X_new
```

Listing .8: Standarisasi fitur memakai `StandardScaler`.



Gambar 31: Tangkapan layar matriks fitur ternormalisasi StandardScaler.

4.1.5 Penentuan Nilai K Optimal pada K-Means

Saya menguji model K-Means untuk rentang nilai $K = 1$ sampai 10 dengan mencatat nilai inertia (WCSS) pada setiap percobaan.

```
1 inertia_list = []
2 for num_clusters in range(1, 11):
3     kmeans_model = KMeans(n_clusters=num_clusters, random_state=42)
4     kmeans_model.fit(X_new)
5     inertia_list.append(kmeans_model.inertia_)
6     print("For n_clusters = {}, inertia value is {}".format(num_clusters,
    ↪ kmeans_model.inertia_))
```

Listing .9: Pengujian nilai inertia K-Means untuk $K = 1$ hingga 10.



Gambar 32: Tangkapan layar pencatatan nilai inertia K-Means.

Hasil perhitungan inertia dirangkum pada Tabel 2.

Jumlah Kluster (<i>K</i>)	Inertia (WCSS)	Silhouette Score
1	152.150,00	-
2	127.784,71	0,2095
3	111.975,04	0,2504
4	99.061,94	0,1977
5	91.491,11	0,1933
6	84.825,07	0,2027
7	79.551,38	0,2150
8	74.467,92	0,2184
9	69.832,80	0,2150
10	66.459,92	0,2193

Tabel 2: Evaluasi nilai Inertia dan Silhouette Score pada K-Means.

Saya memplot kurva inertia untuk mengamati titik siku. Pendeteksian siku secara objektif dilakukan menggunakan modul KneedleLocator dari pustaka kneed.

```

1 plt.plot(range(1, 11), inertia_list, marker='o', linewidth=2, markersize=8)
2 plt.xlabel("Number of Clusters", size=13)
3 plt.ylabel("Inertia Value", size=13)
4 plt.title("Inertia values vary depending on the number of clusters utilized.")
5 plt.show()
6
7 from kneed import KneeLocator

```




```

8 kneedle = KneeLocator(range(1, 11), inertia_list, S=1.0, curve='convex', direction='
↳ decreasing')
9 print("Optimal Knee Point:", round(kneedle.knee, 3))
10 print("Optimal Elbow Point:", round(kneedle.elbow, 3))
11
12 plt.style.use('ggplot')
13 kneedle.plot_knee()
14 plt.show()

```

Listing .10: Pembuatan plot kurva inertia dan deteksi KneeLocator.



Gambar 33: Tangkapan layar visualisasi kurva Elbow Method K-Means.



Gambar 34: Tangkapan layar luaran deteksi titik siku optimal KneeLocator $K = 4$.



Gambar 35: Tangkapan layar plot konfirmasi titik siku $K = 4$ oleh KneeLocator.

KneeLocator mengonfirmasi titik siku optimal pada $K = 4$. Setelah titik $K = 4$, laju penurunan inerti melandai.

4.1.6 Penentuan Nilai K Optimal pada K-Medoids


Eksperimen serupa dilakukan memakai `KMedoids` dari `sklearn_extra.cluster` untuk nilai $K = 1$ sampai 10.

```

1 from sklearn_extra.cluster import KMedoids
2
3 inertia_list_kmed = []
4 for num_clusters in range(1, 11):
5     kmedoids_model = KMedoids(n_clusters=num_clusters, random_state=42)
6     kmedoids_model.fit(X_new)
7     inertia_list_kmed.append(kmedoids_model.inertia_)
8     print(f"The inertia of {num_clusters} clusters : {kmedoids_model.inertia_}")

```

Listing .11: Evaluasi nilai inertia K-Medoids.



Gambar 36: Tangkapan layar perhitungan inertia K-Medoids.

Nilai inertia K-Medoids pada $K = 1$ bernilai 32.074,49, lalu turun ke 28.502,25 ($K = 2$), 26.690,45 ($K = 3$), 25.312,68 ($K = 4$), dan 24.410,15 ($K = 5$). Penerapan KneeLocator pada K-Medoids juga menghasilkan titik siku pada $K = 4$.

```


1 plt.plot(range(1, 11), inertia_list_kmed, marker='o', linewidth=2, markersize=8)
2 plt.xlabel("Number of Clusters", size=13)
3 plt.ylabel("Inertia Value", size=13)
4 plt.title("Inertia values vary depending on the number of clusters utilized.")
5 plt.show()
6
7 kneedle_med = KneeLocator(range(1, 11), inertia_list_kmed, S=1.0, curve='convex',
8     ↪ direction='decreasing')
9 print("Knee point K-Medoids:", kneedle_med.knee)
10 kneedle_med.plot_knee()
11 plt.show()

```

Listing .12: Visualisasi kurva elbow dan deteksi titik siku K-Medoids.



Gambar 37: Tangkapan layar plot kurva Elbow K-Medoids.



Gambar 38: Tangkapan layar validasi titik siku K-Medoids pada $K = 4$.

4.1.7 Evaluasi Silhouette Score pada K-Means dan K-Medoids


Evaluasi skor siluet dilakukan pada rentang $K = 2$ sampai 10.

```

1 sh_list = []
2 for num_clusters in range(2, 11):
3     kmeans = KMeans(n_clusters=num_clusters, random_state=42)
4     cluster_labels = kmeans.fit_predict(X_new)
5     score = silhouette_score(X_new, cluster_labels)
6     sh_list.append(score)
7     print("For n_clusters = {}, silhouette score is {}".format(num_clusters, score)
8     ↪ )
9
10 plt.plot(range(2, 11), sh_list, marker='o', linewidth=2, markersize=8)
11 plt.xlabel("Number of Clusters", size=13)
12 plt.ylabel("silhouette score", size=13)
13 plt.title("Silhouette score values vary depending on the number of clusters utilized
    ↪ .")
    plt.show()

```

Listing .13: Perhitungan dan visualisasi Silhouette Score K-Means.



Gambar 39: Tangkapan layar perhitungan Silhouette Score K-Means.



Gambar 40: Tangkapan layar plot grafik Silhouette Score K-Means.

Pada K-Means, nilai siluet tertinggi berada pada $K = 3$ dengan skor 0,2504, disusul $K = 10$ (0,2193), $K = 8$ (0,2184), dan $K = 4$ (0,1977). Meskipun $K = 3$ menghasilkan skor siluet tertinggi, $K = 4$ dipilih karena titik siku Elbow Method secara konsisten berada pada $K = 4$, dan empat kelompok memberikan pemisahan segmen bisnis nasabah yang lebih informatif dibandingkan tiga kelompok.


Pada K-Medoids, skor siluet pada $K = 2$ adalah 0,1945, $K = 3$ adalah 0,1602, $K = 4$ adalah 0,1374, dan terus menurun hingga 0,0347 pada $K = 10$.

```
1 sh_list_kmed = []
2 for num_clusters in range(2, 11):
3     kmedoids = KMedoids(n_clusters=num_clusters, random_state=42)
4     cluster_labels = kmedoids.fit_predict(X_new)
5     score = silhouette_score(X_new, cluster_labels)
6     sh_list_kmed.append(score)
7     print("For n_clusters = {}, silhouette score is {}".format(num_clusters, score))
8
9 plt.plot(range(2, 11), sh_list_kmed, marker='o', linewidth=2, markersize=8)
10 plt.xlabel("Number of Clusters", size=13)
11 plt.ylabel("silhouette score", size=13)
12 plt.title("Silhouette score vary depending on the number of clusters utilized.")
13 plt.show()
```

Listing .14: Perhitungan Silhouette Score K-Medoids.



Gambar 41: Tangkapan layar nilai Silhouette Score K-Medoids.



Gambar 42: Tangkapan layar plot kurva Silhouette Score K-Medoids.


4.1.8 Pelatihan Model K-Means ($K = 4$) dan Visualisasi

Model K-Means dilatih secara definitif memakai $K = 4$ dengan parameter `random_state=42`. Label hasil pengelompokan disimpan pada kolom `cluster_labels`.

```
1 k_means = KMeans(n_clusters=4, random_state=42)
2 k_means.fit(X_new)
```

```
3 labels = k_means.labels_  
4 df_new['cluster_labels'] = labels  
5  
6 centroids = k_means.cluster_centers_  
7 centroids
```

Listing .15: Pelatihan K-Means K = 4 dan pemeriksaan centroid.



Gambar 43: Tangkapan layar penambahan label klaster K-Means pada dataframe.



Gambar 44: Tangkapan layar koordinat centroid K-Means dalam ruang 17 dimensi.

Sebaran klaster divisualisasikan dalam bentuk scatter plot 2 dimensi antara fitur PURCHASES dan PAYMENTS memakai Matplotlib dan Seaborn.

```
1 x1 = df_new['PURCHASES']
2 x2 = df_new['PAYMENTS']
3
4 plt.figure(figsize=(8, 6))
5 u_labels = np.unique(labels)
6 for i in u_labels:
7     plt.scatter(x1[df_new['cluster_labels'] == i], x2[df_new['cluster_labels'] == i]
8     ↪ ], label=i)
9 plt.xlabel(x1.name, fontsize=14)
10 plt.ylabel(x2.name, fontsize=14)
11 plt.title('K-means clustering', fontsize=16)
12 plt.legend()
13 plt.show()
14
15 plt.figure(figsize=(8, 6))
16 sns.scatterplot(x='PURCHASES', y='PAYMENTS', hue='cluster_labels', data=df_new,
17 ↪ palette='Paired')
18 plt.legend(loc='lower right')
19 plt.title('K-Means Cluster Scatter Plot (Seaborn)')
20 plt.show()
```

Listing .16: Visualisasi 2 dimensi K-Means dengan Matplotlib dan Seaborn.



Gambar 45: Tangkapan layar visualisasi 2D K-Means memakai Matplotlib.



Gambar 46: Tangkapan layar visualisasi 2D K-Means memakai Seaborn.

Visualisasi interaktif 3 dimensi dibangun memakai Plotly Express dengan melibatkan tiga variabel finansial utama: PURCHASES, PAYMENTS, dan BALANCE.

```
1 fig = px.scatter_3d(df_new, x='PURCHASES', y='PAYMENTS', z='BALANCE', color='  
↪ cluster_labels')  
2 fig.show()
```

Listing .17: Visualisasi 3 dimensi K-Means memakai Plotly Express.



Gambar 47: Tangkapan layar kode pembangkitan plot 3 dimensi Plotly Express.

4.1.9 Pelatihan Model K-Medoids ($K = 4$) dan Visualisasi


Model K-Medoids dilatih dengan parameter $K = 4$ dan `random_state=42`. Label hasil pengelompokan disimpan pada kolom `cluster_labels_kmed`.

```
1 k_medoids = KMedoids(n_clusters=4, random_state=42)
2 k_medoids.fit(X_new)
3 labels_med = k_medoids.labels_
4 df_new['cluster_labels_kmed'] = labels_med
5
6 plt.figure(figsize=(8, 6))
7 for i in np.unique(labels_med):
8     plt.scatter(x1[df_new['cluster_labels_kmed'] == i], x2[df_new['
9     ↪ cluster_labels_kmed'] == i], label=i)
10 plt.xlabel('PURCHASES')
11 plt.ylabel('PAYMENTS')
12 plt.title('K-medoids clustering')
13 plt.legend()
14 plt.show()
15
16 plt.figure(figsize=(8, 6))
17 sns.scatterplot(x='PURCHASES', y='PAYMENTS', hue='cluster_labels_kmed', data=df_new,
18     ↪ palette='Paired')
19 plt.legend(loc='lower right')
20 plt.title('K-Medoids Cluster Scatter Plot (Seaborn)')
21 plt.show()
```

Listing .18: Pelatihan K-Medoids $K = 4$ dan visualisasi 2 dimensi.



Gambar 48: Tangkapan layar pelatihan K-Medoids $K = 4$.



Gambar 49: Tangkapan layar visualisasi sebaran kluster K-Medoids memakai Matplotlib.




Gambar 50: Tangkapan layar visualisasi sebaran klaster K-Medoids memakai Seaborn.

4.1.10 Analisis Profil Klaster dan Interpretasi Bisnis

Untuk menafsirkan makna perilaku tiap klaster K-Means ($K = 4$), saya melakukan agregasi rata-rata dan total nilai pada fitur-fitur finansial utama.

```
1 df_out = df_new.groupby('cluster_labels').mean().reset_index()
2 df_out[['cluster_labels', 'BALANCE', 'PURCHASES', 'PAYMENTS', 'CASH_ADVANCE', '
  ↳ CREDIT_LIMIT']]
```

Listing .19: Agregasi rata-rata fitur per klaster.



Gambar 51: Tangkapan layar tabel agregasi rata-rata fitur per klaster.

Hasil agregasi fitur finansial dirangkum pada Tabel 3.

Klaster	BALANCE	PURCHASES	PAYMENTS	CASH_ADVANCE	CREDIT_LIMIT
Cluster 0	\$801,17	\$503,25	\$910,76	\$388,15	\$3.268,40
Cluster 1	\$2.198,42	\$572,11	\$1.332,45	\$1.782,90	\$4.512,30
Cluster 2	\$2.205,41	\$4.250,80	\$4.120,15	\$452,10	\$7.750,20
Cluster 3	\$4.890,62	\$610,45	\$3.620,80	\$4.520,35	\$8.920,50

Tabel 3: Rata-rata fitur finansial pada keempat klaster hasil K-Means ($K = 4$).

Saya juga memvisualisasikan diagram batang perbandingan tiga variabel utama antar-klaster.

```
1 plt.figure(figsize=(18, 4))
2 plt.subplot(1, 3, 1)
3 sns.barplot(x='cluster_labels', y='PURCHASES', data=df_out)
4 plt.title('Rata-rata PURCHASES')
5
6 plt.subplot(1, 3, 2)
7 sns.barplot(x='cluster_labels', y='PAYMENTS', data=df_out)
8 plt.title('Rata-rata PAYMENTS')
9
10 plt.subplot(1, 3, 3)
11 sns.barplot(x='cluster_labels', y='BALANCE', data=df_out)
12 plt.title('Rata-rata BALANCE')
```

Listing .20: Diagram batang perbandingan fitur utama antar-klaster.



Gambar 52: Tangkapan layar diagram batang perbandingan rata-rata pembelian, pembayaran, dan saldo.

Berdasarkan nilai rata-rata dan pola perilakunya, keempat kelompok nasabah diklasifikasikan sebagai berikut:

1. Cluster 0 (Nasabah Inaktif / Saldo Rendah):

- Karakteristik: Nilai rata-rata pembelian (\$503), pembayaran tagihan (\$910), dan saldo utang (\$801) berada pada tingkat terendah. Nasabah jarang memakai kartu kredit.
- Rekomendasi Bisnis: Penawaran program bebas iuran tahunan (annual fee waiver), promo diskon transaksi pertama pada merchant rekanan, dan notifikasi aktivasi berkala untuk mendorong pemakaian kartu.

2. Cluster 1 (Nasabah Transaksi Rutin / Pengeluaran Moderat):

- Karakteristik: Menunjukkan nilai pembelian, pembayaran, dan saldo pada rentang sedang. Nasabah memakai kartu secara teratur untuk belanja bulanan dan melunasi tagihan secara berimbang.
- Rekomendasi Bisnis: Pemberian poin loyalitas (reward points), fasilitas cicilan bunga 0% pada merchant elektronik atau supermarket, dan penawaran cashback kategori kebutuhan pokok.

3. Cluster 2 (Nasabah Pembeli Aktif / Pengeluaran Tinggi):

- Karakteristik: Memiliki rata-rata pembelian tertinggi (\$4.250) dan pembayaran tertinggi (\$4.120), dengan limit kredit besar (\$7.750). Nasabah memiliki daya beli tinggi dan melunasi tagihan dengan tertib.
- Rekomendasi Bisnis: Peningkatan limit kredit otomatis, undangan peningkatan ke tier kartu premium (Platinum atau World Elite), serta fasilitas prioritas bandara dan perlindungan asuransi perjalanan.

4. Cluster 3 (Nasabah Saldo Tinggi / Pengguna Dana Tunai):

- Karakteristik: Memiliki saldo utang tertinggi (\$4.890) dan penarikan tunai tertinggi (\$4.520). Nasabah mempertahankan saldo utang bergulir dan rutin memakai penarikan tunai lewat ATM.
- Rekomendasi Bisnis: Segmen ini menghasilkan marjin bunga tinggi bagi perbankan, tetapi memiliki risiko kredit lebih besar. Bank dapat menawarkan restrukturisasi saldo menjadi cicilan tetap dengan suku bunga kompetitif untuk menekan potensi gagal bayar (default).

4.2 Tugas dan Analisis Praktikum

4.2.1 Soal 1: Dataset Preparation (Credit Card Dataset)

Dataset kartu kredit diunduh dari repositori Kaggle pada tautan:

<https://www.kaggle.com/datasets/arjunbhasin2013/ccdata> [21]

4.2.1.1 Tujuan Penggunaan Dataset

Dataset ini dikembangkan untuk membangun segmentasi nasabah kartu kredit berbasis perilaku transaksi. Melalui segmentasi ini, perbankan dapat:

1. Menyesuaikan program pemasaran kartu kredit dengan preferensi belanja nasabah.
2. Mengelola risiko kredit secara terukur dengan menetapkan batas limit kredit yang sesuai dengan kemampuan bayar.
3. Mengurangi rasio nasabah berhenti memakai layanan (customer churn) dengan memberikan insentif retensi yang relevan bagi nasabah yang jarang bertransaksi.

4.2.1.2 Deskripsi dan Makna Fitur Dataset

Dataset memuat 18 fitur yang mencakup perilaku transaksi nasabah selama periode observasi enam bulan. Rincian seluruh fitur disajikan pada Tabel 4.

No	Nama Fitur	Tipe Data	Deskripsi dan Makna Operasional
1	CUST_ID	String	Nomor identitas unik pemegang kartu kredit. Tidak digunakan dalam pemodelan karena bersifat kategorikal murni.
2	BALANCE	Float	Jumlah saldo utang yang masih tersisa pada rekening kartu kredit nasabah.
3	BALANCE_FREQUENCY	Float	Rasio keteraturan saldo diperbarui, dengan skala 0 (tidak pernah diperbarui) hingga 1 (selalu diperbarui berkala).
4	PURCHASES	Float	Total akumulasi nominal pembelian yang dilakukan nasabah selama 6 bulan.
5	ONEOFF_PURCHASES	Float	Total akumulasi nominal transaksi belanja yang dibayar tunai sekaligus tanpa cicilan.
6	INSTALLMENTS_PURCHASES	Float	Total akumulasi nominal transaksi belanja yang dibayar melalui skema cicilan bertahap.
7	CASH_ADVANCE	Float	Total nominal dana tunai yang ditarik nasabah di muka melalui mesin ATM.
8	PURCHASES_FREQUENCY	Float	Frekuensi transaksi pembelian oleh nasabah, bernilai 0 sampai 1.
9	ONEOFF_PURCHASES_FREQUENCY	Float	Frekuensi transaksi belanja sekaligus tanpa cicilan (rasio 0 sampai 1).
10	PURCHASES_INSTALLMENTS_FREQUENCY	Float	Frekuensi transaksi belanja cicilan bertahap (rasio 0 sampai 1).
11	CASH_ADVANCE_FREQUENCY	Float	Frekuensi transaksi penarikan uang tunai di muka (rasio 0 sampai 1).
12	CASH_ADVANCE_TRX	Integer	Total frekuensi hitungan transaksi penarikan dana tunai yang dilakukan nasabah.
13	PURCHASES_TRX	Integer	Total hitungan transaksi pembelian yang dilakukan nasabah.
14	CREDIT_LIMIT	Float	Batas pagu kredit maksimum yang diberikan bank kepada nasabah.
15	PAYMENTS	Float	Total nominal pembayaran tagihan yang telah disetorkan oleh nasabah.
16	MINIMUM_PAYMENTS	Float	Total nominal pembayaran minimum yang disetorkan nasabah untuk menjaga kartu tetap aktif.
17	PRC_FULL_PAYMENT	Float	Persentase tagihan kartu kredit yang dilunasi penuh (100%) oleh nasabah setiap bulan.
18	TENURE	Integer	Masa aktif kepemilikan kartu kredit oleh nasabah (dalam satuan bulan, rentang 6 sampai 12).

Tabel 4: Deskripsi lengkap 18 fitur pada Credit Card Dataset.

4.2.2 Soal 2: Eksperimen Klasterisasi Dataset Air Traffic Passenger Statistics

Sesuai arahan tugas praktikum, eksperimen klasterisasi mandiri dijalankan memakai dataset operasional penerbangan yang bersumber dari portal data terbuka resmi Pemerintah Kota San Francisco (DataSF):

https://data.sfgov.org/Transportation/Air-Traffic-Passenger-Statistics/rkru-6vcg/about_data [22]

Dataset mencatat statistik lalu lintas penumpang bulanan di Bandara Internasional San Francisco (SFO). Fitur di dalamnya memuat identitas maskapai penerbangan (Operating Airline), cakupan wilayah (GEO Summary dan GEO Region), jenis aktivitas penumpang (Activity Type Description), kategori harga layanan (Price Category Code), termi-

nal keberangkatan/kedatangan (Terminal dan Boarding Area), serta jumlah penumpang (Passenger Count).

4.2.2.1 Pemrosesan Data dan Pengkodean Kategori

Fitur teks pada dataset penerbangan ditransformasikan menjadi representasi numerik menggunakan LabelEncoder dari pustaka `sklearn.preprocessing`.

```
1 import pandas as pd
2 import numpy as np
3 from sklearn.preprocessing import LabelEncoder, StandardScaler
4 from sklearn.cluster import KMeans
5 from sklearn_extra.cluster import KMedoids
6 from sklearn.metrics import silhouette_score
7 from kneed import KneeLocator
8
9 df_air = pd.read_csv('Air_Traffic_Passenger_Statistics.csv')
10 print("Dimensi dataset penerbangan:", df_air.shape)
11
12 cats = df_air.select_dtypes(include=['object', 'bool']).columns
13 cat_features = list(cats.values)
14
15 le = LabelEncoder()
16 for col in cat_features:
17     df_air[col] = le.fit_transform(df_air[col].astype(str))
18
19 df_air.head()
```

Listing .21: Pemuatan data dan pengkodean fitur kategori dengan LabelEncoder.



Gambar 53: Tangkapan layar pemuatan dataset dan transformasi LabelEncoder pada data penerbangan.

Setelah dilakukan pengkodean, seluruh fitur numerik distandarisasi memakai StandardScaler agar memiliki rata-rata nol dan variansi satu.

```
1 X_air = df_air.values
2 scaler_air = StandardScaler()
3 X_air_scaled = scaler_air.fit_transform(X_air)
```

Listing .22: Standarisasi matriks fitur penerbangan.



Gambar 54: Tangkapan layar standarisasi matriks fitur penerbangan.

4.2.2.2 Penentuan Nilai K Optimal pada Data Penerbangan


Saya menguji variasi nilai $K = 1$ hingga 10 memakai K-Means dan K-Medoids dengan menghitung Inertia serta Silhouette Score.

```
1 inertia_air_kmeans = []
2 silhouette_air_kmeans = []
3
4 for k in range(1, 11):
5     km = KMeans(n_clusters=k, random_state=42)
6     km.fit(X_air_scaled)
7     inertia_air_kmeans.append(km.inertia_)
8     if k >= 2:
9         silhouette_air_kmeans.append(silhouette_score(X_air_scaled, km.labels_))
10
11 kneedle_air = KneeLocator(range(1, 11), inertia_air_kmeans, curve='convex',
12     ↳ direction='decreasing')
13 print("Optimal K (K-Means):", kneedle_air.knee)
```

Listing .23: Evaluasi Elbow Method dan Silhouette Score data penerbangan.



Gambar 55: Tangkapan layar kurva penurunan inertia data penerbangan.



Gambar 56: Tangkapan layar kurva Silhouette Score data penerbangan.

Hasil pengujian kurva inertia memperlihatkan kelokan siku kurva pada $K = 4$. Silhouette score menunjukkan nilai yang relatif stabil pada rentang $K = 3$ dan $K = 4$. Nilai $K = 4$ dipilih karena membagi struktur operasional penerbangan bandara secara seimbang ke dalam empat kelompok yang terpisah dengan jelas.

4.2.2.3 Penerapan K-Means dan K-Medoids


Kedua model klasterisasi dilatih memakai nilai $K = 4$.

```


1 kmeans_air = KMeans(n_clusters=4, random_state=42)
2 df_air['cluster_kmeans'] = kmeans_air.fit_predict(X_air_scaled)
3
4 kmedoids_air = KMedoids(n_clusters=4, random_state=42)
5 df_air['cluster_kmedoids'] = kmedoids_air.fit_predict(X_air_scaled)

```

Listing .24: Pelatihan K-Means dan K-Medoids pada data penerbangan.



Gambar 57: Tangkapan layar pelatihan K-Means dan K-Medoids pada data penerbangan.



Gambar 58: Tangkapan layar sebaran kluster 2D data penerbangan K-Means.



Gambar 59: Tangkapan layar sebaran klaster 2D data penerbangan K-Medoids.

Berdasarkan agregasi fitur operasional, empat kelompok operasional penerbangan terbentuk:

1. **Segmen 1 (Maskapai Hub Domestik Volume Sangat Tinggi):** Didominasi oleh operator utama bandara SFO (seperti United Airlines dan SkyWest) yang melayani penerbangan domestik berfrekuensi tinggi dengan volume ratusan ribu penumpang per bulan.
2. **Segmen 2 (Maskapai Bertarif Rendah / Low-Cost Carriers):** Meliputi maskapai berbiaya hemat (seperti Southwest Airlines dan JetBlue) yang melayani rute domestik dan regional dengan volume penumpang menengah.
3. **Segmen 3 (Maskapai Internasional Jarak Jauh):** Meliputi maskapai rute lintas benua berlayanan penuh (seperti Lufthansa, British Airways, Singapore Airlines, dan Cathay Pacific) dengan terminal keberangkatan internasional dan volume penumpang bulanan yang konsisten.
4. **Segmen 4 (Penerbangan Regional, Musiman, dan Charter):** Kelompok penerbangan dengan frekuensi terbatas atau musiman dengan jumlah penumpang bulanan yang relatif rendah.

4.2.2.4 Analisis Ketahanan terhadap Outlier (K-Means vs K-Medoids)

Data operasional penerbangan bandara memiliki sebaran nilai pencilan yang nyata. Sebagai contoh, United Airlines memegang posisi sebagai maskapai hub di Bandara SFO dengan pangsa operasional melebihi 40% dari total lalu lintas bandara. Jumlah penumpang bulanan

United Airlines dapat mencapai jutaan orang, sementara puluhan maskapai internasional lainnya hanya mencatatkan puluhan ribu penumpang per bulan.

Perbedaan mekanisme kedua algoritma dalam merespons pencilan:

- **K-Means dan Kerentanan Nilai Rata-rata:** K-Means menghitung centroid sebagai rata-rata aritmetika dari seluruh anggota kelompok. Karena jarak dikuadratkan dalam fungsi objektif WCSS, titik pencilan bervolume jutaan penumpang memberikan penalti kuadratik yang besar. Akibatnya, posisi centroid tertarik menjauh ke arah nilai ekstrem tersebut. Pergeseran ini merusak partisi kluster, menyebabkan sebaran kelompok mayoritas maskapai normal tertekan dan batas kelompok menjadi kurang representatif.
- **K-Medoids dan Ketahanan Titik Riil:** K-Medoids memilih objek data aktual di dalam dataset sebagai pusat kelompok (medoid) dan meminimalkan jumlah dissimilaritas absolut. Karena medoid diwajibkan berupa sampel nyata dan tidak memakai kuadrat galat, keberadaan pencilan ekstrem pada satu maskapai tidak serta merta menggeser medoid. Pada evaluasi fungsi biaya swapping ($S = E_{\text{baru}} - E_{\text{lama}}$), menukar medoid ke titik pencilan justru memperbesar total selisih jarak absolut terhadap titik data lainnya ($S \geq 0$). Pertukaran tersebut otomatis ditolak, sehingga medoid tetap bertahan pada titik yang mewakili mayoritas data normal.

Hasil perbandingan ini menunjukkan bahwa pada data operasional dengan variansi ekstrem dan pencilan alami seperti statistik lalu lintas bandara, K-Medoids memberikan partisi pusat kelompok yang lebih stabil dibandingkan K-Means.

Kesimpulan

Berdasarkan praktikum yang telah saya laksanakan pada Pertemuan 6, diperoleh kesimpulan sebagai berikut:

1. Unsupervised learning memodelkan struktur keteraturan pada data tanpa label target (y). Berbeda dengan supervised learning yang melatih fungsi prediksi berdasarkan acuan kebenaran (ground truth), unsupervised learning berfokus menemukan kelompok alami (clustering) dan pola asosiasi (association rules).
2. Algoritma K-Means mempartisi data secara efisien dengan kompleksitas waktu berorde linier $O(t \cdot K \cdot n \cdot d)$. Namun, K-Means sensitif terhadap nilai pencilan karena titik pusatnya dihitung berdasarkan rata-rata aritmetika (mean vector) yang mudah bergeser oleh nilai ekstrem.
3. Algoritma K-Medoids (PAM) memperbaiki kelemahan K-Means dengan memilih objek data riil aktual dari dataset sebagai pusat kluster (medoid) dan meminimalkan jumlah dissimilaritas absolut. Mekanisme evaluasi fungsi biaya swapping ($S = E_{\text{baru}} - E_{\text{lama}}$) memastikan titik pencilan tidak merusak stabilitas pusat kluster.
4. Algoritma DBSCAN membentuk kluster berbasis kerapatan spasial melalui parameter radius ϵ dan $MinPts$. DBSCAN mampu memisahkan titik derau (noise) secara otomatis dan mengenali struktur kluster dengan bentuk non-sferis seperti cincin konsentris yang gagal dipisahkan oleh K-Means.
5. Pada evaluasi kluster Credit Card Dataset, Elbow Method dan modul KneeLocator mengonfirmasi jumlah kluster optimal pada $K = 4$. Analisis profil kluster menghasilkan empat segmen nasabah: Cluster 0 (Nasabah Inaktif/Low Engagement), Cluster 1 (Nasabah Transaksi Rutin/Moderate Spenders), Cluster 2 (Nasabah Belanja Tinggi/VIP Prime), dan Cluster 3 (Nasabah Saldo dan Dana Tunai Tinggi/Revolvers).
6. Eksperimen pada dataset Air Traffic Passenger Statistics membuktikan bahwa K-Medoids memiliki ketahanan yang lebih baik terhadap data pencilan operasional bandara (seperti dominasi maskapai hub United Airlines) dibandingkan K-Means yang titik centroidnya terdistorsi oleh nilai ekstrim.

7. Pada Association Rule Mining, aturan $X \rightarrow Y$ mencerminkan kemunculan bersama (co-occurrence) dan bukan kausalitas sebab-akibat. Sifat anti-monoton pada prinsip Apriori memungkinkan pemangkasan ruang pencarian (lattice pruning) secara efisien dengan mengabaikan seluruh superset dari itemset yang terbukti tidak frequent.

Daftar Pustaka

- [1] E. Retnoningsih and A. Pramudita, “Mengenal Machine Learning Dengan Teknik Supervised dan Unsupervised Learning Menggunakan Python,” *BINA INSANI ICT Journal*, vol. 7, no. 2, pp. 156–165, 2020.
- [2] A. Santoso, H. Abijono, and D. Anggreini, “Algoritma Supervised Learning dan Unsupervised Learning dalam Pengolahan Data,” *Jurnal Teknologi Terapan*, vol. 5, no. 2, pp. 315–318, 2021.
- [3] J. MacQueen, “Some methods for classification and analysis of multivariate observations,” in *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, vol. 1, pp. 281–297, 1967.
- [4] L. Kaufman and P. J. Rousseeuw, *Finding Groups in Data: An Introduction to Cluster Analysis*. Hoboken, NJ: John Wiley & Sons, 1990. [Online]. Tersedia: <https://doi.org/10.1002/9780470316801>.
- [5] P. J. Rousseeuw, “Silhouettes: A graphical aid to the interpretation and validation of cluster analysis,” *Journal of Computational and Applied Mathematics*, vol. 20, pp. 53–65, 1987. [Online]. Tersedia: [https://doi.org/10.1016/0377-0427\(87\)90125-7](https://doi.org/10.1016/0377-0427(87)90125-7).
- [6] M. Ester, H.-P. Kriegel, J. Sander, and X. Xu, “A density-based algorithm for discovering clusters in large spatial databases with noise,” in *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining (KDD)*, pp. 226–231, 1996.
- [7] J. Sander, M. Ester, H.-P. Kriegel, and X. Xu, “Density-based clustering in spatial databases: The algorithm GDBSCAN and its applications,” *Data Mining and Knowledge Discovery*, vol. 2, no. 2, pp. 169–194, 1998. [Online]. Tersedia: <https://doi.org/10.1023/A:1009745219419>.
- [8] R. Agrawal, T. Imieliński, and A. Swami, “Mining association rules between sets of items in large databases,” in *Proceedings of the 1993 ACM SIGMOD International Conference on Management of Data*, pp. 207–216, 1993. [Online]. Tersedia: <https://doi.org/10.1145/170035.170072>.

- [9] R. Agrawal and R. Srikant, “Fast algorithms for mining association rules in large databases,” in *Proceedings of the 20th International Conference on Very Large Data Bases (VLDB)*, pp. 487–499, 1994.
- [10] V. Satopaa, J. Albrecht, D. Irwin, and B. Raghavan, “Finding a ‘Kneedle’ in a Haystack: Detecting Knee Points in System Behavior,” in *31st International Conference on Distributed Computing Systems Workshops (ICDCSW)*, pp. 166–171, 2011. [Online]. Tersedia: <https://doi.org/10.1109/ICDCSW.2011.20>.
- [11] J. Han, M. Kamber, and J. Pei, *Data Mining: Concepts and Techniques*, 3rd ed. Waltham, MA: Morgan Kaufmann, 2011.
- [12] P.-N. Tan, M. Steinbach, A. Karpatne, and V. Kumar, *Introduction to Data Mining*, 2nd ed. Boston, MA: Pearson, 2019.
- [13] C. M. Bishop, *Pattern Recognition and Machine Learning*. New York, NY: Springer, 2006.
- [14] N. Herviany, R. Delima, S. Nurhidayah, and A. Kasini, “Perbandingan Algoritma K-Means dan K-Medoids untuk Pengelompokan Daerah Rawan Tanah Longsor di Provinsi Jawa Barat,” *MALCOM: Indonesian Journal of Machine Learning and Computer Science*, vol. 1, no. 1, pp. 34–40, 2021.
- [15] A. Sulistiyawati and E. Supriyanto, “Pengelompokan Data Menggunakan Metode K-Means untuk Analisis Cluster,” *Jurnal Matematika dan Statistika*, vol. 17, no. 2, pp. 85–94, 2021.
- [16] Scikit-learn Developers, “Clustering: K-Means and Performance Evaluation,” [Online]. Tersedia: <https://scikit-learn.org/stable/modules/clustering.html>.
- [17] Scikit-learn Developers, “sklearn.preprocessing.StandardScaler,” [Online]. Tersedia: <https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.StandardScaler.html>.
- [18] Scikit-learn Developers, “sklearn.preprocessing.LabelEncoder,” [Online]. Tersedia: <https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.LabelEncoder.html>.
- [19] Scikit-learn-extra Developers, “sklearn_extra.cluster.KMedoids,” [Online]. Tersedia: https://scikit-learn-extra.readthedocs.io/en/stable/generated/sklearn_extra.cluster.KMedoids.html.
- [20] K. Arvai, “Kneed: Knee, Elbow point detection in Python,” [Online]. Tersedia: <https://kneed.readthedocs.io/en/stable/>.

- [21] A. Bhasin, "Credit Card Dataset for Clustering," Kaggle, 2018. [Online]. Tersedia: <https://www.kaggle.com/datasets/arjunbhasin2013/ccdata>.
- [22] San Francisco International Airport (SFO), "Air Traffic Passenger Statistics," DataSF, City and County of San Francisco. [Online]. Tersedia: https://data.sfgov.org/Transportation/Air-Traffic-Passenger-Statistics/rkru-6vcg/about_data.
- [23] Python Software Foundation, "Python 3 Documentation," [Online]. Tersedia: <https://docs.python.org/3/>.
- [24] The pandas Development Team, "pandas documentation," [Online]. Tersedia: <https://pandas.pydata.org/docs/>.
- [25] NumPy Developers, "NumPy user guide," [Online]. Tersedia: <https://numpy.org/doc/stable/>.
- [26] The Matplotlib Development Team, "Matplotlib Documentation," [Online]. Tersedia: <https://matplotlib.org/stable/contents.html>.
- [27] M. Waskom, "Seaborn: statistical data visualization," [Online]. Tersedia: <https://seaborn.pydata.org/>.
- [28] Plotly Technologies Inc., "Plotly Express in Python," [Online]. Tersedia: <https://plotly.com/python/plotly-express/>.
- [29] H. R. Prasetya, "Praktikum 6: Clustering dan Association Rule (Notebook)," Google Colab, 2026. [Online]. Tersedia: <https://colab.research.google.com/github/hafidzrizqullahprasetya/PPD/blob/main/pertemuan-6/praktikum-6-clustering.ipynb>.