

Session 6

Unsupervised Learning

Ganjar Alfian
Teknik Elektro dan Informatika
Sekolah Vokasi, Universitas Gadjah Mada
ganjar.alfian@ugm.ac.id

Table of Content

What will We Learn Today?


1. Unsupervised Learning
2. K-Means
3. K-Medoids
4. DBSCAN
5. Association Rule

Unsupervised Learning





Supervised vs Unsupervised

- **Supervised** = Mempelajari untuk memprediksi hasil.
 - Kita tahu target label-nya, sehingga kita membuat model yang bisa memprediksi label.
- **Unsupervised** = Mencari pola atau characteristic dari data.
 - Kita tidak tahu target label-nya, sehingga kita membuat model yang bisa mengelompokkan data.



Application of Unsupervised Learning

- Customer segmentation.
 - Memahami kelompok pelanggan yang berbeda untuk membangun pemasaran atau strategi bisnis lainnya.
- Anomaly detection.
- Recommender systems, yang mencoba mengelompokkan user dengan pola yang sama untuk memberi rekomendasi content yang mirip.




K-Means



K-Means

- K-means clustering algorithm mencoba mengelompokkan item ke dalam bentuk cluster.
- Jumlah kelompok direpresentasikan sebagai K .




How K-Means works?


1. **Memilih object sejumlah k** sebagai awalan titik tengah cluster
2. **Menetapkan setiap object** ke dalam cluster dengan titik tengah terdekat
3. **Mengupdate titik tengah cluster** sebagai nilai rata rata dari point yang ada dalam cluster
4. Kembali lagi ke Step 2, berhenti ketika tidak ada perubahan

How K-Means works?

- Memilih titik acak sejumlah K sebagai titik tengah (means)
 - Disini jumlah $K=2$





- Iterative Step 1
 - Menetapkan data point ke titik tengah cluster terdekat




How K-Means works?


- Iterative Step 2
 - Mengupdate titik tengah
 - Ganti titik tengah menjadi rata rata dari poin yang dalam cluster



- Ulangi proses ini sampai “convergence”



How K-Means works?



Evaluating clustering performance

1. Inertia

- Jumlah kuadrat (Sum of squared distance) jarak dari setiap titik (x_i) dengan cluster-nya (C_k).
- Jika inertia kecil, artinya poin dekat satu sama lain.

$$\sum_{i=1}^n (x_i - C_k)^2$$


2. Silhoutte score

- a : jarak rata-rata ke semua titik lain dalam clusternya.
- b : jarak rata-rata ke semua titik lain di cluster terdekat berikutnya.
- Score diatara -1 to 1. Bagus jika score mendekati 1.

$$SC = \frac{b-a}{\max(a,b)}$$


How to choose the K?

1. Elbow method



2. Silhouette score

- Semakin tinggi nilai, semakin baik



Discussion on the K-means

- **Keuntungan K-means**

- Mudah untuk di-implementasikan
- Mampu menangani dataset yang besar
- Generalisasi cluster untuk berbagai bentuk dan ukuran.


-

- **Kerugian K-means**

- Sensitive terhadap outliers.
- Memilih nilai k butuh usaha yang lebih.
- Ketika jumlah dimensi meningkat, skalabilitasnya menurun.

A Problem of K-Means

- Sensitive terhadap outliers
- Outlier: objek dengan nilai yang sangat besar (atau kecil)




K-Medoids




K-Medoids

- K-medoids: Memilih representatif object sebanyak k , yang disebut sebagai medoids.
 - K-Means meminimalkan jumlah kuadrat (sum-of-squares) dalam cluster
 - K-Medoids meminimalkan jumlah jarak (sum of distances) antara setiap titik dengan medoid dari clusternya.



k-means




k-medoids

How K-Medoids (PAM) works?


- Partitioning Around Medoids (PAM)
- 1. Initialize: pilih titik acak sebanyak k , yang kita sebut sebagai medoids.
- 2. Repeat:
 - Tetapkan setiap titik ke cluster dengan jarak terdekat dengan medoid m .
 - Memilih objek baru oi dalam cluster
 - Hitung “total cost of swapping S ”, antara medoid m dengan oi
 - If $S < 0$:
 - Ganti m dengan oi untuk membentuk kumpulan medoids.
- Ulangi proses ini dan berhenti ketika “convergence”.

How K-Medoids works?

- Pilih medoid secara acak sebanyak K
- Contoh K=2




- Tetapkan data points ke titik tengah cluster terdekat



How K-Medoids works?

Data Objects		
	A_1	A_2
O_1	2	6
O_2	3	4
O_3	3	8
O_4	4	7
O_5	6	2
O_6	6	4
O_7	7	3
O_8	7	4
O_9	8	5
O_{10}	7	6



Hitung “absolute error criterion” [jika Medoids nya adalah (O_2, O_8)]


$$E = \sum_{i=1}^k \sum_{p \in C_i} |p - o_i| = (|O_1 - O_2| + |O_3 - O_2| + |O_4 - O_2|) + (|O_5 - O_8| + |O_6 - O_8| + |O_7 - O_8| + |O_9 - O_8| + |O_{10} - O_8|)$$

Nilai “absolute error criterion” [Jika Medoids nya adalah (O_2, O_8)]

$$E = (3+4+4)+(3+1+1+2+2) = 20$$

How K-Medoids works?

Data Objects		
	A_1	A_2
O_1	2	6
O_2	3	4
O_3	3	8
O_4	4	7
O_5	6	2
O_6	6	4
O_7	7	3
O_8	7	4
O_9	8	5
O_{10}	7	6




- Pilih object baru secara acak O_7
- Ganti O_8 dengan O_7
- Hitung “absolute error criterion” [Jika Medoids nya adalah (O_2, O_7)]

$$E = (3+4+4)+(2+2+1+3+3) = 22$$

How K-Medoids works?

Data Objects		
	A_1	A_2
O_1	2	6
O_2	3	4
O_3	3	8
O_4	4	7
O_5	6	2
O_6	6	4
O_7	7	3
O_8	7	4
O_9	8	5
O_{10}	7	6



→ Hitung “cost function”

Absolute error [O_2, O_7] - Absolute error [for O_2, O_8]

$$S = 22 - 20$$

$S > 0 \Rightarrow$ Ide yang buruk jika mengganti O_8 dengan O_7


Discussion on the K-medoids

- Keuntungan:
 - Mudah dipahami dan diimplementasikan
 - K-Medoid Algorithm bekerja dengan cepat dan bisa “converges” dalam jumlah steps tertentu.
 - PAM tidak terlalu sensitive terhadap outliers dibanding algorithms lain.
- Kerugian:
 - Hasilnya bisa berbeda ketika dijalankan, karena nilai medoids k adalah dipilih secara acak saat pertama kali
 - PAM algorithm dalam K-medoid clustering bekerja baik pada dataset tapi tidak bisa “scale well” untuk dataset yang besar.




DBSCAN

DBSCAN

- Density-Based Spatial Clustering of Applications with Noise (DBSCAN) adalah
 - algoritma berbasis density-based
 - Diusulkan oleh Martin Ester, Hans-Peter Kriegel, Jörg Sander dan Xiaowei Xu pada tahun 1996



Why DBSCAN?




DBSCAN dapat meng-cluster data points dengan benar, dan bisa mendeteksi noise

How DBSCAN works?

- Mengelompokkan objects dalam area yang padat (dense region)
- Fitur utama
 - Bisa menemukan cluster yang bentuknya “arbitrary”
 - Bisa handle noise
 - Satu kali scanning
 - Membutuhkan “density parameters”
- Density parameters
 - **Radius ϵ** : jarak untuk menentukan tetangga
 - **MinPts** : Jumlah minimum poin dalam lingkungan (neighborhood)

Definitions

- Core object
 - ε -neighborhood yang mempunyai object sejumlah **MinPts**
- Directly density-reachable
 - **p** bisa disebut “directly density-reachable” dari **q** jika **q** adalah “core object”, dan **p** adalah ε -neighborhood dari **q**




$\varepsilon = 10$
MinPts = 5

DBSCAN

- Sebuah *cluster* - koleksi dari point yang “density-connected”
- Menemukan clusters dengan bentuk “arbitrary”
 1. Memilih secara acak sebuah point ***p***
 2. Menemukan semua ε -neighborhood dari ***p***
 3. Jika ***p*** adalah sebuah core object, maka sebuah cluster bisa dibentuk
 4. Dari core object ***p***, mencari secara terus menerus object yang “density-reachable” (sehingga bisa tergabung menjadi cluster)
 5. Proses ini dikerjakan terus menerus sampai tidak ada point baru yang bisa ditambahkan ke dalam cluster
- Permasalahan dalam DBSCAN
 - Memilih parameter ε dan ***MinPts***


DBSCAN



- Ada 3 tipe points
 - core point (merah)
 - border points (biru)
 - noise points (abu abu)

How to determine MinPts and eps

- MinPts
 - Menggunakan “domain knowledge”
 - Semakin besar data set, semakin besar nilai dari MinPts
 - Jika dataset lebih banyak noise-nya, isikan MinPts dengan nilai yang lebih besar
 - Umumnya, $\text{MinPts} \geq$ atau $=$ jumlah dimensi dalam data set
 - Untuk 2-dimensional data, gunakan $\text{MinPts} = 4$ (Ester et al., 1996).
 - Jika dataset lebih dari 2 dimensions, pilih $\text{MinPts} = 2 \times \text{dim}$, yang mana dim = jumlah dimensi dalam dataset (Sander et al., 1998).
- Epsilon
 - sorted k-dist graph



Association Rule

Association Rule Mining

- Given a set of transactions, find rules that will predict the occurrence of an item based on the occurrences of other items in the transaction

Market-Basket transactions

<i>TID</i>	<i>Items</i>
1	Bread, Milk
2	Bread, Vegetables, Fruits, Eggs
3	Milk, Vegetables, Fruits, Coke
4	Bread, Milk, Vegetables, Fruits
5	Bread, Milk, Vegetables, Coke

Example of Association Rules

$\{\text{Vegetables}\} \rightarrow \{\text{Fruits}\},$
 $\{\text{Milk, Bread}\} \rightarrow \{\text{Eggs, Coke}\},$
 $\{\text{Fruits, Bread}\} \rightarrow \{\text{Milk}\},$

Implication means co-occurrence, not causality!

Definition: Frequent Itemset

- **Itemset**
 - A collection of one or more items
 - ⑩ Example: {Milk, Bread, Vegetables}
 - k-itemset
 - ⑩ An itemset that contains k items
- **Support count (σ)**
 - Frequency of occurrence of an itemset
 - E.g. $\sigma(\{\text{Milk, Bread, Vegetables}\}) = 2$
- **Support**
 - Fraction of transactions that contain an itemset
 - E.g. $s(\{\text{Milk, Bread, Vegetables}\}) = 2/5$
- **Frequent Itemset**
 - An itemset whose support is greater than or equal to a *minsup* threshold

<i>TID</i>	<i>Items</i>
1	Bread, Milk
2	Bread, Vegetables, Fruits, Eggs
3	Milk, Vegetables, Fruits, Coke
4	Bread, Milk, Vegetables, Fruits,
5	Bread, Milk, Vegetables, Coke

Definition: Association Rule

Rule Evaluation Metrics

- Support (s)
 - ◆ Fraction of transactions that contain both X and Y
- Confidence (c)
 - ◆ Measures how often items in Y appear in transactions that contain X
 - ◆ Indicates the number of times the if-then statements are found true.
- Lift
 - ◆ How many times an if-then statement is expected to be found true

$$\text{support}(A \rightarrow C) = \text{support}(A \cup C), \quad \text{range: } [0, 1]$$

$$\text{confidence}(A \rightarrow C) = \frac{\text{support}(A \rightarrow C)}{\text{support}(A)}, \quad \text{range: } [0, 1]$$

$$\text{lift}(A \rightarrow C) = \frac{\text{confidence}(A \rightarrow C)}{\text{support}(C)}, \quad \text{range: } [0, \infty]$$

Definition: Association Rule

<i>TID</i>	<i>Items</i>
1	Bread, Milk
2	Bread, Vegetables, Fruits, Eggs
3	Milk, Vegetables, Fruits, Coke
4	Bread, Milk, Vegetables, Fruits
5	Bread, Milk, Vegetables, Coke

Example:

$\{\text{Milk, Vegetables}\} \Rightarrow \text{Fruits}$

$\{X\} \Rightarrow Y$

$$s = \frac{\sigma(\text{Milk, Vegetables, Fruits})}{|T|} = \frac{2}{5} = 0.4$$

$$c = \frac{\sigma(\text{Milk, Vegetables, Fruits})}{\sigma(\text{Milk, Vegetables})} = \frac{2}{3} = 0.67$$


$$l = \frac{\sigma(\text{Milk, Vegetables, Fruits})}{\sigma(\text{Milk, Vegetables}) * \sigma(\text{Fruits})} = \frac{2}{(3*3)} = 0.22$$

Apriori




Reducing Number of Candidates


- **Apriori principle:**
 - If an itemset is frequent, then all of its subsets must also be frequent



Illustrating Apriori Principle



Illustrating Apriori Principle



Apriori Algorithm

- Method:
 - Let $k=1$
 - Generate frequent itemsets of length 1
 - Repeat until no new frequent itemsets are identified
 - Generate length $(k+1)$ candidate itemsets from length k frequent itemsets
 - Prune candidate itemsets containing subsets of length k that are infrequent
 - Count the support of each candidate by scanning the DB
 - Eliminate candidates that are infrequent, leaving only those that are frequent

Let's Practice!

Thank You