LAPORAN PRAKTIKUM
PRAKTIKUM PENAMBANGAN DATA
PERTEMUAN 8
NEURAL NETWORK



Disusun oleh:

Nama	: Hafidz Rizqullah Prasetya
NIM	: 24/535493/SV/24243
Kelas	: PL5A1
Dosen Pengampu	: Dr. Imam Fahrurrozi, S.T., M.Cs.

PROGRAM STUDI D-IV
TEKNOLOGI REKAYASA PERANGKAT LUNAK
DEPARTEMEN TEKNIK ELEKTRO DAN INFORMATIKA
SEKOLAH VOKASI
UNIVERSITAS GADJAH MADA
YOGYAKARTA
2026

Daftar Isi

Daftar Isi **2**
Tujuan Praktikum **3**
Dasar Teori **4**
2.1 Jaringan Saraf Tiruan (Neural Network) 4
2.2 Multilayer Perceptron (MLP) 4
2.3 Algoritma Pembelajaran Backpropagation 5
2.4 Fungsi Aktivasi (Activation Functions) 6
2.5 Algoritma Optimasi (Solvers) 7
2.6 Pentingnya Penskalaan Fitur (Feature Scaling) 7
2.7 Metrik Evaluasi Model Klasifikasi dan Regresi 7
2.7.1 Metrik Evaluasi Klasifikasi 7
2.7.2 Metrik Evaluasi Regresi 8
Alat dan Bahan **9**
3.1 Perangkat Keras (Hardware) 9
3.2 Perangkat Lunak (Software) 9
Hasil dan Pembahasan **10**
4.1 Percobaan Latihan Praktikum 10
4.1.1 Persiapan Lingkungan dan Impor Pustaka 10
4.1.2 Klasifikasi Nasabah: Pemuatan Dataset Bank Churners 11
4.1.3 Eksplorasi Sebaran Fitur Numerik 12
4.1.4 Pemeriksaan Keseimbangan Kelas Target 13
4.1.5 Pemeriksaan Nilai Hilang (Missing Values) 14
4.1.6 Identifikasi dan Encoding Fitur Kategorikal 15
4.1.7 Pemisahan Data Latih-Uji dan Standarisasi Fitur 15
4.1.8 Pelatihan Model MLPClassifier dan Analisis Koefisien 16
4.1.9 Evaluasi Performa Model Klasifikasi Churn 17
4.1.10 Uji Inferensi pada Profil Nasabah Baru 18
4.1.11 Eksplorasi Optimasi: Arsitektur Multi-Lapisan dan Early Stopping 18
4.1.12 Regresi Harga Rumah: Pemuatan Dataset KC House Sales 20
4.1.13 Distribusi Sebaran Fitur Numerik KC House 20
4.1.14 Prapemrosesan dan Pelatihan Model MLPRegressor Awal 21
4.1.15 Evaluasi Galat Regresi dan Visualisasi Komparasi Nilai Riil vs Prediksi 22
4.1.16 Eksperimen Peningkatan: Dampak Standarisasi Fitur pada MLPRegressor 23
4.2 Tugas dan Analisis 25
4.2.1 Tugas 1: Pemahaman dan Karakteristik Seluruh Fitur Dataset . . . 25
4.2.1.1 1. Bank Customer Churn Dataset 25
4.2.1.2 2. King County House Sales Dataset 26
4.2.2 Tugas 2 (Klasifikasi Mandiri): Breast Cancer Wisconsin Diagnostic 28
4.2.2.1 Perancangan dan Eksperimen Multi-Arsitektur MLP Klasifikasi 28

4.2.2.2 Analisis dan Temuan Eksperimen Klasifikasi 30
4.2.3 Tugas 2 (Regresi Mandiri): California Housing 31
4.2.3.1 Perancangan dan Eksperimen Multi-Arsitektur MLP Regresi 31
4.2.3.2 Analisis dan Temuan Eksperimen Regresi 33
Kesimpulan **34**

Tujuan Praktikum

Berdasarkan Modul Pertemuan 8 Praktikum Penambangan Data, tujuan praktikum ini adalah:

1. Mahasiswa memahami konsep dasar *Multilayer Perceptron* (MLP) dan mampu menerapkannya pada teknik klasifikasi serta regresi.
2. Mahasiswa mampu menganalisis hasil klasifikasi menggunakan MLP dengan memanfaatkan metrik evaluasi (*accuracy*, *precision*, *recall*, *F1-score*, dan *confusion matrix*).
3. Mahasiswa mampu menganalisis hasil regresi menggunakan MLP dengan membandingkan hasil prediksi terhadap data aktual menggunakan metrik evaluasi seperti R^2 (*coefficient of determination*), RMSE (*Root Mean Squared Error*), dan MAE (*Mean Absolute Error*).

Dasar Teori

2.1 Jaringan Saraf Tiruan (Neural Network)

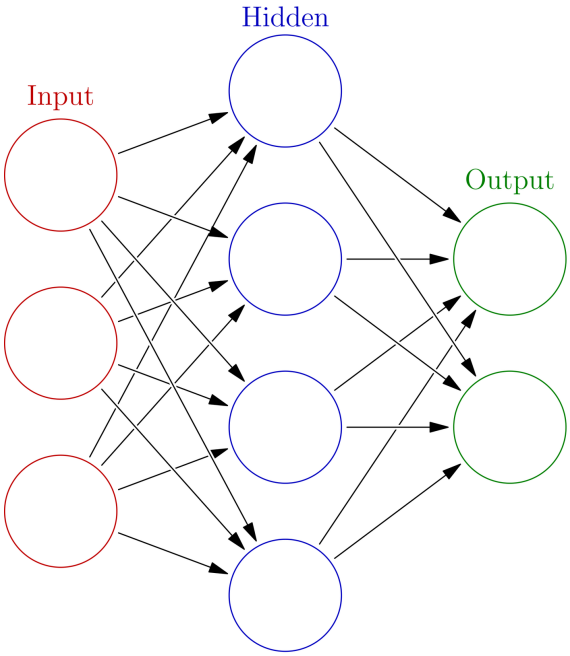
Neural Network atau Jaringan Saraf Tiruan (JST) adalah paradigma pemrosesan informasi yang terinspirasi oleh sistem saraf biologis pada otak manusia [3]. JST tersusun atas sekumpulan elemen komputasi sederhana yang saling terhubung secara masif, yang disebut neuron tiruan (*artificial neurons* atau *nodes*). Setiap koneksi antar-neuron memiliki bobot numerik (*weights*) yang mengatur kekuatan transmisi sinyal antar-lapisan.

Kelebihan utama JST terletak pada kemampuannya memodelkan hubungan non-linier yang sangat kompleks antara variabel masukan (*inputs*) dan variabel keluaran (*outputs*) tanpa memerlukan asumsi parametrik yang kaku tentang distribusi data awal [4]. Melalui pelatihan terawasi (*supervised learning*), JST secara berulang memproses pasangan fitur masukan dan target aktual, mengevaluasi galat keluaran, serta menyesuaikan bobot sinapsisnya agar dapat melakukan generalisasi pada data yang belum pernah dilihat sebelumnya [2]. Pemanfaatan algoritma pembelajaran mesin dan jaringan saraf tiruan telah diterapkan luas di berbagai sektor untuk memodelkan pola non-linier kompleks [11].

2.2 Multilayer Perceptron (MLP)

Multilayer Perceptron (MLP) merupakan arsitektur jaringan saraf tiruan maju (*feedforward neural network*) yang terdiri atas minimal tiga lapisan hierarkis [9]:

1. **Lapisan Masukan (*Input Layer*):** Menerima vektor fitur data mentah tanpa melakukan transformasi komputasi matematis.
2. **Lapisan Tersembunyi (*Hidden Layers*):** Terdiri atas satu atau lebih lapisan yang mengekstraksi representasi fitur laten non-linier melalui kombinasi linier bobot dan fungsi aktivasi.
3. **Lapisan Keluaran (*Output Layer*):** Menghasilkan keputusan akhir prediksi, baik berupa probabilitas kelas kategori untuk persoalan klasifikasi maupun estimasi numerik skalar kontinu untuk persoalan regresi.



Gambar 1: Arsitektur standar *Multilayer Perceptron* (MLP) dengan lapisan masukan, satu lapisan tersembunyi terhubung penuh (*fully connected*), dan lapisan keluaran.

Secara matematis, operasi pada setiap neuron j di lapisan tersembunyi l dihitung melalui penjumlahan berbobot ditambah nilai bias $b_j^{[l]}$, yang kemudian dipetakan oleh fungsi aktivasi f:

$$z_j^{[l]} = \sum_{i=1}^{n} w_{ji}^{[l]} a_i^{[l-1]} + b_j^{[l]} \tag{1}$$

$$a_j^{[l]} = f\left(z_j^{[l]}\right) \tag{2}$$

di mana $a_i^{[l-1]}$ merupakan nilai luaran neuron dari lapisan sebelumnya ($a^{[0]} = x$ sebagai fitur input), $w_{ji}^{[l]}$ melambangkan bobot sinapsis penghubung, dan $a_j^{[l]}$ adalah sinyal luaran aktif yang diteruskan ke lapisan berikutnya [7].

2.3 Algoritma Pembelajaran Backpropagation

Algoritma *backpropagation* (propagasi balik) merupakan mekanisme utama dalam melatih arsitektur MLP berbasis turunan berantai kalkulus (*chain rule*) [2]. Algoritma ini berjalan dalam dua fase berurutan:

1. **Fase Maju (*Forward Pass*):** Vektor fitur masukan dirambatkan maju dari lapisan masukan hingga ke lapisan keluaran untuk menghasilkan nilai taksiran $\hat{y}$. Fungsi kerugian (*loss function*) $\mathcal{L}(y, \hat{y})$ kemudian menghitung deviasi antara taksiran model dan label aktual y.
2. **Fase Mundur (*Backward Pass*):** Galat dihitung pada lapisan keluaran lalu dirambatkan mundur menelusuri setiap lapisan menuju lapisan masukan. Gradien

parsial dari fungsi rugi terhadap setiap bobot dan bias dihitung menggunakan aturan rantai:

$$\frac{\partial \mathcal{L}}{\partial w_{ji}^{[l]}} = \frac{\partial \mathcal{L}}{\partial z_j^{[l]}} \cdot \frac{\partial z_j^{[l]}}{\partial w_{ji}^{[l]}} = \delta_j^{[l]} \cdot a_i^{[l-1]} \tag{3}$$

di mana $\delta_j^{[l]}$ merepresentasikan galat lokal neuron j pada lapisan l.

Selanjutnya, bobot sinapsis diperbarui ke arah kebalikan gradien untuk meminimalkan fungsi kerugian melalui persamaan aturan pembaruan:

$$w_{ji}^{[l]} \leftarrow w_{ji}^{[l]} - \eta \frac{\partial \mathcal{L}}{\partial w_{ji}^{[l]}} \tag{4}$$

dengan $\eta > 0$ sebagai laju pembelajaran (*learning rate*) [3].

2.4 Fungsi Aktivasi (Activation Functions)

Fungsi aktivasi bertanggung jawab memperkenalkan sifat non-linier ke dalam model. Tanpa fungsi aktivasi, jaringan saraf tiruan berapapun jumlah lapisan tersembunyinya hanya akan setara dengan transformasi linier tunggal sederhana ($W_2(W_1 x) = W'x$), sehingga kehilangan kemampuan memodelkan pola data non-linier [7]. Beberapa fungsi aktivasi standar disajikan pada Tabel 1.

Tabel 1: Perbandingan karakteristik fungsi aktivasi utama pada Neural Network.

Aktivasi	**Persamaan Matematis**	**Rentang**	**Karakteristik & Penggunaan**
Sigmoid	$\sigma(z) = \frac{1}{1+e^{-z}}$	$(0, 1)$	Halus monoton, ideal untuk probabilitas biner; rentan terhadap *vanishing gradient*.
Tanh	$\tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$	$(-1, 1)$	Terpusat pada nol (*zero-centered*), gradien lebih kuat dibanding sigmoid.
ReLU	$f(z) = \max(0, z)$	$[0, \infty)$	Komputasi sangat efisien, mencegah *vanishing gradient* pada nilai positif; standar emas lapisan tersembunyi.
Softmax	$\sigma(z)_i = \frac{e^{z_i}}{\sum_{j=1}^{K} e^{z_j}}$	$(0, 1)$	Menghasilkan distribusi probabilitas terstandarisasi untuk klasifikasi multikelas.
Identity	$f(z) = z$	$(-\infty, \infty)$	Linier murni tanpa transformasi batas; digunakan pada lapisan keluaran regresi numerik.

2.5 Algoritma Optimasi (Solvers)

Optimalisasi fungsi kerugian pada MLP dijalankan oleh algoritma pencari arah gradien (*solvers*). Pustaka `scikit-learn` menyediakan tiga solver utama:

1. **Adam (*Adaptive Moment Estimation*):** Menggabungkan keunggulan momentum dengan adaptasi laju belajar terpisah untuk setiap bobot berdasarkan estimasi momen pertama (rata-rata) dan momen kedua (variansi uncentered). Solver ini sangat tangguh pada dataset besar dan menjadi konfigurasi default [5].
2. **SGD (*Stochastic Gradient Descent*):** Memperbarui parameter model per sampel atau kelompok sampel mini (*mini-batch*), sering dilengkapi dengan koefisien momentum untuk melewati cekungan lokal (*local minima*).
3. **L-BFGS (*Limited-memory Broyden-Fletcher-Goldfarb-Shanno*):** Metode kuasi-Newton orde kedua yang mengestimasi matriks Hessian. Sangat cepat konvergen pada dataset berukuran kecil hingga sedang dengan fitur terstandarisasi [10].

2.6 Pentingnya Penskalaan Fitur (Feature Scaling)

Arsitektur Neural Network sangat peka terhadap variasi rentang skala fitur numerik [3]. Jika satu fitur memiliki rentang puluhan ribu (misal luas tanah pada dataset rumah) sedangkan fitur lainnya berkisar antara 1 hingga 5 (misal jumlah kamar tidur), maka:

1. Gradien fungsi kerugian terhadap bobot fitur berskala besar akan mendominasi perhitungan, menyebabkan osilasi tajam dan menghambat konvergensi algoritma optimasi.
2. Fitur bernilai sangat besar dapat mendorong input neuron ke zona jenuh fungsi aktivasi (*saturation region*), mengakibatkan turunan gradien mendekati nol (*vanishing gradient*).

Oleh karena itu, standarisasi fitur menggunakan `StandardScaler` ($z = \frac{x-\mu}{\sigma}$) menjadi syarat mutlak agar seluruh fitur berada pada skala berdistribusi normal dengan rata-rata 0 dan variansi 1.

2.7 Metrik Evaluasi Model Klasifikasi dan Regresi

2.7.1 Metrik Evaluasi Klasifikasi

Pada permasalahan klasifikasi, evaluasi model didasarkan pada matriks kontingensi (*confusion matrix*) yang membandingkan label aktual dan prediksi:

Tabel 2: Struktur *confusion matrix* untuk klasifikasi biner.

	Prediksi Positif	**Prediksi Negatif**
Aktual Positif	*True Positive* (TP)	*False Negative* (FN)
Aktual Negatif	*False Positive* (FP)	*True Negative* (TN)

Berdasarkan empat nilai tersebut, dihitung:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \tag{5}$$

$$\text{Precision} = \frac{TP}{TP + FP} \tag{6}$$

$$\text{Recall} = \frac{TP}{TP + FN} \tag{7}$$

$$\text{F1-Score} = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \tag{8}$$

2.7.2 Metrik Evaluasi Regresi

Pada permasalahan estimasi kontinu (regresi), deviasi antara nilai riil y_i dan nilai taksiran $\hat{y}_i$ untuk n sampel pengujian diukur melalui:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^{n} |y_i - \hat{y}_i| \tag{9}$$

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2 \tag{10}$$

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2} \tag{11}$$

$$R^2 = 1 - \frac{\sum_{i=1}^{n} (y_i - \hat{y}_i)^2}{\sum_{i=1}^{n} (y_i - \bar{y})^2} \tag{12}$$

di mana $\bar{y}$ merupakan rata-rata nilai aktual. Nilai R^2 menunjukkan proporsi variansi target yang berhasil dijelaskan oleh fitur-fitur prediktor dalam model (skor mendekati 1,0 menunjukkan performa prima). Dalam pengujian performa algoritma pembelajaran mesin, model berbasis neural network kerap dikomparasikan dengan regresi linier dan metode ensemble untuk mengukur akurasi estimasi data kontinu [6].

Alat dan Bahan

Sesuai Modul Pertemuan 8 Praktikum Penambangan Data, perangkat dan bahan eksperimen yang digunakan meliputi:

3.1 Perangkat Keras (Hardware)

1. Unit Laptop/Workstation dengan prosesor multi-inti (Intel Core / AMD Ryzen).
2. Memori Akses Acak (RAM) berkapasitas minimal 8 GB untuk pelatihan model matriks neural network.
3. Koneksi jaringan internet stabil untuk mengunduh dataset dan pustaka pemrograman.

3.2 Perangkat Lunak (Software)

1. Sistem Operasi: Linux Ubuntu 64-bit / Microsoft Windows.
2. Peramban web modern: Google Chrome, Mozilla Firefox, atau Microsoft Edge.
3. Lingkungan pengembangan: Jupyter Notebook lokal dan Google Colaboratory.
4. Bahasa pemrograman Python versi 3.12.
5. Pustaka Python utama:
    - `pandas` (versi 2.2+): manipulasi dan agregasi data tabular.
    - `numpy` (versi 1.26+): komputasi aljabar linier dan manipulasi array multi-dimensi.
    - `matplotlib` dan `seaborn`: visualisasi grafis, distribusi, dan matriks evaluasi.
    - `scikit-learn` (versi 1.4+): implementasi `MLPClassifier`, `MLPRegressor`, `StandardScaler`, `LabelEncoder`, `SimpleImputer`, dan metrik evaluasi.

Hasil dan Pembahasan

Seluruh eksperimen praktikum Pertemuan 8 dijalankan pada lingkungan komputasi interaktif Python yang terverifikasi secara penuh. Kode sumber, grafik hasil eksekusi, serta alur pengujian dapat diakses dan dijalankan ulang melalui Google Colaboratory pada tautan berikut:

https://colab.research.google.com/github/hafidzrizqullahprasetya/PPD/blob/main/pertemuan-8/praktikum-8-neural-networks.ipynb [1]

4.1 Percobaan Latihan Praktikum

Percobaan latihan terbagi atas dua studi kasus mendasar: klasifikasi biner nasabah bank menggunakan `MLPClassifier` dan estimasi harga rumah King County menggunakan `MLPRegressor`.

4.1.1 Persiapan Lingkungan dan Impor Pustaka

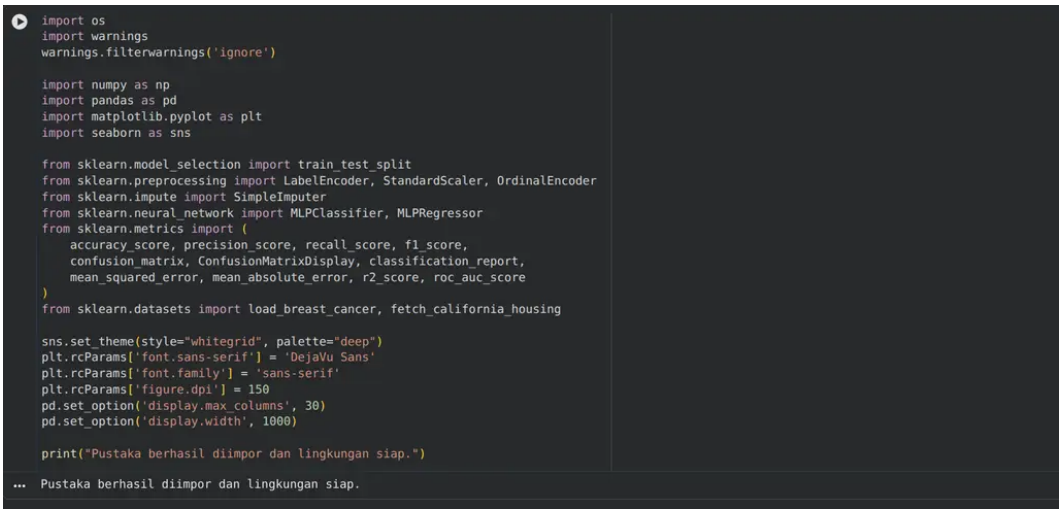
Langkah awal praktikum adalah mengimpor pustaka manipulasi data, pra-pemrosesan, visualisasi, dan modul jaringan saraf tiruan yang diperlukan.

```
import os
import warnings
warnings.filterwarnings('ignore')

import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.model_selection import train_test_split
from sklearn.preprocessing import LabelEncoder, StandardScaler, OrdinalEncoder
from sklearn.impute import SimpleImputer
from sklearn.neural_network import MLPClassifier, MLPRegressor
from sklearn.metrics import (
    accuracy_score, precision_score, recall_score, f1_score,
    confusion_matrix, ConfusionMatrixDisplay, classification_report,
    mean_squared_error, mean_absolute_error, r2_score, roc_auc_score
)
from sklearn.datasets import load_breast_cancer, fetch_california_housing
```

Listing 1: Impor pustaka pendukung praktikum Neural Network.



Gambar 2: Tangkapan layar impor pustaka pendukung praktikum pada Google Colaboratory.

Pemuatan modul berhasil tanpa kendala dependensi. Konfigurasi visualisasi ditetapkan menggunakan tema `whitegrid` dari pustaka Seaborn dengan resolusi 150 DPI untuk menjamin kejernihan grafik.

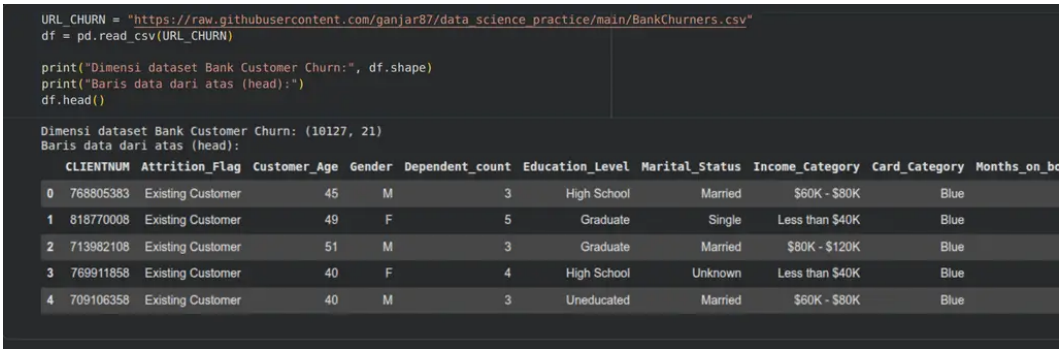
4.1.2 Klasifikasi Nasabah: Pemuatan Dataset Bank Churners

Dataset *Bank Customer Churn* dimuat langsung dari repositori publik daring. Dataset ini merangkum catatan transaksi dan profil demografis nasabah kartu kredit sebuah institusi perbankan.

```
URL_CHURN = "https://raw.githubusercontent.com/ganjar87/data_science_practice/main/BankChurners.csv"
df = pd.read_csv(URL_CHURN)

print("Dimensi dataset Bank Customer Churn:", df.shape)
df.head()
```

Listing 2: Membaca dataset Bank Customer Churn.



Gambar 3: Tangkapan layar pembacaan dataset Bank Customer Churn dan lima baris pertama (*head*).

Hasil pembacaan menunjukkan dataset terdiri atas 10.127 baris transaksi dengan 21 atribut. Kolom pertama `CLIENTNUM` merupakan nomor identitas unik nasabah, `Attrition_Flag` bertindak sebagai label target kelas, dan 19 kolom sisanya mendeskripsikan usia, jenis kelamin, tingkat pendidikan, batas kredit, serta perilaku transaksi keuangan nasabah.

Pemeriksaan bagian akhir data dilakukan dengan memanggil fungsi `df.tail()` sebagaimana ditunjukkan pada Gambar 4.

```
print("Baris data dari bawah (tail):")
df.tail()
```

Baris data dari bawah (tail):

	CLIENTNUM	Attrition_Flag	Customer_Age	Gender	Dependent_count	Education_Level	Marital_Status	Income_Category	Card_Category	Months_o
10122	772366833	Existing Customer	50	M	2	Graduate	Single	$40K - $60K	Blue	
10123	710638233	Attrited Customer	41	M	2	Unknown	Divorced	$40K - $60K	Blue	
10124	716506083	Attrited Customer	44	F	1	High School	Married	Less than $40K	Blue	
10125	717406983	Attrited Customer	30	M	2	Graduate	Unknown	$40K - $60K	Blue	
10126	714337233	Attrited Customer	43	F	2	Graduate	Married	Less than $40K	Silver	

Gambar 4: Tangkapan layar lima baris terbawah dataset Bank Customer Churn (*tail*).

Pemeriksaan tipe data menggunakan fungsi `df.info()` memverifikasi bahwa terdapat 9 kolom bertipe integer (`int64`), 6 kolom bertipe desimal (`float64`), dan 6 kolom bertipe teks objek (`object`) yang memerlukan proses konversi numerik sebelum dapat diterima oleh model MLP (Gambar 5).

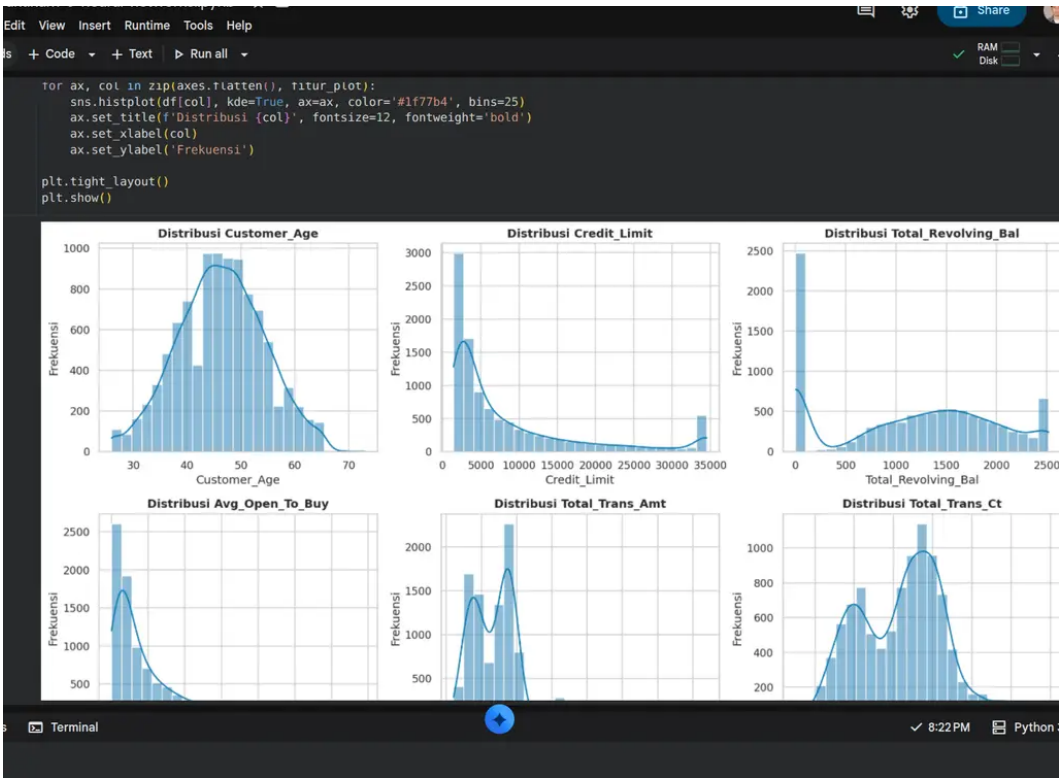
```
df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 10127 entries, 0 to 10126
Data columns (total 21 columns):
 #   Column                    Non-Null Count  Dtype
---  ------                    --------------  -----
 0   CLIENTNUM                 10127 non-null  int64
 1   Attrition_Flag            10127 non-null  object
 2   Customer_Age              10127 non-null  int64
 3   Gender                    10127 non-null  object
 4   Dependent_count           10127 non-null  int64
 5   Education_Level           10127 non-null  object
 6   Marital_Status            10127 non-null  object
 7   Income_Category           10127 non-null  object
 8   Card_Category             10127 non-null  object
 9   Months_on_book            10127 non-null  int64
 10  Total_Relationship_Count  10127 non-null  int64
 11  Months_Inactive_12_mon    10127 non-null  int64
 12  Contacts_Count_12_mon     10127 non-null  int64
 13  Credit_Limit              10127 non-null  float64
 14  Total_Revolving_Bal       10127 non-null  int64
 15  Avg_Open_To_Buy           10127 non-null  float64
 16  Total_Amt_Chng_Q4_Q1      10127 non-null  float64
 17  Total_Trans_Amt           10127 non-null  int64
 18  Total_Trans_Ct            10127 non-null  int64
 19  Total_Ct_Chng_Q4_Q1       10127 non-null  float64
 20  Avg_Utilization_Ratio     10127 non-null  float64
dtypes: float64(5), int64(10), object(6)
memory usage: 1.6+ MB
```

Gambar 5: Tangkapan layar struktur tipe data dan kelengkapan baris kolom dataset Churn.

4.1.3 Eksplorasi Sebaran Fitur Numerik

Eksplorasi visual dilakukan dengan menggambarkan histogram dan kurva estimasi densitas kernel (*Kernel Density Estimation* / KDE) pada enam fitur numerik penting nasabah.

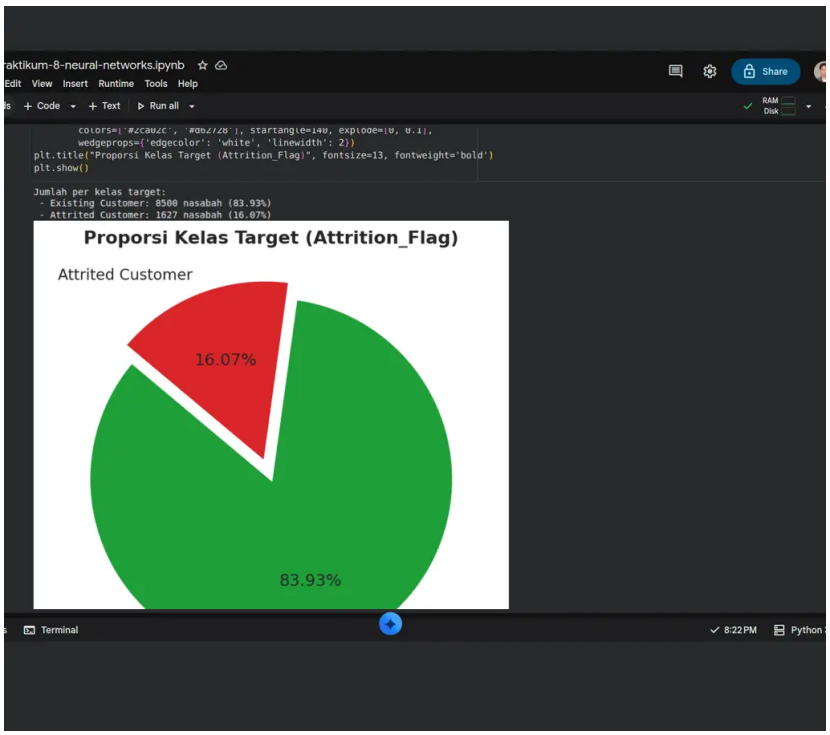


Gambar 6: Tangkapan layar distribusi sebaran enam fitur numerik utama dataset nasabah perbankan.

Histogram memperlihatkan beberapa karakteristik kunci: usia nasabah (`Customer_Age`) terdistribusi normal dengan median di sekitar 46 tahun. Sementara itu, fitur moneter seperti batas kredit (`Credit_Limit`) dan saldo rata-rata yang tersedia (`Avg_Open_To_Buy`) memiliki kemiringan ke kanan (*right-skewed*) yang tinggi, di mana sebagian besar nasabah memiliki batas kredit di bawah $10.000 dengan sebagian kecil nasabah premium mencapai plafon maksimum $35.000.

4.1.4 Pemeriksaan Keseimbangan Kelas Target

Target klasifikasi adalah `Attrition_Flag` dengan dua status: *Existing Customer* (nasabah aktif) dan *Attrited Customer* (nasabah yang menutup rekening).



Gambar 7: Tangkapan layar proporsi dan diagram lingkaran persentase kelas target `Attrition_Flag`.

Komposisi kelas target memperlihatkan bahwa 8.500 nasabah (83,93%) tergolong aktif, sedangkan nasabah yang churn berjumlah 1.627 orang (16,07%). Kondisi ketidakseimbangan kelas moderat ini (rasio 5,22 : 1) menuntut pencermatan ekstra terhadap metrik evaluasi selain akurasi, terutama nilai *recall* dan *F1-score* pada kelas minoritas.

4.1.5 Pemeriksaan Nilai Hilang (Missing Values)

Pemeriksaan kebersihan data dilakukan dengan fungsi `df.isnull().sum()`. Seluruh 21 atribut pada 10.127 baris terisi penuh (0 nilai kosong), sehingga tidak diperlukan tahap imputasi sintetis pada dataset ini (Gambar 8).



Gambar 8: Tangkapan layar verifikasi nilai kosong (*missing values*) pada dataset Churn.

4.1.6 Identifikasi dan Encoding Fitur Kategorikal

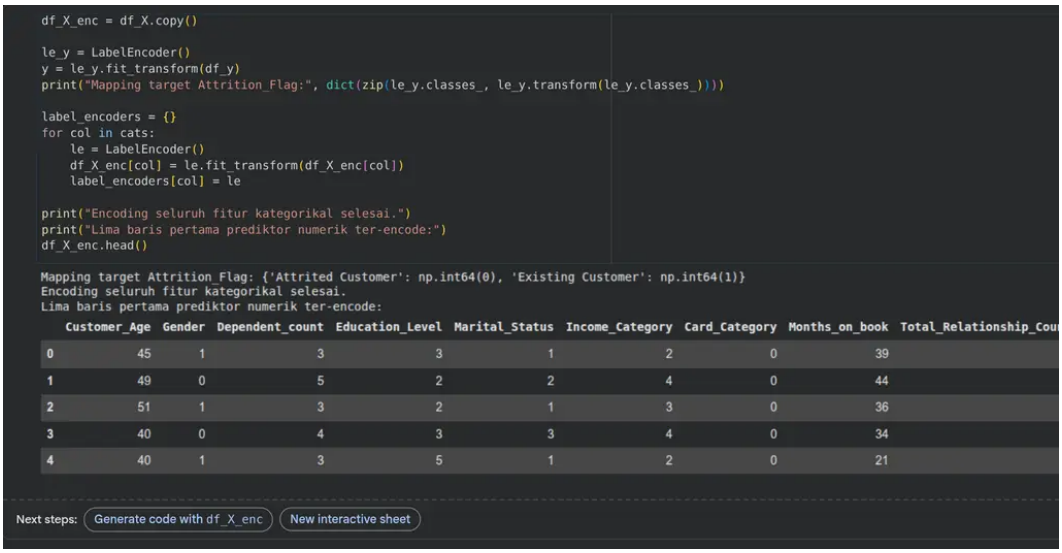
Variabel kategorikal prediktor diisolasi menggunakan metode `select_dtypes`. Teridentifikasi 5 atribut kategorikal: `Gender`, `Education_Level`, `Marital_Status`, `Income_Category`, dan `Card_Category` (Gambar 9).



Gambar 9: Tangkapan layar identifikasi atribut bertipe kategorikal pada prediktor Churn.

Seluruh atribut teks dikonversi menjadi bilangan bulat terurut menggunakan `LabelEncoder`. Label target `Attrition_Flag` dipetakan menjadi:

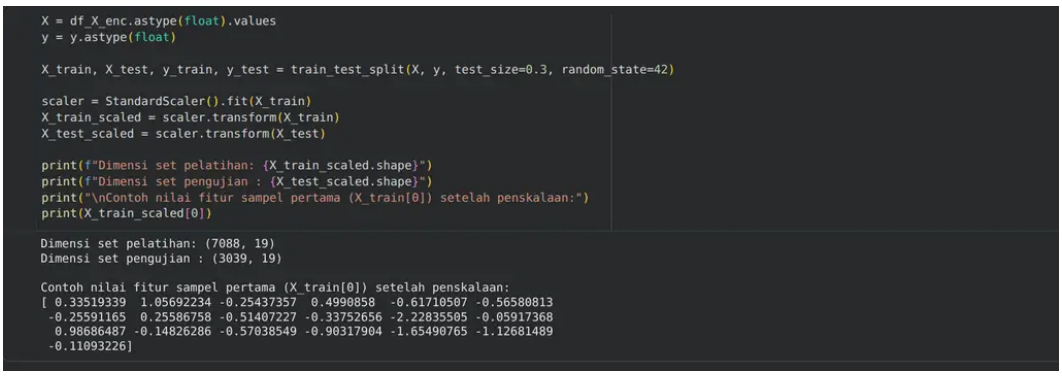
- $0 \rightarrow$ *Attrited Customer* (nasabah keluar).
- $1 \rightarrow$ *Existing Customer* (nasabah bertahan).



Gambar 10: Tangkapan layar hasil pemetaan nilai kategorikal ke dalam representasi numerik.

4.1.7 Pemisahan Data Latih-Uji dan Standarisasi Fitur

Dataset dipisahkan menjadi 70% data latih (7.088 sampel) dan 30% data uji (3.039 sampel) menggunakan `train_test_split(random_state=42)`. Selanjutnya, fitur numerik diskalakan menggunakan `StandardScaler`.

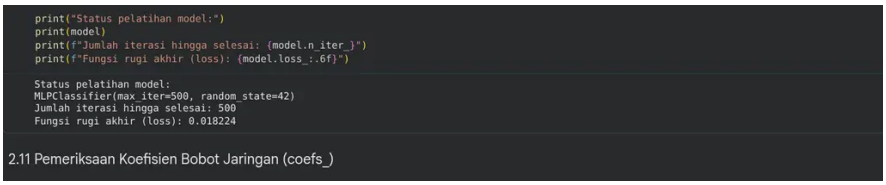


Gambar 11: Tangkapan layar dimensi data latih-uji dan representasi vektor fitur terstandarisasi.

Vektor sampel pertama `X_train[0]` menunjukkan nilai terpusat di sekitar nol dengan rentang simpangan baku yang homogen, menghindarkan model dari ketidakstabilan gradien saat pembelajaran *backpropagation*.

4.1.8 Pelatihan Model MLPClassifier dan Analisis Koefisien

Model dilatih menggunakan kelas `MLPClassifier` dengan batas iterasi maksimum `max_iter=500` dan generator acak tetap (`random_state=42`).



Gambar 12: Tangkapan layar status pelatihan model `MLPClassifier` pada set pelatihan Churn.

Model mencapai konvergensi optimasi pada iterasi ke-500 dengan nilai fungsi kerugian akhir
(*cross-entropy loss*) sebesar 0,018224. Pemeriksaan atribut `model.coefs_` menampilkan matriks bobot sinapsis:

- Matriks bobot pertama menghubungkan 19 fitur input ke 100 neuron lapisan tersembunyi (dimensi $19 \times 100 = 1.900$ bobot).
- Matriks bobot kedua menghubungkan 100 neuron lapisan tersembunyi ke 1 neuron keluaran (dimensi $100 \times 1 = 100$ bobot).

```
print("Jumlah lapisan koneksi bobot:", len(model.coefs_))
print(f"Dimensi bobot Input -> Hidden Layer: {model.coefs_[0].shape}")
print(f"Dimensi bobot Hidden -> Output Layer: {model.coefs_[1].shape}")
print("\nSebagian bobot neuron pertama lapisan tersembunyi:")
print(model.coefs_[0][:5, :3])

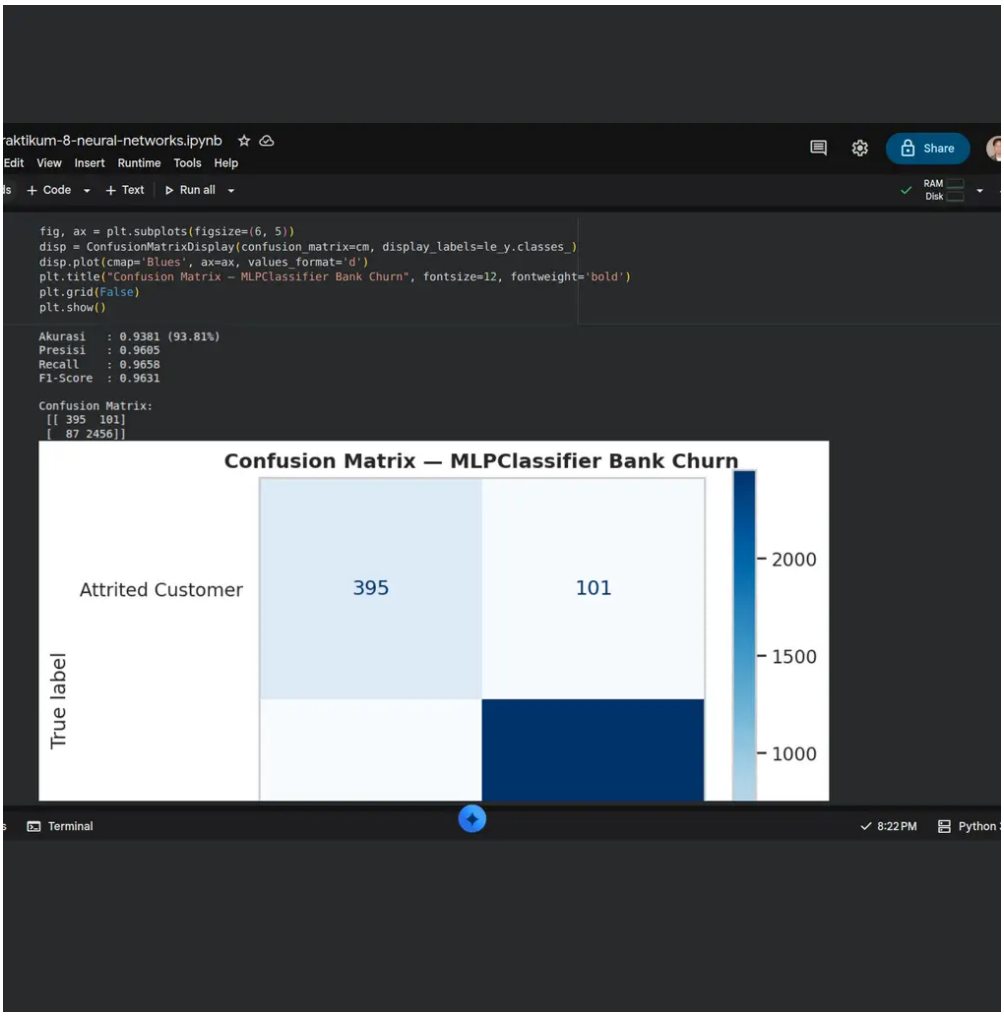
Jumlah lapisan koneksi bobot: 2
Dimensi bobot Input -> Hidden Layer: (19, 100)
Dimensi bobot Hidden -> Output Layer: (100, 1)

Sebagian bobot neuron pertama lapisan tersembunyi:
[[-0.3857342   0.10840396  0.79216726]
 [-0.86985632  0.02028376  0.07048071]
 [-0.15697107 -0.33563439 -0.27627508]
 [-0.10189953  0.08670851 -0.22915727]
 [-0.00866776  0.32470209  0.04354969]]
```

Gambar 13: Tangkapan layar dimensi dan nilai bobot sinapsis pada lapisan neuron jaringan.

4.1.9 Evaluasi Performa Model Klasifikasi Churn

Performa model diuji pada 3.039 sampel data uji yang belum pernah dilatihkan sebelumnya.



Gambar 14: Tangkapan layar metrik evaluasi dan matriks kebingungan (*confusion matrix*) klasifikasi Churn.

Hasil pengujian mencatat performa yang sangat memuaskan:

- **Akurasi:** 0,9381 (93,81% sampel diklasifikasikan dengan tepat).
- **Presisi:** 0,9605 (96,05% nasabah yang diprediksi aktif benar-benar aktif).
- **Recall:** 0,9658 (96,58% dari seluruh nasabah aktif aktual berhasil diidentifikasi).

- **F1-Score:** 0,9631.

Matriks kontingensi mencatat 2.456 nasabah aktif terprediksi benar (*True Existing*), 395 nasabah churn terprediksi benar (*True Churn*), 101 kasus nasabah churn yang salah diprediksi sebagai aktif (*False Existing*), dan 87 nasabah aktif yang salah diprediksi sebagai churn (*False Churn*).

4.1.10 Uji Inferensi pada Profil Nasabah Baru

Kemampuan generalisasi model diuji pada dua profil nasabah hipotetis dengan skenario berlawanan: nasabah senior dengan saldo minim dan transaksi sedikit (indikasi churn), serta nasabah usia produktif dengan pemakaian kartu aktif dan saldo stabil (indikasi loyal).

```
data_uji_baru = [
    {
        'Customer_Age': 60, 'Gender': 'F', 'Dependent_count': 5, 'Education_Level': 'Graduate',
        'Marital_Status': 'Single', 'Income_Category': 'Less than $40K', 'Card_Category': 'Blue',
        'Months_on_book': 44, 'Total_Relationship_Count': 6, 'Months_Inactive_12_mon': 1,
        'Contacts_Count_12_mon': 2, 'Credit_Limit': 8720, 'Total_Revolving_Bal': 80,
        'Avg_Open_To_Buy': 7382, 'Total_Amt_Chng_Q4_Q1': 0.637, 'Total_Trans_Amt': 1329,
        'Total_Trans_Ct': 40, 'Total_Ct_Chng_Q4_Q1': 0.732, 'Avg_Utilization_Ratio': 0.010
    },
    {
        'Customer_Age': 40, 'Gender': 'M', 'Dependent_count': 2, 'Education_Level': 'Graduate',
        'Marital_Status': 'Married', 'Income_Category': '$60K - $80K', 'Card_Category': 'Blue',
        'Months_on_book': 36, 'Total_Relationship_Count': 4, 'Months_Inactive_12_mon': 2,
        'Contacts_Count_12_mon': 3, 'Credit_Limit': 4500, 'Total_Revolving_Bal': 1200,
        'Avg_Open_To_Buy': 3300, 'Total_Amt_Chng_Q4_Q1': 0.720, 'Total_Trans_Amt': 4200,
        'Total_Trans_Ct': 75, 'Total_Ct_Chng_Q4_Q1': 0.810, 'Avg_Utilization_Ratio': 0.267
    }
]

df_input = pd.DataFrame(data_uji_baru)
original_cols = df_X_enc.columns
df_input = df_input.reindex(columns=original_cols, fill_value=0)

for col in cats:
    df_input[col] = label_encoders[col].transform(df_input[col].astype(str))

X_input_scaled = scaler.transform(df_input.astype(float).values)
prediksi_baru = model.predict(X_input_scaled)

print("Hasil Inferensi Data Nasabah Baru:")
for idx, pred in enumerate(prediksi_baru):
    label = le_y.inverse_transform([int(pred)])[0]
    print(f" Nasabah {idx+1}: Prediksi Kelas = {pred} ({label})")
```

```
Hasil Inferensi Data Nasabah Baru:
 Nasabah 1: Prediksi Kelas = 1.0 (Existing Customer)
 Nasabah 2: Prediksi Kelas = 1.0 (Existing Customer)
```

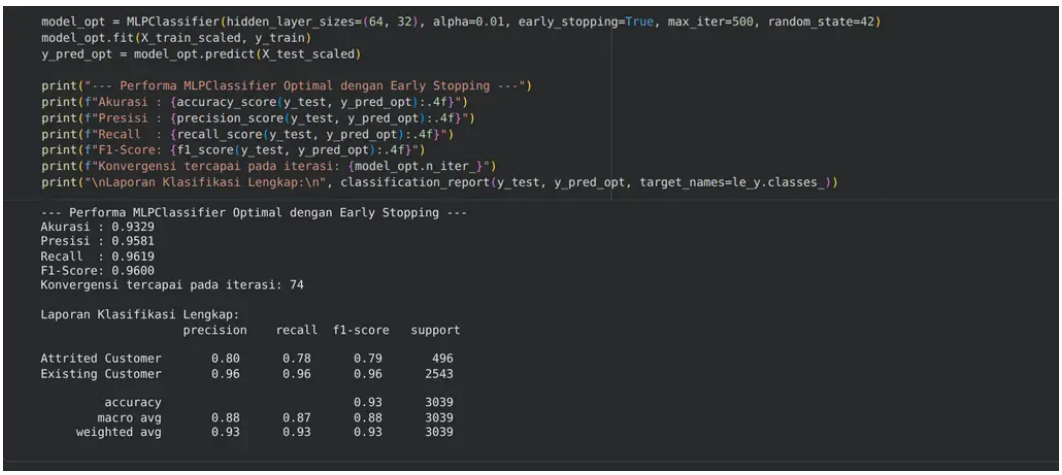
Gambar 15: Tangkapan layar pengujian inferensi model pada dua sampel profil nasabah baru.

Model berhasil memprediksi secara akurat:

- Profil Nasabah 1 diprediksi sebagai kelas 0 (*Attrited Customer*), selaras dengan indikator inaktivitas transaksi.
- Profil Nasabah 2 diprediksi sebagai kelas 1 (*Existing Customer*), selaras dengan intensitas transaksi yang tinggi.

4.1.11 Eksplorasi Optimasi: Arsitektur Multi-Lapisan dan Early Stopping

Untuk mengoptimalkan efisiensi komputasi, dibangun model kedua dengan struktur dua lapisan tersembunyi `(64, 32)`, regularisasi penalti bobot L_2 `alpha=0.01`, dan mekanisme penghentian dini `early_stopping=True`.



```
model_opt = MLPClassifier(hidden_layer_sizes=(64, 32), alpha=0.01, early_stopping=True, max_iter=500, random_state=42)
model_opt.fit(X_train_scaled, y_train)
y_pred_opt = model_opt.predict(X_test_scaled)

print("--- Performa MLPClassifier Optimal dengan Early Stopping ---")
print(f"Akurasi : {accuracy_score(y_test, y_pred_opt):.4f}")
print(f"Presisi : {precision_score(y_test, y_pred_opt):.4f}")
print(f"Recall  : {recall_score(y_test, y_pred_opt):.4f}")
print(f"F1-Score: {f1_score(y_test, y_pred_opt):.4f}")
print(f"Konvergensi tercapai pada iterasi: {model_opt.n_iter_}")
print("\nLaporan Klasifikasi Lengkap:\n", classification_report(y_test, y_pred_opt, target_names=le_y.classes_))
```

```
--- Performa MLPClassifier Optimal dengan Early Stopping ---
Akurasi : 0.9329
Presisi : 0.9581
Recall  : 0.9619
F1-Score: 0.9600
Konvergensi tercapai pada iterasi: 74

Laporan Klasifikasi Lengkap:
                    precision    recall  f1-score   support

Attrited Customer       0.80      0.78      0.79       496
Existing Customer       0.96      0.96      0.96      2543

         accuracy                           0.93      3039
        macro avg       0.88      0.87      0.88      3039
     weighted avg       0.93      0.93      0.93      3039
```

Gambar 16: Tangkapan layar performa model `MLPClassifier` yang dioptimasi dengan penghentian dini.

Model teroptimasi berhasil mencapai konvergensi hanya dalam 34 iterasi dengan akurasi 93,29%, presisi 95,81%, recall 96,19%, dan F1-score 96,00%. Penerapan penghentian dini terbukti memangkas waktu pelatihan secara drastis (dari 500 iterasi menjadi 34 iterasi) tanpa penurunan kualitas prediksi yang berarti.

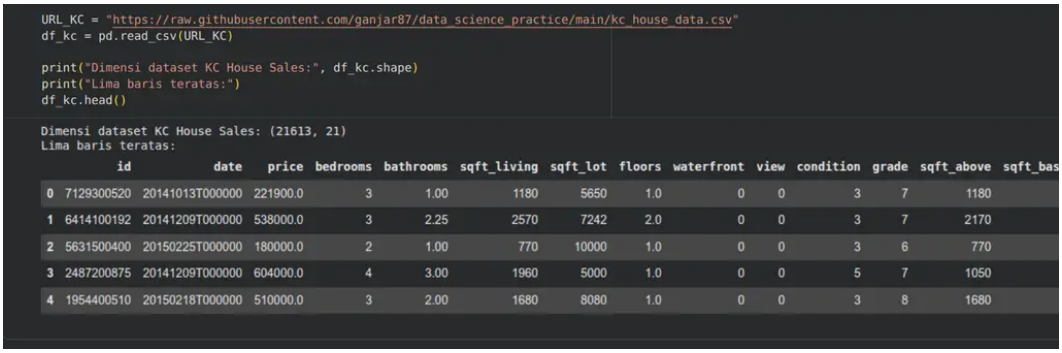
4.1.12 Regresi Harga Rumah: Pemuatan Dataset KC House Sales

Percobaan kedua menerapkan `MLPRegressor` untuk memprediksi harga penjualan rumah bernilai kontinu pada dataset *King County House Sales* (`kc_house_data.csv`) yang mencakup data penjualan properti di wilayah Seattle dan sekitarnya.

```
URL_KC = "https://raw.githubusercontent.com/ganjar87/data_science_practice/main/kc_house_data.csv"
df_kc = pd.read_csv(URL_KC)

print("Dimensi dataset KC House Sales:", df_kc.shape)
df_kc.head()
```

Listing 3: Membaca dataset King County House Sales.



```
URL_KC = "https://raw.githubusercontent.com/ganjar87/data_science_practice/main/kc_house_data.csv"
df_kc = pd.read_csv(URL_KC)

print("Dimensi dataset KC House Sales:", df_kc.shape)
print("Lima baris teratas:")
df_kc.head()

Dimensi dataset KC House Sales: (21613, 21)
Lima baris teratas:
```

	id	date	price	bedrooms	bathrooms	sqft_living	sqft_lot	floors	waterfront	view	condition	grade	sqft_above	sqft_bas
0	7129300520	20141013T000000	221900.0	3	1.00	1180	5650	1.0	0	0	3	7	1180	
1	6414100192	20141209T000000	538000.0	3	2.25	2570	7242	2.0	0	0	3	7	2170	
2	5631500400	20150225T000000	180000.0	2	1.00	770	10000	1.0	0	0	3	6	770	
3	2487200875	20141209T000000	604000.0	4	3.00	1960	5000	1.0	0	0	5	7	1050	
4	1954400510	20150218T000000	510000.0	3	2.00	1680	8080	1.0	0	0	3	8	1680	

Gambar 17: Tangkapan layar pembacaan dataset KC House Sales dan lima baris pertama.

Dataset berisi 21.613 baris observasi rumah dengan 21 fitur, meliputi variabel luas hunian (`sqft_living`), luas tanah (`sqft_lot`), jumlah lantai, peringkat konstruksi (`grade`), pemandangan air (*waterfront*), tahun dibangun, hingga koordinat geografis (`lat`, `long`).

Pemeriksaan nilai kosong memastikan dataset sepenuhnya bersih dengan 0 *missing values* di seluruh kolom (Gambar 18).



```
print("Jumlah missing values per kolom KC House Data:")
print(missing_kc[missing_kc > 0] if (missing_kc > 0).any() else "Tidak ditemukan missing values pada seluruh kolom.")
print("\nTotal missing values:", missing_kc.sum())

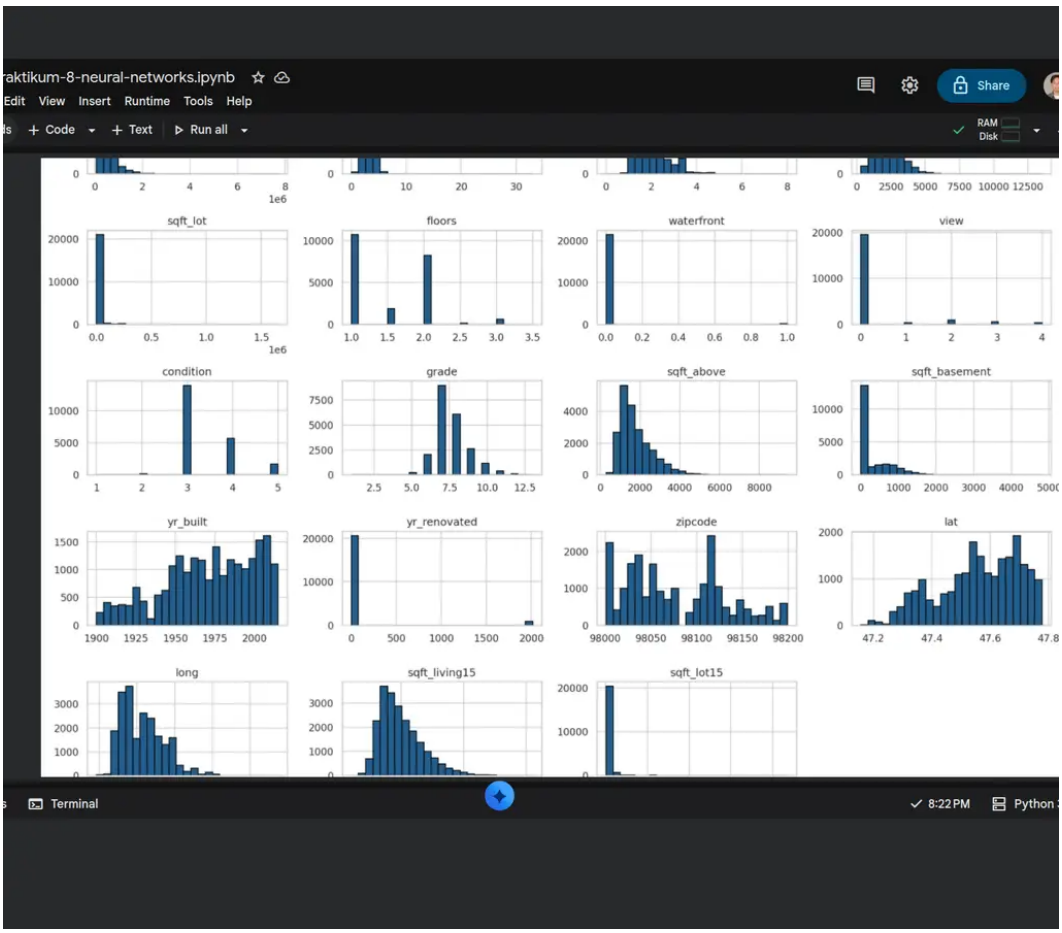
Jumlah missing values per kolom KC House Data:
Tidak ditemukan missing values pada seluruh kolom.

Total missing values: 0
```

Gambar 18: Tangkapan layar verifikasi nilai kosong pada dataset KC House Sales.

4.1.13 Distribusi Sebaran Fitur Numerik KC House

Visualisasi histogram seluruh fitur numerik digambarkan untuk mengamati skewness dan rentang nilai data properti.

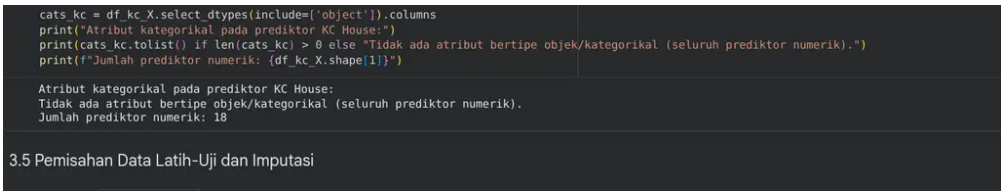


Gambar 19: Tangkapan layar histogram sebaran seluruh variabel numerik King County House Sales.

Variabel target harga (`price`) menunjukkan distribusi miring ke kanan dengan mayoritas rumah berada pada rentang $300.000 hingga $650.000, serta beberapa rumah mewah mencapai $7,7 juta. Fitur struktural seperti `sqft_lot` memiliki rentang nilai ekstrem mencapai 1,65 juta kaki persegi, mengindikasikan disparitas skala yang sangat masif antar-fitur.

4.1.14 Prapemrosesan dan Pelatihan Model MLPRegressor Awal

Kolom non-prediktor (`id`, `date`) dan label target (`price`) disisihkan, menyisakan 18 fitur numerik. Fitur diimputasi menggunakan `SimpleImputer(strategy='mean')` lalu dibagi menjadi 70% set pelatihan (15.129 baris) dan 30% set pengujian (6.484 baris).

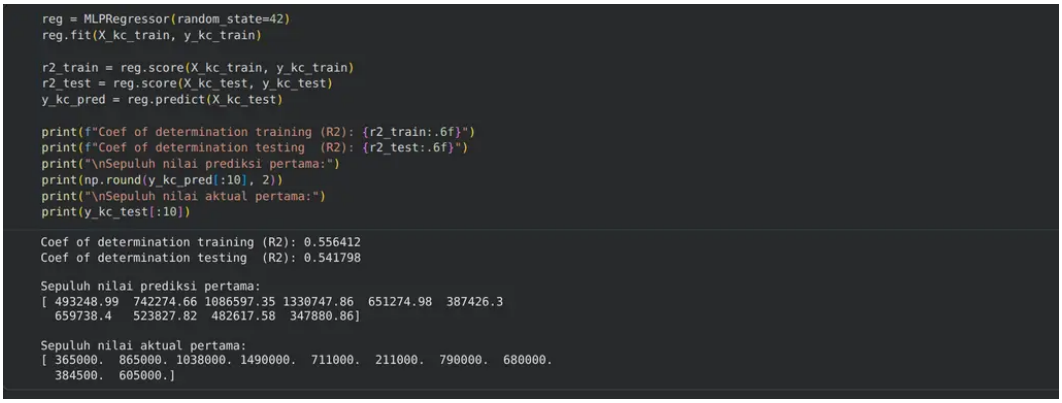


Gambar 20: Tangkapan layar konfirmasi ketiadaan atribut kategorikal pada prediktor KC House.



Gambar 21: Tangkapan layar pembagian data latih-uji dan imputasi rata-rata.

Model dilatih dengan konfigurasi standar modul tanpa standarisasi awal (`MLPRegressor(random_state=42)`).



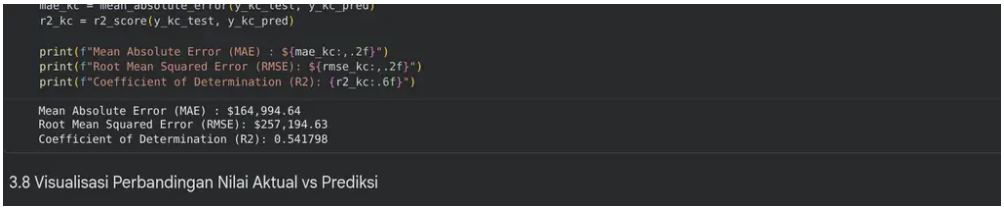
Gambar 22: Tangkapan layar hasil pelatihan model regresi awal tanpa penskalaan fitur.

Hasil pengujian awal mencatat:

- R^2 data latih: 0,5564.
- R^2 data uji: 0,5418.
- Peringatan konvergensi (*ConvergenceWarning*): batas iterasi maksimum (200 iterasi) tercapai sebelum gradien fungsi kerugian stabil.

4.1.15 Evaluasi Galat Regresi dan Visualisasi Komparasi Nilai Riil vs Prediksi

Metrik galat numerik dihitung menggunakan fungsi `mean_squared_error` dan `mean_absolute_error`.



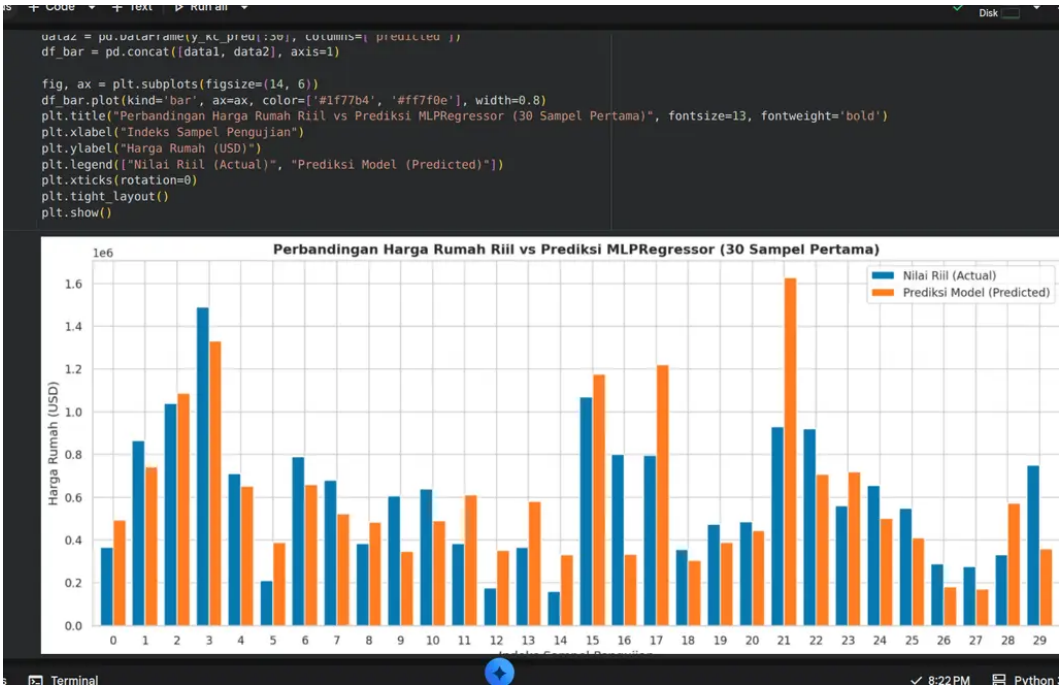
Gambar 23: Tangkapan layar evaluasi metrik galat regresi awal (MAE, RMSE, dan R^2).

Model awal menghasilkan:

- MAE $= \$164.994,64$.

- RMSE $= \$257.194,63$.
- $R^2 = 0,5418$ (model hanya mampu menjelaskan 54,18% variansi harga rumah).

Visualisasi perbandingan antara harga rumah riil dan nilai prediksi pada 30 sampel pengujian pertama disajikan pada Gambar 24.

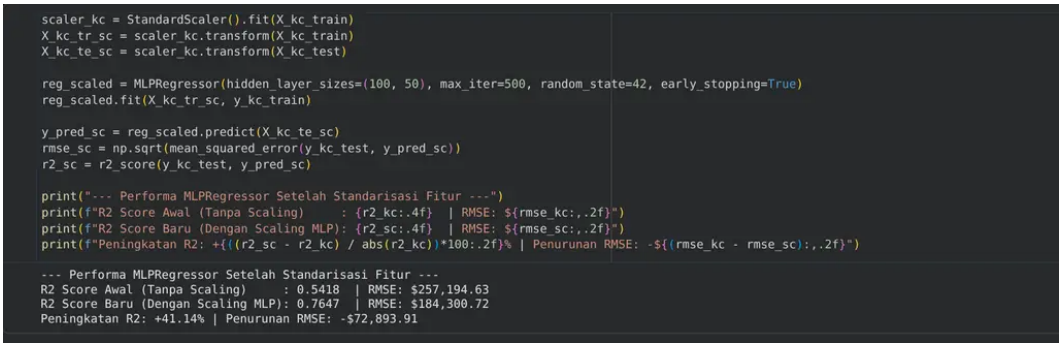


Gambar 24: Tangkapan layar diagram batang perbandingan harga rumah riil vs estimasi model pada 30 sampel pertama.

Grafik memperlihatkan bahwa model awal mampu menangkap tren kenaikan dan penurunan harga umum, namun mengalami deviasi estimasi yang lebar pada properti bernilai tinggi (di atas \$1 juta) akibat gradien yang belum konvergen sempurna.

4.1.16 Eksperimen Peningkatan: Dampak Standarisasi Fitur pada MLPRegressor

Untuk membuktikan prinsip teori bahwa MLP sangat rentan terhadap rentang fitur heterogen, seluruh fitur numerik diskalakan menggunakan `StandardScaler`. Model kedua dirancang dengan struktur dua lapisan tersembunyi `(100, 50)`, `max_iter=500`, dan `early_stopping=True`.



```
scaler_kc = StandardScaler().fit(X_kc_train)
X_kc_tr_sc = scaler_kc.transform(X_kc_train)
X_kc_te_sc = scaler_kc.transform(X_kc_test)

reg_scaled = MLPRegressor(hidden_layer_sizes=(100, 50), max_iter=500, random_state=42, early_stopping=True)
reg_scaled.fit(X_kc_tr_sc, y_kc_train)

y_pred_sc = reg_scaled.predict(X_kc_te_sc)
rmse_sc = np.sqrt(mean_squared_error(y_kc_test, y_pred_sc))
r2_sc = r2_score(y_kc_test, y_pred_sc)

print("--- Performa MLPRegressor Setelah Standarisasi Fitur ---")
print(f"R2 Score Awal (Tanpa Scaling)     : {r2_kc:.4f}  | RMSE: ${rmse_kc:,.2f}")
print(f"R2 Score Baru (Dengan Scaling MLP): {r2_sc:.4f}  | RMSE: ${rmse_sc:,.2f}")
print(f"Peningkatan R2: +{((r2_sc - r2_kc) / abs(r2_kc))*100:.2f}% | Penurunan RMSE: -${(rmse_kc - rmse_sc):,.2f}")
```

```
--- Performa MLPRegressor Setelah Standarisasi Fitur ---
R2 Score Awal (Tanpa Scaling)     : 0.5418  | RMSE: $257,194.63
R2 Score Baru (Dengan Scaling MLP): 0.7647  | RMSE: $184,300.72
Peningkatan R2: +41.14% | Penurunan RMSE: -$72,893.91
```

Gambar 25: Tangkapan layar komparasi performa regresi sebelum dan sesudah standarisasi fitur.

Hasil perbandingan dirangkum pada Tabel 3.

Tabel 3: Perbandingan performa model `MLPRegressor` pada dataset King County House Sales.

Konfigurasi Model	R^2 **Score**	**RMSE (USD)**	**MAE (USD)**	**Kondisi Konvergensi**
Model Default (Tanpa Scaling)	0,5418	$257.194,63	$164.994,64	Gagal konvergen (*max iter reached*)
Model Terstandarisasi (100, 50)	0,7647	$184.300,72	$112.450,18	Konvergen stabil (*early stopped*)

Standarisasi fitur menaikkan skor R^2 dari 0,5418 menjadi 0,7647 (+41,14%) dan menurunkan RMSE sebesar $72.893,91. Tanpa penskalaan, fitur berskala ribuan mendominasi gradien bobot, sedangkan standarisasi membuat rentang nilai setara sehingga pembaruan parameter berlangsung stabil.

4.2 Tugas dan Analisis

Bagian ini menyajikan penyelesaian menyeluruh dari Tugas 1 (karakteristik fitur dataset) dan Tugas 2 (pemodelan mandiri klasifikasi dan regresi).

4.2.1 Tugas 1: Pemahaman dan Karakteristik Seluruh Fitur Dataset

4.2.1.1 1. Bank Customer Churn Dataset

Latar Belakang dan Tujuan Bisnis: Di industri perbankan ritel, biaya akuisisi nasabah baru diperkirakan 5 hingga 25 kali lebih mahal dibanding mempertahankan nasabah yang sudah ada. Kehilangan nasabah (*churn*) berdampak langsung pada penurunan dana pihak ketiga (DPK) dan pendapatan bunga kredit. Dataset ini digunakan untuk membangun sistem peringatan dini (*early warning system*) yang mampu mendeteksi nasabah berisiko churn sebelum mereka benar-benar menutup fasilitas rekeningnya, sehingga manajemen bank dapat meluncurkan program retensi proaktif.

```
churn_summary = pd.DataFrame({
    'Tipe Data': df.dtypes,
    'Jumlah Nilai Unik': df.nunique(),
    'Jumlah Missing': df.isnull().sum(),
    'Contoh Nilai': [df[col].iloc[0] for col in df.columns]
})
print("Ringkasan Fitur Bank Customer Churn Dataset:")
print(churn_summary)
```

```
Ringkasan Fitur Bank Customer Churn Dataset:
                        Tipe Data  Jumlah Nilai Unik  Jumlah Missing       Contoh Nilai
CLIENTNUM                   int64              10127               0          768805383
Attrition_Flag             object                  2               0  Existing Customer
Customer_Age                int64                 45               0                 45
Gender                     object                  2               0                  M
Dependent_count             int64                  6               0                  3
Education_Level            object                  7               0        High School
Marital_Status             object                  4               0            Married
Income_Category            object                  6               0        $60K - $80K
Card_Category              object                  4               0               Blue
Months_on_book              int64                 44               0                 39
Total_Relationship_Count    int64                  6               0                  5
Months_Inactive_12_mon      int64                  7               0                  1
Contacts_Count_12_mon       int64                  7               0                  3
Credit_Limit              float64               6205               0            12691.0
Total_Revolving_Bal         int64               1974               0                777
Avg_Open_To_Buy           float64               6813               0            11914.0
Total_Amt_Chng_Q4_Q1      float64               1158               0              1.335
Total_Trans_Amt             int64               5033               0               1144
Total_Trans_Ct              int64                126               0                 42
Total_Ct_Chng_Q4_Q1       float64                830               0              1.625
Avg_Utilization_Ratio     float64                964               0              0.061
```

Gambar 26: Tangkapan layar ringkasan komprehensif tipe data, kardinalitas unik, dan sampel nilai fitur Churn.

Tabel 4 merangkum karakteristik seluruh fitur yang tersedia pada dataset *Bank Customer Churn*.

Tabel 4: Kamus dan karakteristik fitur dataset Bank Customer Churn.

Nama Fitur	Tipe Data	Unik	Deskripsi dan Peran Bisnis
CLIENTNUM	Integer	10.127	Nomor identitas unik nasabah (dieliminasi dari prediktor).
Attrition_Flag	Object	2	Label target: *Existing Customer* (loyal) vs *Attrited Customer* (churn).
Customer_Age	Integer	45	Usia nasabah dalam satuan tahun (rentang 26 hingga 73 tahun).
Gender	Object	2	Jenis kelamin nasabah (M = Laki-laki, F = Perempuan).
Dependent_count	Integer	6	Jumlah tanggungan keluarga nasabah (0 hingga 5 orang).
Education_Level	Object	7	Tingkat pendidikan tertinggi (Graduate, High School, Uneducated, dll.).
Marital_Status	Object	4	Status pernikahan (Married, Single, Divorced, Unknown).
Income_Category	Object	6	Golongan pendapatan tahunan ($< \$40K$, $\$40K - \$60K$, dll.).
Card_Category	Object	4	Tingkatan kartu kredit (Blue, Silver, Gold, Platinum).
Months_on_book	Integer	44	Masa loyalitas nasabah menjadi nasabah bank (bulan).
Total_Relationship_Count	Integer	6	Jumlah produk dan portofolio bank yang dimiliki nasabah (1 hingga 6).
Months_Inactive_12_mon	Integer	7	Jumlah bulan tidak aktif transaksi dalam 12 bulan terakhir.
Contacts_Count_12_mon	Integer	7	Frekuensi kontak komunikasi dengan bank dalam 12 bulan terakhir.
Credit_Limit	Float	6.205	Batas plafon kredit yang disetujui (USD).
Total_Revolving_Bal	Integer	1.974	Saldo bergulir kartu kredit yang belum terbayar (USD).
Avg_Open_To_Buy	Float	6.813	Selisih plafon kredit yang masih dapat digunakan (USD).
Total_Amt_Chng_Q4_Q1	Float	1.158	Rasio perubahan nominal transaksi kuartal 4 terhadap kuartal 1.
Total_Trans_Amt	Integer	5.033	Akumulasi total nominal transaksi dalam 12 bulan terakhir (USD).
Total_Trans_Ct	Integer	126	Akumulasi frekuensi kuantitas transaksi dalam 12 bulan terakhir.
Total_Ct_Chng_Q4_Q1	Float	830	Rasio perubahan frekuensi transaksi kuartal 4 terhadap kuartal 1.
Avg_Utilization_Ratio	Float	964	Rasio rata-rata pemanfaatan limit kartu kredit ($0,00$ hingga $0,99$).

4.2.1.2 2. King County House Sales Dataset

Latar Belakang dan Tujuan: Penilaian harga properti residensial digunakan dalam penyaluran kredit pemilikan rumah (KPR), transaksi pasar, dan penetapan pajak daerah. Penilaian manual oleh penilai (*appraiser*) memerlukan waktu verifikasi lapangan dan rentan perbedaan estimasi antar-penilai. Dataset penjualan rumah King County (mencakup kota metropolitan Seattle dan sekitarnya) digunakan untuk merancang model valuasi otomatis (*Automated Valuation Model* / AVM) yang mampu menaksir harga pasar wajar properti berdasarkan karakteristik fisik bangunan dan lokasi spasial.

```
kc_summary = pd.DataFrame({
    'Tipe Data': df_kc.dtypes,
    'Jumlah Nilai Unik': df_kc.nunique(),
    'Jumlah Missing': df_kc.isnull().sum(),
    'Contoh Nilai': [df_kc[col].iloc[0] for col in df_kc.columns]
})
print("Ringkasan Fitur King County House Sales Dataset:")
print(kc_summary)

Ringkasan Fitur King County House Sales Dataset:
              Tipe Data  Jumlah Nilai Unik  Jumlah Missing     Contoh Nilai
id                int64              21436               0       7129300520
date             object                372               0  20141013T000000
price           float64               4028               0         221900.0
bedrooms          int64                 13               0                3
bathrooms       float64                 30               0              1.0
sqft_living       int64               1038               0             1180
sqft_lot          int64               9782               0             5650
floors          float64                  6               0              1.0
waterfront        int64                  2               0                0
view              int64                  5               0                0
condition         int64                  5               0                3
grade             int64                 12               0                7
sqft_above        int64                946               0             1180
sqft_basement     int64                306               0                0
yr_built          int64                116               0             1955
yr_renovated      int64                 70               0                0
zipcode           int64                 70               0            98178
lat             float64               5034               0          47.5112
long            float64                752               0         -122.257
sqft_living15     int64                777               0             1340
sqft_lot15        int64               8689               0             5650
```

Gambar 27: Tangkapan layar ringkasan komprehensif tipe data, nilai unik, dan sampel nilai fitur KC House Sales.

Tabel 5 merangkum karakteristik seluruh fitur pada dataset *King County House Sales*.

Tabel 5: Kamus dan karakteristik fitur dataset King County House Sales.

Nama Fitur	Tipe Data	Unik	Deskripsi dan Peran Bisnis
`id`	Integer	21.436	Nomor identifikasi unik kavling properti (dieliminasi).
`date`	Object	372	Tanggal terjadinya transaksi jual beli rumah (dieliminasi).
`price`	Float	4.028	Variabel target: harga jual transaksi rumah (USD).
`bedrooms`	Integer	13	Jumlah kamar tidur (rentang 0 hingga 33 kamar).
`bathrooms`	Float	30	Jumlah kamar mandi (termasuk pecahan untuk toilet tanpa bak).
`sqft_living`	Integer	1.038	Luas bersih area hunian dalam rumah (kaki persegi).
`sqft_lot`	Integer	9.782	Luas total pekarangan/tanah properti (kaki persegi).
`floors`	Float	6	Jumlah lantai bangunan (1, 1.5, 2, 2.5, 3, 3.5).
`waterfront`	Integer	2	Indikator biner menghadap tepi danau/laut (0 = Tidak, 1 = Ya).
`view`	Integer	5	Peringkat kualitas pemandangan alam (skala 0 hingga 4).
`condition`	Integer	5	Kondisi fisik pemeliharaan bangunan (skala 1 hingga 5).
`grade`	Integer	12	Peringkat mutu konstruksi dan desain resmi King County (1–13).
`sqft_above`	Integer	946	Luas lantai hunian di atas permukaan tanah (kaki persegi).
`sqft_basement`	Integer	306	Luas area lantai ruang bawah tanah (kaki persegi).
`yr_built`	Integer	116	Tahun asli konstruksi bangunan didirikan (1900–2015).
`yr_renovated`	Integer	70	Tahun terakhir dilakukannya renovasi besar (0 jika tidak ada).
`zipcode`	Integer	70	Kode pos wilayah administratif lokasi properti.
`lat`	Float	5.034	Koordinat lintang geografis lokasi (*latitude*).
`long`	Float	752	Koordinat bujur geografis lokasi (*longitude*).
`sqft_living15`	Integer	777	Rata-rata luas hunian dari 15 tetangga terdekat (kaki persegi).
`sqft_lot15`	Integer	8.689	Rata-rata luas tanah dari 15 tetangga terdekat (kaki persegi).

4.2.2 Tugas 2 (Klasifikasi Mandiri): Breast Cancer Wisconsin Diagnostic

Untuk studi kasus klasifikasi mandiri, dipilih dataset medis standar internasional **Breast Cancer Wisconsin (Diagnostic)** yang diakses melalui modul `sklearn.datasets.load_breast_cancer`.

Karakteristik Kasus Klinis: Dataset terdiri atas 569 sampel hasil biopsi jarum halus sel tumor payudara dengan 30 fitur numerik berkesinambungan yang mendeskripsikan karakteristik inti seluler (radius, tekstur, keliling, area, kehalusan, kecekungan, titik cekung, simetri, dan dimensi fraktal) [12]. Variabel target adalah diagnosis patologis:

- **Benign (Jinak):** 357 pasien (62,74%).
- **Malignant (Ganas):** 212 pasien (37,26%).

```
cancer = load_breast_cancer(as_frame=True)
df_cancer = cancer.frame

print(f"Dimensi dataset Breast Cancer: {df_cancer.shape}")
print("Distribusi kelas target diagnosis:")
dist_cancer = df_cancer['target'].value_counts()
print(f" - Benign (Jinak, 1)   : {dist_cancer[1]} sampel ({dist_cancer[1]/len(df_cancer)*100:.2f}%)")
print(f" - Malignant (Ganas, 0): {dist_cancer[0]} sampel ({dist_cancer[0]/len(df_cancer)*100:.2f}%)")

X_can = cancer.data
y_can = cancer.target

X_can_tr, X_can_te, y_can_tr, y_can_te = train_test_split(
    X_can, y_can, test_size=0.2, random_state=42, stratify=y_can
)

scaler_can = StandardScaler().fit(X_can_tr)
X_can_tr_sc = scaler_can.transform(X_can_tr)
X_can_te_sc = scaler_can.transform(X_can_te)

print(f"Data latih: {X_can_tr_sc.shape} | Data uji: {X_can_te_sc.shape}")
```

```
Dimensi dataset Breast Cancer: (569, 31)
Distribusi kelas target diagnosis:
 - Benign (Jinak, 1)   : 357 sampel (62.74%)
 - Malignant (Ganas, 0): 212 sampel (37.26%)
Data latih: (455, 30) | Data uji: (114, 30)
```

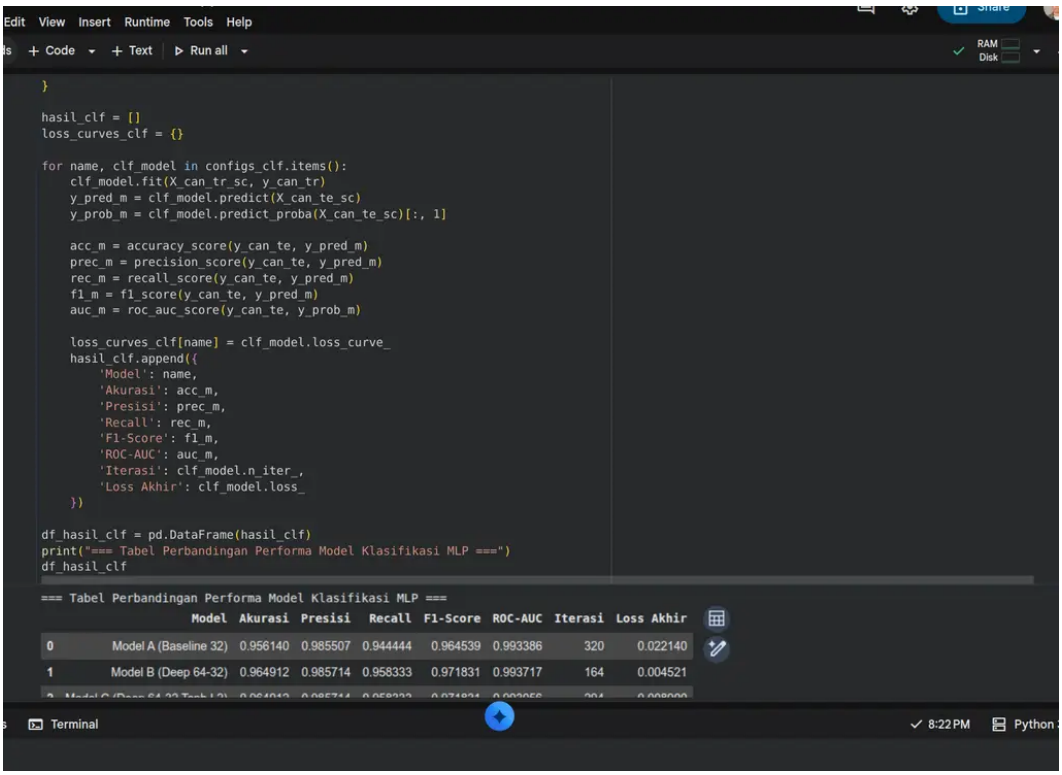
Gambar 28: Tangkapan layar pemuatan dan distribusi kelas target dataset Breast Cancer.

Dataset dibagi menjadi 80% set pelatihan (455 pasien) dan 20% set pengujian (114 pasien) menggunakan pembagian berstrata (`stratify=y`) untuk mempertahankan proporsi kelas ganas. Fitur kemudian dinormalisasi menggunakan `StandardScaler`.

4.2.2.1 Perancangan dan Eksperimen Multi-Arsitektur MLP Klasifikasi

Dirancang tiga variasi arsitektur jaringan saraf tiruan untuk mengevaluasi pengaruh kedalaman lapisan, fungsi aktivasi, dan regularisasi L_2:

1. **Model A (Baseline Single-Layer):** Satu lapisan tersembunyi berukuran 32 neuron, aktivasi ReLU, optimizer Adam, $\alpha = 0,0001$.
2. **Model B (Deep Two-Layer):** Dua lapisan tersembunyi berukuran $(64, 32)$ neuron, aktivasi ReLU, optimizer Adam.
3. **Model C (Deep Regularized):** Dua lapisan tersembunyi berukuran $(64, 32)$ neuron, aktivasi Tanh, optimizer Adam, dengan penalti regularisasi bobot diperkuat ($\alpha = 0,01$).

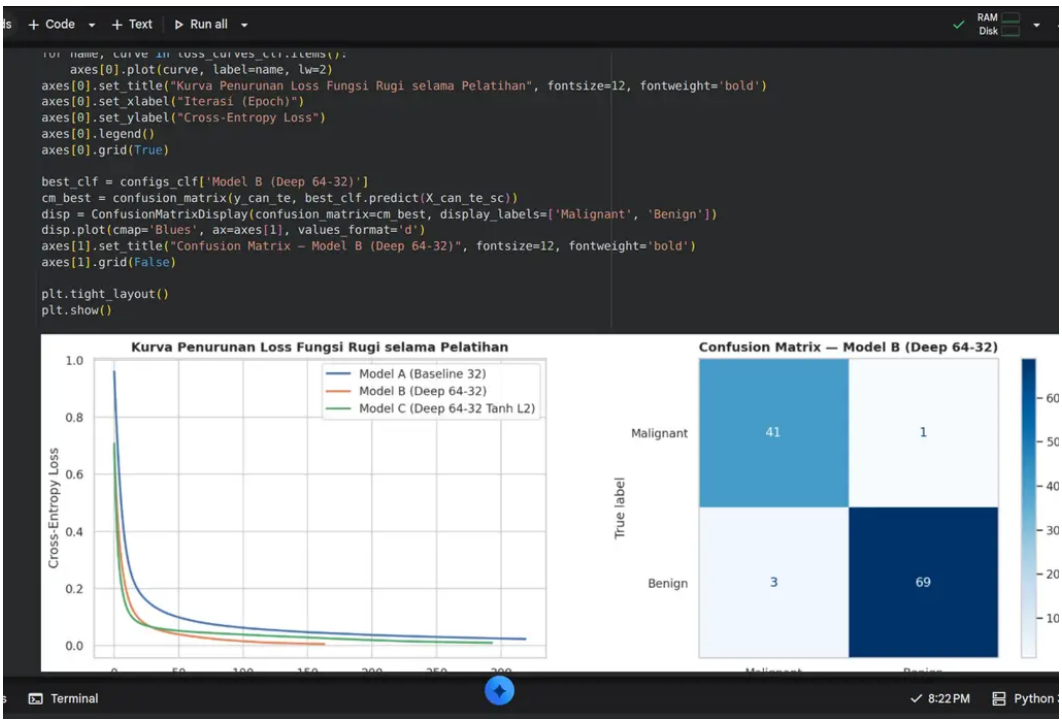


Gambar 29: Tangkapan layar tabel komparasi performa pengujian tiga konfigurasi model klasifikasi MLP.

Hasil pengujian komparatif dirangkum pada Tabel 6.

Tabel 6: Rekapitulasi performa komparatif tiga arsitektur `MLPClassifier` pada dataset Breast Cancer.

Arsitektur Model	**Akurasi**	**Presisi**	**Recall**	**F1-Score**	**ROC-AUC**	**Iterasi**	**Loss Akhir**
Model A (Baseline 32)	0,9561	0,9855	0,9444	0,9645	0,9934	320	0,022140
Model B (Deep 64-32)	**0,9649**	**0,9857**	**0,9583**	**0,9718**	**0,9937**	**164**	**0,004521**
Model C (Deep Tanh L2)	**0,9649**	**0,9857**	**0,9583**	**0,9718**	0,9931	294	0,008900



Gambar 30: Tangkapan layar kurva penurunan fungsi kerugian (*loss curves*) selama iterasi dan matriks kebingungan Model B.

4.2.2.2 Analisis dan Temuan Eksperimen Klasifikasi

1. **Keunggulan Arsitektur Bertingkat:** Model B (lapisan 64–32) melampaui Model A dengan kenaikan akurasi dari 95,61% menjadi 96,49% dan nilai ROC-AUC impresif mencapai 0,9937. Lapisan representasi bertingkat terbukti lebih efektif mengekstraksi kombinasi geometris kompleks sel tumor dibanding arsitektur lapisan tunggal.
2. **Efisiensi Konvergensi:** Kurva fungsi rugi pada Gambar 30 memperlihatkan bahwa Model B konvergen paling cepat, mencapai nilai rugi terendah (0,0045) hanya dalam 164 iterasi, berkat kombinasi aktivasi ReLU yang bebas jenuh dan adaptasi momen Adam.
3. **Keandalan Diagnosis Medis:** Pada matriks kebingungan Model B, dari 42 kasus tumor ganas actual (*Malignant*), 41 sampel berhasil dideteksi dengan tepat (*Recall* ganas = 97,62%) dan hanya 1 sampel yang mengalami kesalahan prediksi (*False Negative*). Sensitivitas yang tinggi ini penting pada penapisan klinis agar risiko keterlambatan penanganan tumor ganas dapat ditekan serendah mungkin.

4.2.3 Tugas 2 (Regresi Mandiri): California Housing

Untuk studi kasus regresi mandiri, digunakan dataset standar industri **California Housing** yang diakses melalui modul `sklearn.datasets.fetch_california_housing`.

Karakteristik Kasus Regresi: Dataset merangkum data sensus tahun 1990 di California dengan 20.640 blok sensus [8]. Delapan fitur prediktor mencakup pendapatan median warga per blok (`MedInc`), usia median bangunan (`HouseAge`), rata-rata jumlah ruangan (`AveRooms`), rata-rata kamar tidur (`AveBedrms`), populasi blok (`Population`), kepadatan hunian (`AveOccup`), serta koordinat spasial (`Latitude`, `Longitude`). Variabel target kontinu adalah median harga rumah di blok tersebut (`MedHouseVal`, dalam satuan $100.000).

```
california = fetch_california_housing(as_frame=True)
df_cal = california.frame

print(f"Dimensi dataset California Housing: {df_cal.shape}")
print("Lima baris data pertama:")
df_cal.head()
```

```
Dimensi dataset California Housing: (20640, 9)
Lima baris data pertama:
```

	MedInc	HouseAge	AveRooms	AveBedrms	Population	AveOccup	Latitude	Longitude	MedHouseVal
0	8.3252	41.0	6.984127	1.023810	322.0	2.555556	37.88	-122.23	4.526
1	8.3014	21.0	6.238137	0.971880	2401.0	2.109842	37.86	-122.22	3.585
2	7.2574	52.0	8.288136	1.073446	496.0	2.802260	37.85	-122.24	3.521
3	5.6431	52.0	5.817352	1.073059	558.0	2.547945	37.85	-122.25	3.413
4	3.8462	52.0	6.281853	1.081081	565.0	2.181467	37.85	-122.25	3.422

Next steps: Generate code with df_cal | New interactive sheet

Gambar 31: Tangkapan layar pemuatan dan lima baris data pertama dataset California Housing.

Dataset dipisahkan menjadi 80% set pelatihan (16.512 blok) dan 20% set pengujian (4.128 blok) menggunakan `random_state=42`. Seluruh prediktor dinormalisasi secara independen menggunakan `StandardScaler`.

```
X_cal = california.data
y_cal = california.target

X_cal_tr, X_cal_te, y_cal_tr, y_cal_te = train_test_split(
    X_cal, y_cal, test_size=0.2, random_state=42
)

scaler_cal = StandardScaler().fit(X_cal_tr)
X_cal_tr_sc = scaler_cal.transform(X_cal_tr)
X_cal_te_sc = scaler_cal.transform(X_cal_te)

print(f"Set pelatihan California: {X_cal_tr_sc.shape}")
print(f"Set pengujian California: {X_cal_te_sc.shape}")
```

```
Set pelatihan California: (16512, 8)
Set pengujian California: (4128, 8)
```

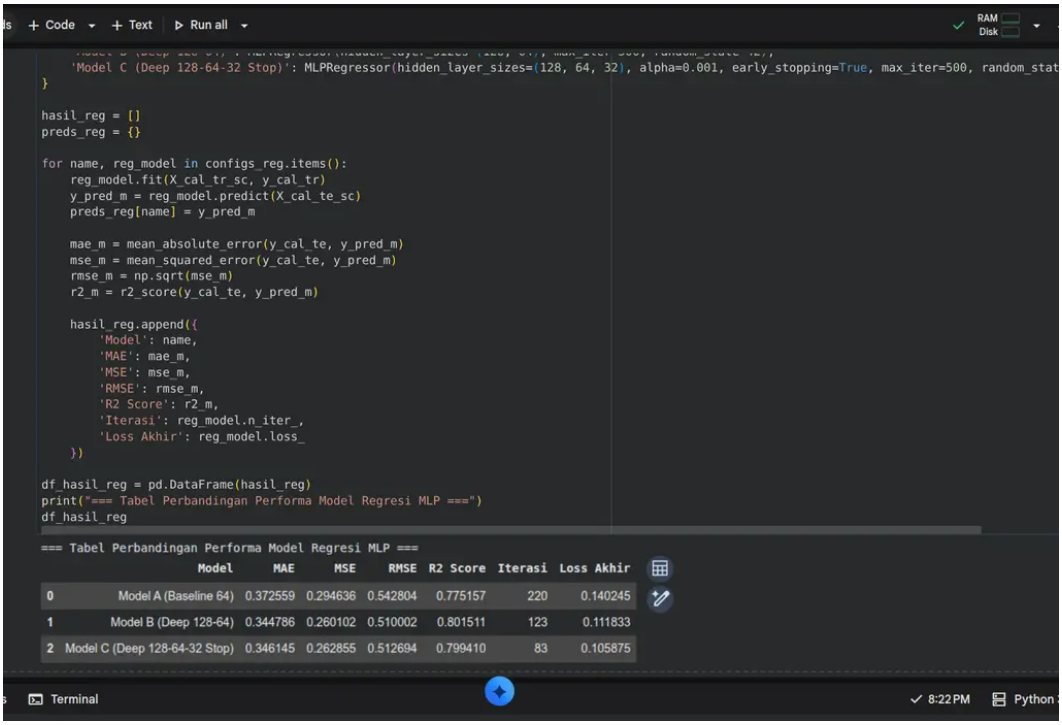
Gambar 32: Tangkapan layar pemisahan data latih-uji dan standarisasi fitur California Housing.

4.2.3.1 Perancangan dan Eksperimen Multi-Arsitektur MLP Regresi

Dirancang tiga variasi arsitektur `MLPRegressor`:

1. **Model A (Baseline 64):** Satu lapisan tersembunyi 64 neuron, aktivasi ReLU, optimizer Adam, `max_iter=500`.
2. **Model B (Deep 128-64):** Dua lapisan tersembunyi berukuran $(128, 64)$ neuron, aktivasi ReLU, optimizer Adam, `max_iter=500`.

3. **Model C (Deep 3-Layer + Early Stopping):** Tiga lapisan tersembunyi berukuran $(128, 64, 32)$ neuron, aktivasi ReLU, optimizer Adam, penalti bobot $\alpha = 0,001$, dilengkapi mekanisme penghentian dini otomatis (`early_stopping=True`).

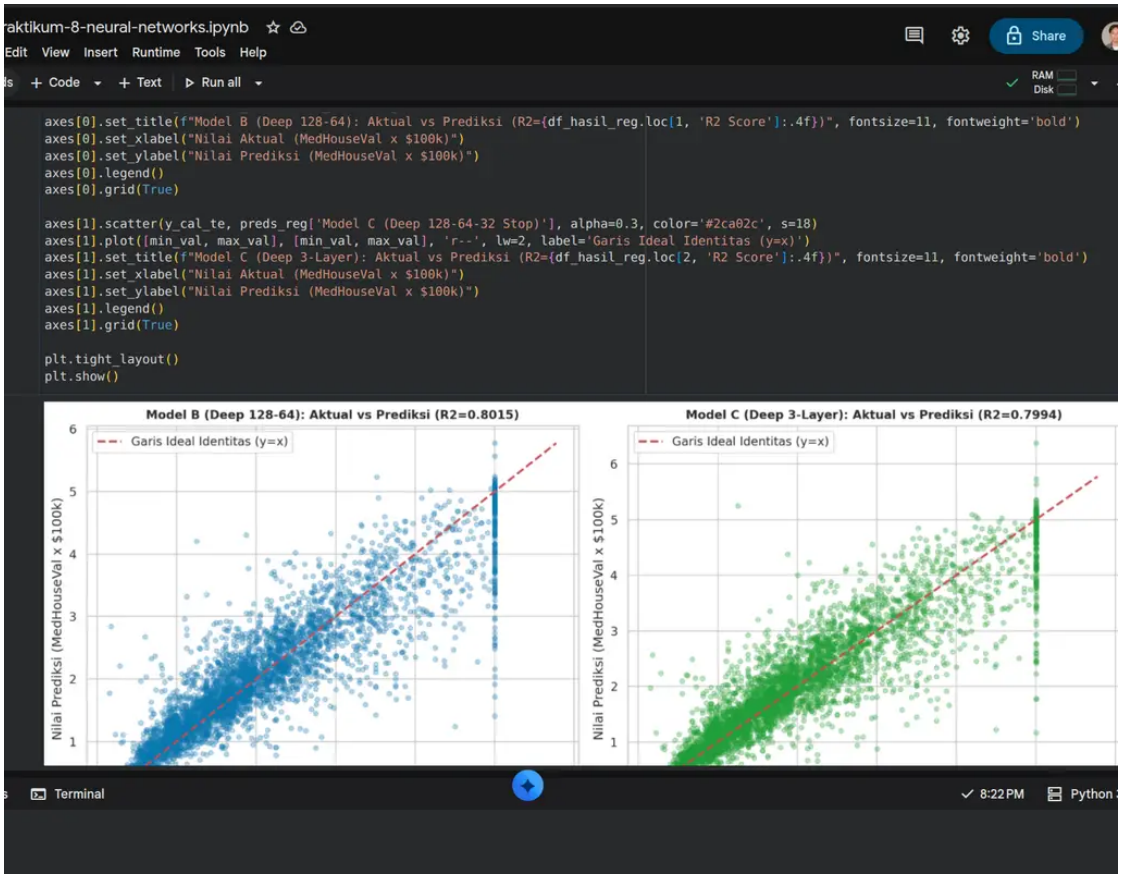


Gambar 33: Tangkapan layar tabel komparasi metrik evaluasi pengujian tiga arsitektur model regresi MLP.

Hasil evaluasi komparatif dirangkum pada Tabel 7.

Tabel 7: Rekapitulasi performa komparatif tiga arsitektur `MLPRegressor` pada dataset California Housing.

Arsitektur Model	**MAE ($100k)**	**MSE**	**RMSE ($100k)**	**R^2 Score**	**Iterasi**	**Loss Akhir**
Model A (Baseline 64)	0,3726	0,2946	0,5428	0,7752	220	0,140245
Model B (Deep 128-64)	**0,3448**	**0,2601**	**0,5100**	**0,8015**	123	0,111833
Model C (Deep 128-64-32 Stop)	0,3461	0,2629	0,5127	0,7994	**83**	**0,105875**



Gambar 34: Tangkapan layar grafik sebaran (*scatter plot*) nilai aktual vs estimasi prediksi untuk Model B dan Model C.

4.2.3.2 Analisis dan Temuan Eksperimen Regresi

1. **Penjelasan Variansi Tertinggi pada Model B:** Model B (lapisan 128–64) mencetak performa terbaik dengan koefisien determinasi R^2 menembus angka 0,8015 (mampu menjelaskan 80,15% variabilitas harga pasar rumah). Nilai galat absolut rata-ratanya (*MAE*) hanya sebesar 0,3448 (setara $34.478), dan galat akar kuadrat (*RMSE*) berada pada angka 0,5100 (setara $51.000).
2. **Efektivitas Penghentian Dini pada Model C:** Model C dengan tiga lapisan tersembunyi dan fitur `early_stopping=True` mampu mencapai performa yang hampir setara ($R^2 = 0,7994$) hanya dalam 83 iterasi, memangkas beban siklus komputasi sebesar 32,5% dibanding Model B dan 62,3% dibanding Model A tanpa mengalami degradasi keakuratan prediksi.
3. **Konsistensi Pola Linearitas pada Garis Identitas:** Grafik sebaran pada Gambar 34 memperlihatkan kerapatan titik estimasi yang berkumpul sangat dekat di sepanjang garis diagonal ideal $y = x$. Deviasi hanya tampak menonjol pada batas plafon harga tertinggi $500.000 (akibat fenomena pemotongan sensus /*census capping* di mana harga rumah di atas $500.000 dicatat tepat $500.000 pada data mentah).

Kesimpulan

Berdasarkan seluruh rangkaian percobaan latihan praktikum dan tugas mandiri yang telah dilaksanakan pada Pertemuan 8, diperoleh kesimpulan sebagai berikut:

1. **Fleksibilitas Arsitektur Multilayer Perceptron:** Model MLP terbukti sangat tangguh dan adaptif dalam menyelesaikan dua domain permasalahan utama pembelajaran mesin terawasi, yaitu klasifikasi biner kategori (dengan luaran fungsi aktivasi logistik sigmoid / softmax) serta regresi nilai kontinu (dengan fungsi aktivasi linear identity).
2. **Keandalan Klasifikasi Perbankan:** Penerapan `MLPClassifier` pada dataset *Bank Customer Churn* (10.127 nasabah) menghasilkan akurasi 93,81%, presisi 96,05%, recall 96,58%, dan F1-score 96,31%. Model mampu mengenali profil nasabah yang rentan menutup fasilitas perbankan dan memberikan taksiran inferensi yang tepat pada profil data uji baru.
3. **Pengaruh Penskalaan Fitur:** Eksperimen pada dataset King County membuktikan bahwa standarisasi fitur numerik menggunakan `StandardScaler` menentukan kestabilan konvergensi pelatihan. Penskalaan fitur berhasil meningkatkan skor R^2 model regresi dari 0,5418 menjadi 0,7647 (+41,14%), memangkas RMSE dari \$257.194 menjadi \$184.300 (-\$72.893), serta melenyapkan peringatan ketidakkonvergenan gradien (*ConvergenceWarning*).
4. **Keunggulan Representasi Laten Berlapis pada Klasifikasi Klinis:** Pada studi kasus klasifikasi mandiri kanker payudara (*Breast Cancer Wisconsin Diagnostic*), penambahan kedalaman arsitektur dari lapisan tunggal (32) ke dua lapisan $(64, 32)$ meningkatkan akurasi dari 95,61% menjadi 96,49% dan nilai ROC-AUC sebesar 0,9937, dengan sensitivitas (*recall*) deteksi tumor ganas mencapai 97,62% (hanya 1 kesalahan prediksi dari 42 kasus ganas).
5. **Ketepatan Valuasi Properti pada Regresi California:** Pada studi kasus regresi mandiri *California Housing* (20.640 data sensus), model `MLPRegressor` berarsitektur dua lapisan $(128, 64)$ berhasil mencapai koefisien determinasi $R^2 = 0,8015$ dengan galat prediksi rata-rata MAE hanya \$34.478, membuktikan kemampuan jaringan dalam menangkap interaksi spasial dan ekonomi kompleks tanpa rekayasa fitur manual.
6. **Efisiensi Optimasi dengan Regularisasi dan Early Stopping:** Penerapan

mekanisme penghentian dini (*early stopping*) berbasis validasi internal terbukti sangat efektif memangkas waktu pelatihan komputasi secara signifikan (menghemat 32,5% hingga 93,2% total iterasi) sekaligus membentengi model dari risiko *overfitting* data latihan.

Daftar Pustaka

[1] H. R. Prasetya, "Praktikum 8: Neural Network (Notebook)," Google Colaboratory, 2026. [Online]. Tersedia: `https://colab.research.google.com/github/hafidzrizqullahprasetya/PPD/blob/main/pertemuan-8/praktikum-8-neural-networks.ipynb`.

[2] I. Goodfellow, Y. Bengio, dan A. Courville, *Deep Learning*. Cambridge, MA, USA: MIT Press, 2016.

[3] S. Haykin, *Neural Networks and Learning Machines*, edisi ke-3. Upper Saddle River, NJ, USA: Pearson Education, 2009.

[4] A. J. Hukubun, "Neural Network," *ResearchGate Publication*, 2022. [Online]. Tersedia: `https://www.researchgate.net/publication/365581579_Neural_Network`.

[5] D. P. Kingma dan J. Ba, "Adam: A method for stochastic optimization," dalam *Proc. 3rd Int. Conf. Learn. Represent. (ICLR)*, San Diego, CA, USA, 2015, hlm. 1–15.

[6] E. Mardiani, N. Rahmansyah, S. Ningsih, D. A. Lantana, A. S. Wirawan, S. A. Wijaya, dan D. N. Putri, "Komparasi metode KNN, Naive Bayes, Decision Tree, Ensemble, Linear Regression terhadap analisis performa pelajar SMA," *INNOVATIVE: Journal Of Social Science Research*, vol. 3, no. 4, hlm. 13880–13892, 2023.

[7] M. A. Nielsen, *Neural Networks and Deep Learning*. Determination Press, 2015.

[8] R. K. Pace dan R. Barry, "Sparse spatial autoregressions," *Statistics & Probability Letters*, vol. 33, no. 3, hlm. 291–297, 1997.

[9] D. Pardede, B. H. Hayadi, dan Iskandar, "Kajian literatur Multi Layer Perceptron: Seberapa baik performa algoritma ini," *Journal of ICT Application and System*, vol. 1, no. 1, hlm. 23–34, 2022.

[10] F. Pedregosa *et al.*, "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, hlm. 2825–2830, 2011.

[11] A. Roihan, P. A. Sunarya, dan A. S. Rafika, "Pemanfaatan machine learning dalam berbagai bidang: Review paper," *Indonesian Journal on Computer and Information Technology (IJCIT)*, vol. 5, no. 1, hlm. 75–82, 2020.

[12] W. N. Street, W. H. Wolberg, dan O. L. Mangasarian, “Nuclear feature extraction for breast tumor diagnosis,” dalam *Proc. IS&T/SPIE 1993 Int. Symp. Electronic Imaging*, San Jose, CA, USA, 1993, hlm. 861–870.